


Artigo à Prova de Futuro: Jornada de Open Science na Prática



Artigo à Prova de Futuro
Jornada de Open Science na Prática

Pablo Rogers
dez, 2025

Índice

 O Curso	1
Instrutores	1
Objetivos	1
Ementa	2
Metodologia	2
Mudanças	3
Citação	4
Licença	4
 Agenda	5
 Pré-requisitos	6
Github	6
Git	6
Zotero	7
OSF	7
Zenodo	7
RStudio	7
Docker	8
Máquinas Virtuais	8
1 Introdução à Ciência Aberta	9
1.1 Objetivos de Aprendizagem	9
1.2 Contextualização	9
1.3 Ciência Aberta no Brasil	10
1.4 Críticas brasileiras à Ciência Aberta	11
1.5 Perspectiva da Ciência Aberta	12
1.6 Educação em Ciência Aberta	12
1.7 Da Teoria à Prática: Implementando Ciência Aberta	13
1.8 Preparação para a Aula	18
2 Repositórios da Ciência Aberta	19
2.1 Objetivos de Aprendizagem	19
2.2 Contextualização	19
2.3 Pré-registro e Transparência Metodológica	22
2.4 Identificadores Persistentes e Rastreabilidade	23
2.5 OSF no Ecossistema de Ferramentas	23

2.6	Quando Não Usar OSF	24
2.7	Preparação para a Aula	24
3	Gerenciamento de Referências e Bibliotecas	25
3.1	Objetivos de Aprendizagem	25
3.2	Contextualização	25
3.3	O Zotero no Ciclo de Pesquisa	27
3.4	Integração com Fluxos de Trabalho Reprodutíveis	28
3.5	IA e Descoberta de Literatura	28
3.6	Indo Além das Funcionalidades Básicas	28
3.7	Preparação para a Aula	29
4	Organização de Projetos	31
4.1	Objetivos de Aprendizagem	31
4.2	Contextualização	31
4.3	Gerenciamento de Dados	32
4.4	Código e Software	33
4.5	Colaboração	33
4.6	Organização de Projetos	34
4.7	Controle de Mudanças	35
4.8	Redação de Manuscritos	36
4.9	Começando de Onde Você Está	36
4.10	Considerações Finais	38
4.11	Preparação para a Aula	38
5	Controle de versão	40
5.1	Objetivos de Aprendizagem	40
5.2	Contextualização	40
5.3	Por Que Ferramentas Simples Não Bastam	42
5.4	Git e GitHub: Ferramentas Complementares	43
5.5	Workflows de Controle de Versão para Pesquisa Reprodutível	44
5.6	Preparação para a Aula	48
6	Documentos Reprodutíveis	49
6.1	Objetivos de aprendizagem	49
6.2	Contextualização	49
6.3	Quarto: Sistema de Publicação Científica	50
6.4	ARTE: Da Reprodutibilidade Mínima à Adequada	52
6.5	Preparação para a Aula	53
7	Controle de Ambiente	55
7.1	Objetivos de Aprendizagem	55
7.2	Contextualização	55
7.3	Soluções para Controle do Ambiente	56
7.4	Combinando Soluções: renv + Docker	59
7.5	Soluções em Nuvem	60
7.6	ARTE: Implementando Reprodutibilidade Completa	61
7.7	Preparação para a Aula	62
8	IA Aplicada à Pesquisa Reprodutível	63

8.1	Objetivos de Aprendizagem	63
8.2	Contextualização	63
8.3	Aplicações Práticas da IA na Pesquisa	64
8.4	Transparência e Questões Éticas	65
8.5	Proposta de Integração: FAIR + IA	65
8.6	Níveis de Integração com Ciência Aberta	66
8.7	Boas Práticas e Recomendações	67
8.8	Aplicações da IA neste Curso	67
8.9	Um Exemplo Prático: A Elaboração dessa Página	69
8.10	Preparação para a Aula	70
Referências		71

O Curso

Página do curso “**Artigo à Prova de Futuro: Jornada de Open Science na Prática**”. Nesse site você encontrará informações sobre o programa do curso, materiais didáticos (resumos, notas de aulas e vídeos) e sugestões de leituras sobre a prática da Ciência Aberta (artigos e livros). Ele foi concebido para ser um **Recurso Educacional Aberto (REA)** e, portanto, todo o conteúdo está disponível gratuitamente para consulta e download. O site é um guia para os que buscam conhecimento sobre ferramentas e práticas relacionadas à Ciência Aberta e à Pesquisa Reprodutível, mas principalmente, uma fonte inicial de leitura e estudo para os participantes do curso.

Instrutores

O curso é coordenado e ministrado por [Pablo Rogers](#), Doutor em Administração pela Universidade de São Paulo (FEA/USP) e professor de finanças e métodos quantitativos desde 2005. Em sua [página de perfil do Github](#) você encontra informações de seus trabalhos recentes, e no seu [site pessoal](#), detalhes sobre suas formações, competências, trajetória e projetos.

O curso tem a parceria do Prof. Ricardo Limongi, Doutor em Administração pela Fundação Getúlio Vargas (FGV-SP), professor de marketing e métodos quantitativos desde 2008 e atual editor chefe da Brazilian Administration Review (BAR). Em seu [perfil do Instagram](#) é possível acompanhar sua agenda de atividades, cursos e palestras sobre Inteligência Artificial (IA) aplicada aos negócios e pesquisa. Em seu [canal do YouTube](#), você encontra vídeos das suas atividades: congressos, palestras, aulas, etc.

Objetivos

O curso tem objetivo de introduzir os conceitos relacionados com a Ciência Aberta (CA) e a Prática da Pesquisa Reprodutível. O curso aborda temas introdutórios sobre CA, com foco no ferramental disponível para tornar a pesquisa mais transparente, reprodutível e acessível.

Ao final pretendemos que os pesquisadores e estudantes de pós-graduação estejam gabaritados para implementar o [ARTE \(Article Reproducibility Template & Environment\)](#), por exemplo, e os professores empenhados em desenvolver um Recurso Didático Aberto (REA), tal como o exemplo dessa disciplina: [Finanças Corporativas de Curto Prazo](#).

Trata-se de um curso intermitente programado para acontecer em 8 encontros de 2 horas/aula, totalizando 16 horas/aula. Para alcançar um número maior de interessadosO

o curso é remoto e síncrono. Ele poderá acontecer mais de uma vez no ano, com datas e horários a serem definidos. Para o último calendário do curso, consulte a seção [Agenda](#).

O curso é gratuito e com de certificado de extensão pela Universidade Federal de Uberlândia (UFU). As inscrições são feitas por meio de um [formulário](#) intermediado pelo projeto [Psico&Econo_METRIA](#). Quando da previsão das datas ou início do curso, uma campanha de e-mail marketing divulgará para os inscritos na [lista de espera](#) e para coordenações de pós-graduações selecionadas.

As vagas são limitadas e a seleção será feita por ordem de inscrição. Após o preenchimento das vagas, os demais interessados serão inscritos automaticamente numa lista de espera e, tempestivamente, serão avisados sobre a próxima edição do curso. Após selecionados, os inscritos receberão um e-mail com instruções para acesso à plataforma de aulas síncronas e para a realização das atividades prévias ao curso.

Ementa

Introdução da Ciência Aberta / Repositórios da Ciência Aberta / Gerenciamento de Referências e Bibliotecas / Organização de Projetos, Dados e Scripts / Controle de Versão / Documentos Dinâmicos e Reprodutíveis / Controle de Ambiente / IA Aplicada à Pesquisa Reprodutível.

Metodologia

O curso foi concebido para acontecer de forma remota e síncrona, com aulas expositivas, porém em grande medida, o conteúdo é essencialmente prático. As aulas serão gravadas e disponibilizadas no [canal do YouTube do projeto Psico&Econo_METRIA](#) (se inscreva ). O conteúdo principal do curso é síncrono, e pode mudar de edição para edição, no entanto, algumas aulas, principalmente para cadastros e instalações das ferramentas utilizadas, podem ser disponibilizadas de forma assíncrona, tal como na página [Pré-requisitos](#).

A proposta do curso busca seguir de perto a mensagem de Dogucu & Çetinkaya-Rundel (2022) e ser um **Recurso Educacional Aberto (REA)**. Nesse artigo as autoras abordam a importância da reprodutibilidade na ciência de dados, tanto na pesquisa quanto no ensino. Elas recomendam que os professores-pesquisadores adotem fluxos de trabalho reprodutíveis em suas pesquisas e ensinem esses fluxos de trabalho aos seus alunos. Elas propõem uma dimensão para as práticas de reprodutibilidade, focada exclusivamente nas ferramentas para o ensino (todos os materiais de ensino devem ser computacionalmente reprodutíveis, bem documentados e abertos).

O REA aqui proposto é para orientação e contextualização dos participantes do curso sobre cada um dos módulos ministrados. Dessa forma, esperamos que em cada uma das aulas (módulos) os alunos façam uma leitura prévia da página do conteúdo a ser ministrado, para que possam acompanhar melhor as explicações e demonstrações feitas durante as aulas síncronas.

Este curso adota o uso de **Inteligência Artificial Generativa (IA)**  como ferramenta de apoio metodológico e pedagógico, alinhado às diretrizes éticas e responsáveis propostas por Sampaio et al. (2024). A IA é utilizada exclusivamente em funções complementares — como resumo de materiais, auxílio na codificação, estruturação de conteúdos, busca

de literatura, elaboração de recursos visuais, revisão e tradução — **sem substituir o trabalho intelectual, crítico e autoral do pesquisador**. Consideramos que o uso ético e transparente de IA alinha-se perfeitamente com os princípios da **Ciência Aberta** : transparência, reprodutibilidade e compartilhamento de processos.

Mudanças

As principais mudanças implementadas na edição atual do curso em relação à edição anterior foram:

- 1 **OSF** – exploramos a nova estrutura e layout do repositório, lançada em outubro de 2025.
- 2 **Zotero 7** – abordamos a versão atualizada dessa ferramenta acessória, em relação à versão 6 trabalhada anteriormente.
- 3 **Projeto TIER 4.0** – boas práticas para organização de pastas e arquivos.
- 4 **ARTE – Article Template Reproducibility & Environment** – modelo para artigos reprodutíveis implementado transversalmente ao longo de vários módulos do curso.
- 5 **Docker** – foco maior em ambientes portáteis.
- 6 **IA Aplicada à Pesquisa Reprodutível** – módulo reformulado abordando o uso ético e responsável da inteligência artificial na pesquisa reprodutível, alinhado às diretrizes de Sampaio et al. (2024).
- 7 **Material** – totalmente reformulado, atualizado e implementado com recursos didáticos extras.

Citação

Se você utilizar o material desse curso em algum trabalho acadêmico, por favor, cite o livro do curso da seguinte forma:

Rogers, P. (2024). Artigo à Prova de Futuro: Jornada de Open Science na Prática (1.0). Disponível em: <https://phdpablo.github.io/curso-open-science/>.
<https://doi.org/10.5281/zenodo.12593928>

Licença

Artigo à Prova de Futuro: Jornada de Open Science na Prática by Pablo Rogers is licensed under CC BY-NC-SA 4.0

Agenda

Planejamento dos dias  e horários das aulas , conforme a ementa do curso. Na seção de cada uma das aulas temos materiais adicionais para o respectivo conteúdo. Quando disponível, por aqui, poderás acessar os slides utilizados nas aulas , aulas gravadas ou indicações de vídeo  e leituras básica sobre os conteúdos .

Aula/Conteúdo	Data	Material Principal	Instrutor
Introdução à CA	 18/11/25  20:30	  	Ricardo Limongi
Repositórios da CA	 13/11/25  19:00	  	Pablo Rogers
Gerenciamento de Referências	 25/11/25  19:00	  	Pablo Rogers
Gestão de Projetos	 27/11/27  19:00	  	Pablo Rogers
Controle de Versão	 02/12/25  19:00	  	Pablo Rogers
Documentos Dinâmicos	 04/12/25  19:00	  	Pablo Rogers
Controle de Ambiente	 09/12/25  19:00	  	Pablo Rogers
IA para Pesquisas Reprodutíveis	 11/12/25  19:00	  	Ricardo Limongi



Pré-requisitos

O curso não exige conhecimento prévio em programação, mas é recomendável que o aluno tenha familiaridade com o uso de computadores e com a escrita de textos científicos. Nesse sentido, não é necessário ter conhecimento prévio sobre as ferramentas e plataformas que utilizaremos no curso: Zotero, OSF, Zenodo, Git, Github, RStudio, Quarto/RMarkdown, Docker, etc; mas desejável que o aluno já as tenha instalado e/ou cadastro nas plataformas.

Abaixo descrevemos sucintamente o que é cada uma dessas ferramentas e plataformas, e como você pode se preparar para o curso. Também apresentamos um vídeo curto sobre a instalação e/ou cadastro em cada uma delas. A ideia é que você já tenha todas as ferramentas e plataformas instaladas e/ou cadastro antes do início do curso, para que possamos focar no conteúdo e prática durante as aulas síncronas.

Github

Primeiramente, se cadastre no Github: <https://github.com/signup>, pois com ele você poderá acessar o material do curso e interagir com os demais participantes. E com a conta do Github você também poderá se cadastrar em outras plataformas, como o Zenodo, OSF, etc. Algumas features que aprenderemos no curso exigem o vínculo entre as contas. Se for professor ou estudante, você pode solicitar o [GitHub Education](#) e ter acesso, por exemplo, ao Copilot, uma das ferramentas de IA mais interessante. Por isso, é importante que você se cadastre com um e-mail institucional. Use o mesmo e-mail para se cadastrar em todas plataformas.

<https://youtu.be/Nmjh9KsV6eU>

Git

Github não é a mesma coisa que Git. O Github é uma plataforma, e o Git é uma ferramenta. Instale a versão mais recente do Git: <https://git-scm.com/downloads>. O Git é uma ferramenta de controle de versão, e o Github é uma plataforma que utiliza o Git. O Git é uma ferramenta essencial para a prática da CA, e é uma das ferramentas mais importantes para o pesquisador que deseja tornar sua pesquisa mais transparente e reprodutível.

<https://youtu.be/XCa6mE0bEI0>

Zotero

Baixe a versão mais recente do Zotero: <https://www.zotero.org/download/> e cadastre uma conta: <https://www.zotero.org/user/register/>. Vamos discutir sobre o Zotero e diversos plugins que são úteis no dia-a-dia do pesquisador. Atualmente, o Zotero é a ferramenta mais completa para gerenciamento de referências e bibliotecas, e se integra nativamente com o RStudio e diversas ferramentas de IA.

<https://youtu.be/Nyi3moDTQ64>

OSF

Cadastre no Open Science Framework (OSF): <https://osf.io/register/>. Como veremos, essa plataforma é uma das mais importantes para a prática da CA. Ela está no começo (pré-registro) e no final (repositório de dados e pré-print) do ciclo de vida (workflow) de um projeto de pesquisa. O vídeo abaixo mostra o cadastro nessa plataforma antes das mudanças de outubro de 2025, mas o processo continua o mesmo.

<https://youtu.be/WQ4O-8O6MwI>

Zenodo

Apesar do Zenodo cumprir funções similares ao OSF e até mesmo ao Github, ele é mais voltado para a publicação de dados e publicações científicas pontuais. Cadastre no Zenodo: <https://zenodo.org/login/> e vincule sua conta com o Github. Isso será útil, principalmente, para geração de DOI de repositórios do Github.

<https://youtu.be/pZaqL3Auxb0>

RStudio

Baixe a versão mais recente do RStudio: <https://posit.co/download/rstudio-desktop/>. O RStudio é uma Integrated Development Environment (IDE) para a linguagem R. O RStudio é uma ferramenta essencial para a prática da CA em R, pois integra as principais soluções que abordaremos no curso (Zotero, Quarto, Git/Github, etc.). A empresa RStudio recentemente mudou o nome para Posit, com o objetivo refletir melhor a expansão da empresa para além do desenvolvimento de ferramentas para R, incluindo Python e outras linguagens. Nesse mesmo link você pode baixar o R, que é a linguagem de programação mais utilizada por cientistas. No curso utilizaremos as versões 4.5.1 do R, 2025.05.1+513 do RStudio e Quarto 1.6.42 (que já vem integrado no RStudio). Assim como o Quarto tem substituído o RMarkdown, a Posit está substituindo o RStudio pelo [Positron](#), que é um “misto” de RStudio + VS Code, e potencialmente veremos em edições futuras de nosso curso. Por hora, focaremos no RStudio.

<https://youtu.be/KM2jxaNIEUk>

Docker

Baixe a versão mais recente do Docker: <https://www.docker.com/products/docker-desktop>. Nesse mesmo link você cria uma conta. O Docker é uma plataforma para desenvolvimento, envio e execução de aplicativos. O Docker é uma ferramenta essencial para a prática da CA, pois permite a criação de ambientes reprodutíveis.

<https://youtu.be/WjXQxhTLlrQ>

Máquinas Virtuais

Embora o curso foque na utilização de containers via Docker para garantir ambientes reprodutíveis, muitos dos Recursos Educacionais Abertos (REA) apresentados ao longo da jornada foram organizados e testados dentro de uma máquina virtual (VM). Por isso, disponibilizamos abaixo uma sequência de vídeos que mostram como configurar uma VM no Windows 11, utilizando duas abordagens:

- **Sandbox:** ambiente temporário e isolado, ideal para testes rápidos.
- **Hyper-V:** solução mais robusta e permanente para virtualização.

Esses vídeos são opcionais e não serão abordados diretamente nas aulas, mas podem ser úteis para quem deseja explorar outras formas de garantir reprodutibilidade e organização dos seus REA.

Sandbox no Windows 11

- [Como habilitar o Sandbox no Windows 11 Pro Pro](#)
- [Como habilitar o Sandbox no Windows 11 Home Home](#)

Esses vídeos mostram como ativar o recurso de Sandbox, mesmo em versões onde ele não está disponível oficialmente. Ideal para quem quer testar rapidamente scripts ou softwares em ambiente isolado.

Hyper-V no Windows 11

- [Como habilitar o Hyper-V no Windows 11 Pro Pro](#)
- [Como habilitar o Hyper-V no Windows 11 Home Home](#)

Esses vídeos explicam como ativar o Hyper-V, mesmo em versões Home, permitindo a criação de ambientes virtuais persistentes e mais completos.

Configuração da Máquina Virtual

- [Como configurar sua primeira máquina virtual no Hyper-V](#)

Este vídeo mostra passo a passo como criar e configurar uma VM no Hyper-V, incluindo alocação de recursos e instalação do sistema operacional.

Capítulo 1

Introdução à Ciência Aberta

1.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender o contexto histórico da crise de reprodutibilidade e o surgimento do movimento de Ciência Aberta como resposta aos desafios contemporâneos da pesquisa científica
- Identificar as diferentes escolas de pensamento e dimensões conceituais da Ciência Aberta, distinguindo entre perspectivas macro (políticas, infraestrutura) e micro (práticas do pesquisador)
- Reconhecer as especificidades da trajetória brasileira rumo à Ciência Aberta, incluindo marcos regulatórios, limitações atuais e correntes críticas no debate nacional
- Compreender o espectro de reprodutibilidade como continuum que organiza práticas abertas em três dimensões (Assets, Platforms, Practices) e três níveis de integração (Data, Code, Linked)
- Identificar os três níveis de reprodutibilidade propostos pelo workflow ARTE (mínima, adequada, completa) e suas respectivas exigências técnicas e metodológicas
- Mapear o arsenal de ferramentas disponíveis para operacionalizar práticas de Ciência Aberta em cada nível do espectro de reprodutibilidade, reconhecendo a adoção não-linear

1.2 Contextualização

A pesquisa científica atual enfrenta vários desafios (Munafò et al., 2017). Problemas como o pequeno tamanho da amostra, pequenos tamanhos de efeito, p-hacking (ajuste indevido de significância estatística) e HARKing (viés positivo de publicação), conflitos de interesse e a competição entre cientistas, têm sido apontados como catalizadores do que se convencionou chamar de “crise de reprodutibilidade” (M. Baker, 2016; Munafò et al., 2017).

Pesquisas apontam que mais de 70% de pesquisadores que tentaram, falharam em reproduzir os experimentos de outros cientistas, e mais da metade falhou em reproduzir seus próprios experimentos (M. Baker, 2016), com estimativa de que 85% dos esforços de pesquisas estejam sendo desperdiçados (Munafò et al., 2017), gerando custos econômicos bilionários (Freedman et al., 2015).

A despeito daqueles que advogam que não existe essa tal “crise de reprodutibilidade” na ciência (Bernard, 2023; Fanelli, 2018; Protzko et al., 2023), a grande maioria da comunidade científica concorda com sua existência e defende a melhoria da transparência, reprodutibilidade e eficiência (M. Baker, 2016).

Nesse contexto, o movimento da Ciência Aberta (CA) tem ganhado notoriedade e mudado a percepção sobre o cenário científico global (Crüwell et al., 2019). Ele busca tornar o conhecimento científico mais acessível, transparente e colaborativo. Se apresenta como uma coleção de práticas de democratização do conhecimento e ruptura com o formato único de divulgação do conhecimento científico (Crüwell et al., 2019; Heinz & Miranda, 2024; Munafò et al., 2017). Ele surge do embate entre aqueles que buscam compartilhar o conhecimento e aqueles que defendem mecanismos de apropriação privada para a produção científica (Heinz & Miranda, 2024).

A CA é um termo complexo e genérico (Vicente-Saez & Martinez-Fuentes, 2018), que representa diversas interpretações, e é considerada um novo modelo de divulgação e produção de resultados científicos por meio do acesso livre e irrestrito ao conhecimento (Heinz & Miranda, 2024). A CA não é apenas um conceito, mas uma proposta prática que influencia o ciclo de vida da pesquisa, desde a concepção até a disseminação dos resultados (Silva & Silveira, 2019).

Existem pelo menos cinco escolas de pensamento dentro da CA. Estas escolas abrangem desde a arquitetura tecnológica necessária para suportar a ciência até a inclusão do público geral na criação de conhecimento, passando pela medição do impacto alternativo, acesso ao conhecimento como um direito humano, e a pesquisa colaborativa como inovação aberta (Silva & Silveira, 2019).

A taxonomia proposta pela **FOSTER** (Facilitate Open Science Training for European Research), e sua releitura revisada e ampliada para o contexto latino americano por Silveira et al. (2023), tendo em vista as recomendações da UNESCO (2021), nos dá uma dimensão da complexidade do assunto (vide ilustração em: <https://doi.org/10.5281/zenodo.7836884>).

1.3 Ciência Aberta no Brasil

O movimento da CA no Brasil está em uma fase transitória (Rezende & Falgueras, 2020), ainda consolidando o acesso aberto, com o governo desempenhando um papel crucial nesse processo. O Brasil tem ganhado destaque por sua abordagem única na implementação da CA. Esta abordagem é moldada por marcos regulatórios que se estendem desde o governo até as instituições e agências de financiamento. Os regulamentos brasileiros, particularmente aqueles que promovem a abertura de dados governamentais, têm um impacto direto na prática científica. Eles incentivam a transparência e facilitam o acesso a dados científicos originados de instituições públicas (Rezende & Falgueras, 2020).

A trajetória brasileira rumo à CA inicia com a abertura de dados na esfera governamental entre 2009 e 2016, evoluindo para a criação de um grupo de trabalho em 2017 pelo

[Ministério da Ciência, Tecnologia, Inovações e Comunicações \(MCTIC\)](#) para desenvolver uma política nacional para a CA. Este esforço concentrou ênfase no reconhecimento dos dados de pesquisa como ativos de desenvolvimento científico, econômico e social, buscando facilitar seu acesso, compartilhamento e reutilização (Rezende & Falgueras, 2020).

Talvez por esse motivo, as políticas institucionais brasileiras revelam um cenário ainda muito influenciado pela “via verde” do movimento de acesso aberto, caracterizado pelo depósito de dados em repositórios digitais abertos, e que o comprometimento efetivo do Brasil com a CA ainda é incipiente. As regulamentações atuais favorecem principalmente o acesso aberto, sem abordar de maneira abrangente outros aspectos da CA (Rezende & Falgueras, 2020). O Brasil é um dos líderes mundiais no fornecimento de acesso universal às suas pesquisas e estudos (Neto et al., 2016), com crescimento estável de sua produção científica disponível em acesso aberto, principalmente, as áreas de Agricultura e Ciência & Tecnologia (Caballero-Rivero et al., 2019).

Em termos de pesquisa acadêmica sobre o tema no Brasil, os estudos são precoces e concentrados na área de Ciência da Informação (Albano et al., 2023). Apesar da maturidade da CA no Brasil, a importância do tema, materializada na quantidade de produção acadêmica, tem aumentado vertiginosamente (Albano et al., 2023), e a dispersão de autores e respectivas instituições que publicam sobre o assunto, parece ser a situação predominante.

Apesar de importantes atores nacionais, tais como [CAPES](#), [CNPq](#) e [SciELO](#), defenderem o crescimento de iniciativas de CA (Mendes-Da-Silva, 2023), o assunto no Brasil parece estar circunscrito em iniciativas de importantes periódicos nacionais sobre dados aberto, capitaneados pelas orientações da [SciELO](#). Considerando o ano de 2024, não encontramos nenhuma pesquisa empírica, sobre a prática da CA no Brasil.

1.4 Críticas brasileiras à Ciência Aberta

A literatura brasileira apresenta uma corrente crítica que questiona se a CA representa efetivamente uma democratização do conhecimento ou se pode funcionar como nova forma de apropriação e dominação de países centrais sobre os periféricos, especialmente por meio do colonialismo de dados, da dependência de infraestruturas digitais externas e da concentração de poder informacional em grandes empresas e instituições do Norte Global (Guimarães Furtado & Evangelista Cunha, 2024; Kronbauer & Oliveira, 2024; Sinãni & Accorssi, 2023). Essas análises destacam riscos de extrativismo de dados, perda de soberania digital e aprofundamento de assimetrias, em um cenário no qual parte significativa dos sistemas nacionais de informação científica opera sobre plataformas controladas por corporações estrangeiras (Guimarães Furtado & Evangelista Cunha, 2024; Sinãni & Accorssi, 2023).

Outra vertente crítica enfatiza a mercantilização da publicação científica e o capitalismo acadêmico, apontando que modelos baseados em Article Processing Charges (APCs) podem deslocar a barreira de acesso para a barreira de publicação, penalizando pesquisadores de contextos periféricos com menor financiamento (Bechi & Almeida, 2024; Neubert & Rodrigues, 2021; Silveira et al., 2025). Ao mesmo tempo, analisa-se a geopolítica do conhecimento e a relação da agenda de CA com lógicas neoliberais, indicando que, se implementada sem considerar as especificidades do Sul Global, a CA pode reforçar padrões epistêmicos eurocêntricos, métricas competitivas e usos privados de resultados

gerados com recursos públicos (Albagli & Maciel, 2004; Bechi & Almeida, 2024).

Por outro lado, o debate também reconhece alternativas e resistências, como o modelo diamante de publicação predominante em parte das revistas latino-americanas, iniciativas de soberania digital e infraestruturas descentralizadas que buscam reduzir dependências estruturais (Abreu, 2022; Silveira et al., 2025). Nessa perspectiva, as críticas não rejeitam a CA em si, mas reforçam a necessidade de políticas e práticas que integrem preocupações com justiça socioeconômica, fortalecimento de infraestruturas locais e um projeto de CA genuinamente emancipatório, em vez de uma nova face da dominação capitalista e colonial.

1.5 Perspectiva da Ciência Aberta

Por prática de CA entende-se a perspectiva micro da CA, relacionadas com as terminologias e conhecimento em torno do fluxo de trabalho do gerador de conhecimento científico aberto (Figura 1.1), ou seja, o cientista que se propõe tornar sua pesquisa transparente, reprodutível e replicável.



Figura 1.1: Perspectiva micro da Ciência Aberta. Taxonomia relacionada com terminologias e conhecimento em torno da prática (fluxo de trabalho) do gerador de conhecimento científico aberto. Ilustração disponível em: <https://doi.org/10.5281/zenodo.10835001>.

Exclui-se a perspectiva macro, relacionadas com as ramificações conceituais da CA concernentes às políticas públicas, infraestrutura, envolvimento aberto de atores sociais e diálogo aberto com outros sistemas de conhecimento (Figura 1.2). Essa última perspectiva está fora do escopo da discussão do curso, que se concentra em algumas das dimensões da perspectiva micro, particularmente, as ferramentas disponíveis para compilação dos produtos científicos que integram a publicação científica (UNESCO, 2021).

1.6 Educação em Ciência Aberta

A comunidade científica e atores importantes do cenário advogam que a solução para a “crise de reprodutibilidade” passa por educar os estudantes e pesquisadores desde cedo em todas as questões da CA (D. H. Baker et al., 2023; Bezjak et al., 2018; Chopik et al.,

A solução para a crise e a construção de uma ciência mais transparente começam com mudanças pragmáticas, implementáveis no nível do pesquisador (Alessandroni & Byers-Heinlein, 2022; Limongi & Rogers, 2025b). A transição para uma ciência mais aberta inicia-se com mudanças concretas e gerenciáveis em nossos ambientes de trabalho, digitais ou não, uma abordagem *bottom-up* onde o pesquisador é protagonista (Limongi & Rogers, 2025b). Nessa perspectiva, o foco recai sobre a dimensão micro da CA: o fluxo de trabalho do cientista que busca tornar sua pesquisa transparente, reproduzível e replicável.

1.7.1 Espectro de Reprodutibilidade

Para compreender os níveis de compromisso com práticas abertas, é útil visualizar a reprodutibilidade como um espectro contínuo, não como um estado binário. Essa perspectiva foi proposta por Zaragozí et al. (2020) e adaptada para o contexto das Ciências Sociais Aplicadas, organizando práticas de reprodutibilidade em três dimensões essenciais: **Assets** (ferramentas e dados locais), **Platforms** (serviços em nuvem para colaboração) e **Practices** (metodologias de trabalho) (Figura 1.3).




Figura 1.3: Espectro de reprodutibilidade em Ciências Sociais Aplicadas: dimensões conceituais. O gradiente de cores representa níveis crescentes de compromisso com práticas abertas, organizados em três dimensões (Assets, Platforms, Practices) e três colunas que representam diferentes estágios de integração: Data (organização e compartilhamento de dados), Code (versionamento e documentação de código), e Linked (integração computacional de dados, código e narrativa). Ilustração disponível em: <https://doi.org/10.5281/zenodo.17830903>.

O espectro apresenta três colunas que representam progressão na integração: **Data** (organização e compartilhamento de dados), **Code** (versionamento e documentação de código), e **Linked** (integração computacional de dados, código e narrativa). O gradiente de cores - do vermelho (práticas básicas) ao amarelo (práticas intermediárias) e verde (práticas avançadas) - comunica visualmente que a reprodutibilidade não é um

objetivo único, mas um continuum onde diferentes níveis de sofisticação tecnológica e metodológica coexistem e são válidos (Zaragozí et al., 2020).

Um aspecto crítico do espectro é que **Practices** (práticas metodológicas) alcançam tons mais intensos de verde mesmo em estágios intermediários, indicando que metodologia adequada pode ser mais determinante que sofisticação tecnológica (Zaragozí et al., 2020). Por exemplo, metadados bem estruturados e documentação clara podem ser mais valiosos para a reprodutibilidade que código complexo sem explicação (Zaragozí et al., 2020).

1.7.2 ARTE: Operacionalizando o Espectro

Neste contexto, o workflow **ARTE** (*Article Reproducibility Template & Environment*) emerge como proposta pedagógica para operacionalizar o espectro de reprodutibilidade em pesquisas na área de Ciências Sociais Aplicadas (Limongi & Rogers, 2025a, 2025b; Rogers & Limongi, 2025). O **ARTE** não impõe uma trajetória única, mas oferece um roteiro estruturado em três níveis progressivos que materializam as dimensões do espectro de reprodutibilidade.

O **ARTE** propõe uma taxonomia de reprodutibilidade em três níveis - **mínima**, **adequada** e **completa** - que permite adoção progressiva de práticas abertas sem sobrecarregar pesquisadores iniciantes (Rogers & Limongi, 2025). Esta abordagem alinha-se com a recomendação pragmática de que “compartilhar algo é melhor que nada compartilhar” (Klein et al., 2018), reconhecendo que diferentes estágios de abertura são válidos e contribuem para o avanço científico (Kathawalla et al., 2021).

A reprodutibilidade **mínima** concentra-se na organização e compartilhamento de dados segundo o **TIER Protocol**, exigindo apenas conhecimentos de gestão de arquivos (literacia em dados) e familiaridade com plataformas como o **Open Science Framework (OSF)** (Limongi & Rogers, 2025b). Corresponde às zonas vermelhas e amarelas da coluna **Data** no espectro, estabelecendo a base: estrutura de pastas padronizada, metadados descritivos e licenciamento adequado.

A reprodutibilidade **adequada** adiciona controle de versão de código (**Git/GitHub**) e gestão de dependências (**renv** para **R/conda** para **Python**), introduzindo a publicação de documentos dinâmicos com **Quarto/RStudio** (Limongi & Rogers, 2025b). Este nível integra as colunas **Data** e **Code** do espectro, avançando para as zonas amarelas e verdes iniciais: versionamento, documentação de código, documentos dinâmicos e controle de dependências.

A reprodutibilidade **completa** integra dados, código e narrativa em ambientes computacionais encapsulados (**Docker**), garantindo execução idêntica em qualquer máquina (Limongi & Rogers, 2025b). Representa a coluna **Linked** do espectro em sua expressão mais avançada (zonas verdes), onde documentos dinâmicos, gerenciadores de dependências e tecnologias de containerização convergem para criar artefatos científicos completamente reproduzíveis.

1.7.3 Ferramentas Práticas e Adoção Incremental

A operacionalização do **ARTE** requer ferramentas concretas em cada nível. A Figura 1.4 apresenta o espectro de reprodutibilidade com ferramentas específicas recomendadas para Ciências Sociais Aplicadas, permitindo que pesquisadores identifiquem soluções práticas para cada estágio de compromisso com a CA.

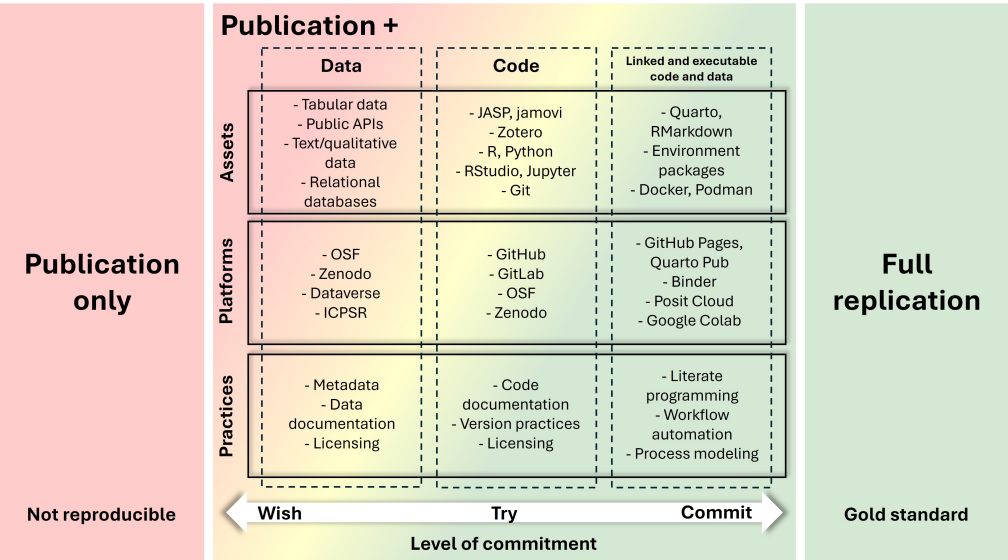


Figura 1.4: Espectro de reprodutibilidade em Ciências Sociais Aplicadas: ferramentas recomendadas. Esta versão do espectro destaca ferramentas específicas organizadas nas mesmas três dimensões (Assets, Platforms, Practices) e colunas (Data, Code, Linked). As ferramentas apresentadas constituem o arsenal prático que o ARTE mobiliza em cada nível de reprodutibilidade. Ilustração disponível em: <https://doi.org/10.5281/zenodo.17830903>.

Na zona mínima (tons avermelhados), priorizam-se formatos de dados tabulares (CSV), APIs públicas para dados abertos, repositórios institucionais ([OSF](#), [Zenodo](#), [Dataverse](#), [ICPSR](#)) e práticas de documentação básica (metadados, licenciamento) (Rogers & Limongi, 2025). Estas ferramentas exigem curva de aprendizado mínima e constituem o ponto de entrada natural para pesquisadores que iniciam sua jornada em CA.

Na zona adequada (tons amarelados), introduzem-se interfaces estatísticas ([JASP](#), [Jamovi](#), [Orange](#), [Knime](#)), linguagens de programação ([R](#), [Python](#)), ambientes de desenvolvimento ([RStudio](#), [Jupyter](#)), versionamento ([Git](#)), plataformas colaborativas ([GitHub](#), [GitLab](#)), e gestão de dependências ([renv](#) para R, [conda](#) para Python) (Rogers & Limongi, 2025). [JASP](#) e [Jamovi](#) servem como pontes para pesquisadores acostumados a interfaces gráficas, gradualmente introduzindo conceitos de código reproduzível (D. H. Baker et al., 2023; Limongi & Rogers, 2025b). [Zotero](#) complementa este ecossistema como ferramenta de gerenciamento de referências, integrando-se aos fluxos de trabalho com [RStudio](#) para facilitar inserção de citações em documentos dinâmicos (Rogers & Limongi, 2025).

Na zona completa (tons esverdeados), integram-se sistemas de publicação científica ([Quarto](#), [RMarkdown](#)), gestão avançada de ambientes ([Docker](#), [Podman](#)), hospedagem estática ([GitHub Pages](#), [Quarto Pub](#)), notebooks executáveis ([Binder](#)), computação em nuvem ([Posit Cloud](#), [Google Colab](#)), e automação de workflows (Rodrigues, 2023; Rogers & Limongi, 2025). [Docker](#) e [Project Rocker](#) encapsulam o ambiente computacional completo, solucionando o “inferno de dependências” e garantindo reprodutibilidade de longo prazo (Moreau et al., 2023; Zandonella Callegher & Massidda, 2022).

A flexibilidade do espectro permite **adoção não-linear**: um pesquisador pode utilizar

[Git](#) e compartilhar scripts no [OSF](#) sem necessariamente usar [GitHub](#), ou adotar [Quarto](#) e [renv](#) sem jamais usar [Docker](#) (Limongi & Rogers, 2025b). Esta característica alinha-se com a filosofia do [ARTE](#) de que “o perfeito é inimigo do bom” (Klein et al., 2018) - melhor compartilhar dados organizados hoje que esperar anos para dominar containerização (Kathawalla et al., 2021).

Ambientes de computação em nuvem - [Google Colab](#), [Posit Cloud](#), [JupyterHub](#), [Binder](#), [Nextjournal](#) e [Code Ocean](#) - abstraem a complexidade da containerização, oferecendo ambientes pré-configurados acessíveis via navegador que democratizam o acesso a ferramentas computacionais (Limongi & Rogers, 2025b; Wiebels & Moreau, 2021). Estas plataformas servem diferentes pontos do espectro, desde reprodutibilidade básica (Colab) até encapsulamento completo (Code Ocean e Nextjournal) (Clyburne-Sherin et al., 2019).

Para pesquisadores do ecossistema [R](#), o [RStudio IDE](#) consolida-se como hub que integra estas soluções em interface única, combinando nativamente [Quarto](#), [Git/GitHub](#), [renv](#), e [Zotero](#) (Rodrigues, 2023; Vuorre & Curley, 2018; Zandonella Callegher & Massidda, 2022). Este ambiente integrado pode ser potencializado ao executar o próprio [RStudio](#) dentro de um container [Docker](#) via [Project Rocker](#), encapsulando todo o ambiente de desenvolvimento (Rodrigues, 2023).

1.7.4 Perspectivas e Desafios

Embora o [ARTE](#) ofereça roteiro estruturado, barreiras persistem. A falta de treinamento formal em ferramentas computacionais, a pressão por publicações rápidas, e a ausência de incentivos institucionais para práticas abertas dificultam a adoção em larga escala (Kathawalla et al., 2021; Limongi & Rogers, 2025b). No contexto brasileiro, onde políticas de CA ainda favorecem predominantemente o acesso aberto sem abordar outros aspectos da reprodutibilidade (Rezende & Falgueras, 2020), iniciativas educacionais como este curso tornam-se ainda mais críticas.

O movimento rumo à ciência reproduzível não requer abandonar práticas estabelecidas, mas **integrá-las progressivamente** ao workflow de pesquisa (Limongi & Rogers, 2025b). Como apontam Alston & Rick (2021), pesquisa reproduzível “não se trata apenas de ferramentas avançadas, mas também de hábitos simples de trabalho”. A jornada para a CA é contínua, construída sobre hábitos consistentes (Limongi & Rogers, 2025b).

A CA, portanto, não é uma revolução disruptiva, mas uma **evolução metodológica** que fortalece a credibilidade científica sem comprometer a autonomia do pesquisador. O [ARTE](#), que adotaremos transversalmente nesse curso, oferece um mapa para esta jornada, reconhecendo que diferentes trajetos são válidos desde que orientados pelos princípios de transparência, reprodutibilidade e abertura. Talvez mais importante que o produto final, seja o processo que levou ao produto final.

1.8 Preparação para a Aula

! Pré-requisitos

Este módulo é focado na apresentação e discussão de conceitos fundamentais sobre Ciência Aberta e reprodutibilidade. A aula será conduzida por meio de exposição dialogada, sem atividades práticas programadas.

Leituras Recomendadas

Para aprofundar sua compreensão dos temas abordados neste módulo, recomendamos a leitura da trilogia de editoriais “Open Science in Three Acts”:

- **Primeiro Ato** (Limongi & Rogers, 2025a): apresenta os fundamentos da Ciência Aberta, discutindo a crise de reprodutibilidade e defendendo o engajamento de orientadores e programas de pós-graduação. Disponível em: <https://doi.org/10.1590/1807-7692bar2025250079>
- **Segundo Ato** (Limongi & Rogers, 2025b): aprofunda a dimensão prática, apresentando o arsenal de ferramentas e soluções para operacionalizar os princípios de transparência e compartilhamento no workflow individual do pesquisador. Disponível em: <https://doi.org/10.1590/1807-7692bar2025250116>
- **Terceiro Ato** (Rogers & Limongi, 2025): apresenta o template ARTE como solução pedagógica para implementação incremental de práticas reproduzíveis em pesquisas quantitativas. Disponível em: <https://doi.org/10.1590/1807-7692bar2025250162>

Pré-requisitos Técnicos

Embora este módulo seja teórico, os módulos seguintes do curso envolverão atividades práticas. Recomendamos que você **antecipe a instalação e configuração das ferramentas necessárias** seguindo as instruções detalhadas na seção de [Pré-requisitos do Curso](#)

Capítulo 2

Repositórios da Ciência Aberta

2.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Criar e configurar projetos no OSF, incluindo metadados, componentes hierárquicos e integrações com serviços externos
- Conectar o OSF a armazenamentos em nuvem (OneDrive, Google Drive), gerenciadores de referências (Zotero) e repositórios de código (GitHub)
- Onde criar e submeter pré-registros utilizando templates apropriados ao desenho de pesquisa (OSF Preregistration, Secondary Data, Registered Reports)
- Distinguir entre preregistration e registration, compreendendo quando aplicar cada modalidade no ciclo de pesquisa
- Gerar DOIs para projetos e componentes, tornando materiais de pesquisa citáveis e rastreáveis permanentemente
- Compartilhar projetos com colaboradores, gerenciar permissões e criar links anônimos para revisão por pares
- Publicar preprints através do OSF Preprints ou serviços disciplinares (PsyArXiv, SocArXiv)
- Avaliar quando escolher OSF versus outras plataformas

2.2 Contextualização

No contexto da CA, existem diversos repositórios disponíveis, cada um com suas funções e propósitos específicos. Esses repositórios são essenciais para promover a transparência, acessibilidade e colaboração na pesquisa científica. Eles assumem um papel muito relevante na democratização do conhecimento e na promoção da colaboração científica. Cada qual com suas particularidades, oferecem aos pesquisadores ferramentas para armazenar, compartilhar e gerenciar dados, publicações e outros materiais de pesquisa, ou se preferir, todo o ciclo de vida da pesquisa.

- **Zenodo**: é um repositório gerido pelo CERN em colaboração com o projeto [OpenAIRE](#) da União Europeia. Oferece armazenamento gratuito e seguro para dados de pesquisa, com a capacidade de gerar DOIs para facilitar a citação dos dados.
- **Figshare**: é um repositório comercial que permite aos pesquisadores armazenar, compartilhar e descobrir dados de pesquisa. Oferece ferramentas para visualização de documentos, gráficos e outros tipos de dados diretamente no navegador, além de gerar DOIs para os projetos.
- **Mendeley Data**: é um repositório de dados de pesquisa da Elsevier, permitindo o armazenamento, compartilhamento e citação de conjuntos de dados. Ele suporta uma ampla gama de tipos de dados e está integrado com a plataforma de referência Mendeley.
- **Harvard Dataverse**: é uma rede de repositórios que permite aos pesquisadores compartilhar, armazenar e citar dados de pesquisa. Ele oferece ferramentas avançadas para a gestão de dados, incluindo controle de versões e metadados ricos, essenciais para o gerenciamento do ciclo de vida da pesquisa.
- **arXiv**: é um repositório de pré-impressões de artigos científicos em física, matemática, ciência da computação e outras áreas. Ele permite aos pesquisadores compartilhar seus trabalhos antes da revisão por pares, facilitando o acesso à pesquisa em estágios iniciais.
- **Github**: é uma plataforma de desenvolvimento colaborativo baseada em Git, amplamente utilizada por pesquisadores para compartilhar código, documentos e outros materiais de pesquisa. Ele oferece controle de versões, rastreamento de problemas e integração com outras ferramentas de desenvolvimento.

Além desses exemplos, poderíamos citar diversas outras soluções que cumprem papéis semelhantes ou focado em disciplinas específicas: [Databrary](#), [DataverseNO](#), [DataONE](#), [DataCite](#), [DataHub](#), [DataMed](#), [DataShare](#), [DataVerse](#), [Dryad](#), [EarthChem](#), [EUDAT](#), [European Nucleotide Archive \(ENA\)](#), [GenBank](#), [Google Dataset Search](#), [HathiTrust Research Center](#), [ICPSR](#), [JSTOR Data for Research](#), [National Center for Biotechnology Information \(NCBI\)](#), [National Institutes of Health \(NIH\) Data Sharing Repositories](#), [National Oceanographic Data Center \(NODC\)](#), [PLOS ONE](#), [PubMed Central](#), [Research Data Australia](#) e [UK Data Service](#); e em última instância, as redes sociais acadêmicas como [Academia.edu](#), [Google Scholar](#), [ORCID](#) e [ResearchGate](#), também podem ser usadas para compartilhar e descobrir pesquisas.

A despeito de todas essas opções, vamos focar na plataforma **Open Science Framework (OSF)** para a realização do nosso curso. O **OSF** é uma plataforma de código aberto para colaboração em pesquisa, que oferece uma estrutura para conectar os fluxos de trabalho de pesquisa, desde a concepção do projeto até a publicação. O **OSF** é mantido pelo [Center for Open Science \(COS\)](#), uma organização sem fins lucrativos com sede nos Estados Unidos. O **OSF** é um dos principais produtos do COS e é usado por pesquisadores de todo o mundo para colaborar em projetos de pesquisa.

O **OSF** oferece uma série de recursos para ajudar os pesquisadores a gerenciar seus projetos de pesquisa, incluindo:

- **Criar projetos de pesquisa**: organizar seus estudos, incluindo metadados, datasets, materiais de pesquisa e publicações.
- **Carregar e publicar dados**: armazenar e compartilhar seus dados de forma segura e acessível.

- **Colaboração em equipe:** convidar colaboradores para participar do projeto, atribuir tarefas e acompanhar o progresso.
- **Integração com outras ferramentas:** conectar a armazenamentos nas nuvens (Box, DropBox, Google Drive e OneDrive), gerenciadores de referências (Zotero e Mendeley) e outros repositórios (Dataverse, Github, figshare, etc).

O **OSF** tem um foco mais amplo em todo o ciclo de vida da pesquisa, desde a concepção da ideia até a publicação dos resultados (Figura 2.1). Já algumas das soluções citadas foca principalmente no compartilhamento de dados e publicações. O **OSF** oferece ferramentas mais robustas para colaboração em equipe, como wikis, painéis de discussão e ferramentas de gerenciamento de tarefas, e principalmente, possui uma comunidade mais ativa de pesquisadores e colaboradores.



Figura 2.1: OSF Research Lifecycle

Para os alunos que desejam uma leitura sobre o **OSF** na prática, indicamos os artigos de Sullivan et al. (2019) e Soderberg (2018). Apesar de o leitor poder encontrar *prints* das telas da plataforma desatualizadas, esses dois artigos podem ser um bom começo para entender a lógica da plataforma. E *off course*, recomendamos fortemente você dar uma olhada no [suporte do OSF](#), onde podemos encontrar vídeos introdutórios excelentes.

💡 Duplicando um projeto

Você sabia que é possível executar um “*duplicate*” e criar uma cópia do projeto existente ou duplicar apenas a estrutura do projeto e seus componentes de um projeto público no OSF?

Você que se interessa em iniciar seu próprio projeto OSF com um modelo, pode criar sua própria duplicata do projeto Olson et al. (2022) para começar!

Neste [projeto](#), existem templates e recursos básicos para diversos casos de uso encontrados no OSF; coordenação de equipes de pesquisa, planejamento de gerenciamento de dados, documentos reprodutíveis e até mesmo gerenciamento de cursos.

2.3 Pré-registro e Transparência Metodológica

Pré-registro documenta hipóteses e planos de análise antes da coleta de dados. A prática mitiga vieses de confirmação e decisões *post-hoc* que comprometem a validade dos resultados. Registrar decisões metodológicas antes de observar os dados torna explícito o que foi planejado versus o que foi exploratório - uma distinção que a ciência tradicional frequentemente obscurece.

O **OSF** distingue duas modalidades. *Preregistration* é criado antes da coleta ou análise de dados, quando os dados ainda não existem ou não foram observados. *Registration* documenta estudos já concluídos ou cria *snapshots* permanentes de projetos em qualquer estágio. Ambos geram registros imutáveis com timestamps, mas o timing difere. Preregistration tem maior valor para transparência metodológica porque compromete o pesquisador com um plano antes de conhecer os resultados.




Figura 2.2: OSF Registration

O **OSF** oferece múltiplos templates adaptados a diferentes desenhos. *OSF Preregistration* é o mais utilizado e abrangente, cobrindo hipóteses, métodos de coleta, planos de análise e critérios de exclusão. *Secondary Data Preregistration* é específico para análises de dados já coletados por outros ou por você em projetos anteriores - ele inclui questões sobre seu conhecimento prévio dos dados, tornando transparente o que já foi explorado. *Registered Report Protocol* é para submissão a periódicos que revisam protocolos antes da coleta (Stage 1), oferecendo aceitação provisória baseada na qualidade metodológica,

independentemente dos resultados futuros. *Generalized Systematic Review Registration* é voltado para revisões sistemáticas e meta-análises, documentando estratégias de busca, critérios de inclusão/exclusão e métodos de síntese.

Preregistros podem ser embargados por até quatro anos, permitindo trabalhar em projetos sem exposição prematura a concorrentes. O histórico de versionamento permanece preservado mesmo durante embargo. Após publicação, o registro torna-se imutável, mas você pode vincular outputs futuros (artigos, datasets, preprints) através da funcionalidade *Connected Resources*, criando uma rede rastreável entre protocolo e produtos finais.

2.4 Identificadores Persistentes e Rastreabilidade

DOIs tornam materiais de pesquisa citáveis permanentemente. O **OSF** gera DOIs para projetos e componentes individuais, transformando qualquer elemento do seu workflow em objeto citável com endereço permanente na web. Datasets, protocolos, códigos de análise, instrumentos - todos ganham identidade própria no registro acadêmico.

A integração com ORCID vincula automaticamente outputs ao perfil permanente do pesquisador. Cada DOI gerado no **OSF** pode ser associado ao seu ORCID, construindo um registro completo da sua produção que transcende afiliações institucionais. Metadados estruturados alimentam sistemas de descoberta como Google Scholar e DataCite, aumentando a visibilidade e o impacto dos materiais compartilhados.

Zenodo e OSF diferem na granularidade. Zenodo gera DOIs por versão de arquivo, permitindo citar exatamente a versão 1.2 de um dataset. OSF gera DOIs por projeto ou componente, citando o container que pode evoluir ao longo do tempo. A escolha depende das necessidades: Zenodo favorece imutabilidade estrita; OSF favorece flexibilidade e evolução do projeto com rastreamento de versões interno.

2.5 OSF no Ecossistema de Ferramentas

Você pode configurar o **OSF** para funcionar como hub central, conectando ferramentas especializadas do seu workflow acadêmico. Ele não compete com GitHub ou Zotero - integra-se a eles. GitHub gerencia controle de versão detalhado de código-fonte, rastreando cada mudança com granularidade de linha. Zotero organiza referências bibliográficas e PDFs anotados. OSF orquestra tudo, vinculando repositórios GitHub como componentes do projeto, sincronizando bibliotecas Zotero, conectando armazenamentos em nuvem onde os dados vivem.

Essa arquitetura modular respeita especializações. Use GitHub para o que ele faz melhor: versionamento de código e colaboração via pull requests. Use Zotero para gestão bibliográfica com plugins e automações. Use OneDrive ou Google Drive para arquivos grandes que excedem limites dos repositórios especializados. O OSF une tudo sob metadados estruturados, controle de acesso unificado e DOI citável que aponta para o projeto completo.

RStudio e Quarto, que serão discutidos em módulos posteriores, produzem documentos dinâmicos onde análises, código e narrativa coexistem. Hospedar esses projetos no GitHub, vinculá-los ao OSF e depositar versões finais no Zenodo com DOI cria pipeline completo: desenvolvimento transparente (GitHub), coordenação de projeto (OSF),

arquivo permanente versionado (Zenodo). Cada ferramenta contribui com sua força, nenhuma tenta fazer tudo.

2.6 Quando Não Usar OSF

GitHub é superior para projetos centrados em código onde colaboração via *issues*, *pull requests* e integração contínua são centrais. Desenvolvedores de software preferem GitHub porque ele foi desenhado para esse workflow. O OSF conecta-se ao GitHub, mas não substitui suas funcionalidades nativas de desenvolvimento colaborativo.

arXiv permanece padrão para física, matemática e ciência da computação por razões históricas e culturais. Submeter preprints ao arXiv sinaliza conformidade com normas disciplinares. O OSF oferece OSF Preprints e serviços disciplinares (PsyArXiv, SocArXiv), mas em campos onde arXiv domina, migrar traz pouco benefício.

Repositórios disciplinares específicos são exigidos por journals ou agências de fomento em algumas áreas como genômica (GenBank) e cristalografia (Protein Data Bank). Nesses casos, depositar no repositório mandatado é obrigatório. O OSF pode complementar, vinculando o projeto ao depósito externo via metadados e *Connected Resources*, mas não substitui requisitos formais.

Dados sensíveis com restrições éticas ou legais severas podem exigir infraestrutura institucional com controles de acesso mais rígidos que os oferecidos pelo OSF. Dados de saúde identificáveis, por exemplo, frequentemente precisam permanecer em servidores certificados pela instituição. O OSF pode hospedar metadados e documentação enquanto os dados permanecem em repositório restrito.

2.7 Preparação para a Aula

! Pré-requisitos

Antes da aula síncrona, certifique-se de completar **todos** os passos abaixo. Um vídeo com instruções detalhadas está disponível na [página de pré-trabalho do curso](#).

Checklist de Preparação:

1. ☒ Criar conta no [OSF](#)
2. ☒ Atualizar seu perfil no OSF (Opcional)
3. ☒ Explorar a interface inicial do OSF e familiarizar-se com a navegação
4. ☒ Dar uma “olhada” nos templates de preregistro disponíveis em [OSF Registries](#) (Opcional)

Capítulo 3

Gerenciamento de Referências e Bibliotecas

3.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Configurar o Zotero 7 com plugins essenciais (Better BibTeX, Zotero Attanger etc.) e sincronização com serviços de nuvem
- Organizar referências em coleções temáticas e utilizar tags para categorizar estágios do processo de pesquisa
- Criar anotações e marcações em PDF como material para análises qualitativas e sínteses de literatura
- Gerar arquivos `.bib` automatizados para integração com documentos dinâmicos (Quarto/RStudio)
- Produzir citações em documentos Word/LibreOffice e em documentos reprodutíveis via chaves BibTeX
- Compartilhar bibliotecas através de grupos do Zotero
- Automatizar renomeação de PDFs e contornar limitações de armazenamento usando nuvem externa
- Informar sobre as diversas possibilidades de integração do Zotero com ferramentas de IA (NotebookLM, Elicit, plugins de sumarização) e gestão de conhecimento (Obsidian, Notion)

3.2 Contextualização

Existem mais de 15 diferentes¹ gerenciadores de referências (Proske et al., 2023). Entre eles podemos indicar o [Citavi](#) e o [RefWorks](#). No entanto, os mais populares são o [EndNote](#), [Mendeley](#) e [Zotero](#). O primeiro é proprietário e descartamos enquanto opção para nosso workflow de Open Science. Os dois últimos são excelentes opções, no entanto,

¹[Esta lista](#) no Wikipedia, que é atualizada constantemente, faz uma comparação entre eles.

o Zotero se destaca por ser código aberto (totalmente gratuito), enquanto o Mendeley, embora gratuito, é propriedade da Elsevier, uma editora comercial. Isso significa que o Zotero não tem restrições de uso e não exige pagamento por recursos adicionais, exceto por maior armazenamento na nuvem, que inclusive, é um destaque do Mendeley (2Gb vs 300Mb).



Figura 3.1: Mapa de decisão para escolha do gerenciador de referências

Essa aparente desvantagem do Zotero é, na prática, contornável. O limite de 300Mb refere-se apenas à sincronização dos metadados (os dados da referência). O armazenamento dos arquivos PDF, que consomem mais espaço, pode ser direcionado para seu serviço de nuvem preferido (OneDrive, Google Drive, etc.) através de configurações e plugins específicos. Essa configuração, que será demonstrada na aula, resolve a limitação.

O Zotero tem uma comunidade ativa e fóruns de suporte, o que pode ser útil para solucionar problemas e compartilhar conhecimento com outros usuários. Como aqui valorizamos a liberdade de código aberto e uma comunidade engajada, o Zotero é nossa escolha.

Essa característica faz com que o Zotero se destaque em relação ao Mendeley, especialmente no que diz respeito ao **Ecossistema de Plugins**. O Zotero possui uma comunidade ativa de desenvolvedores e pesquisadores que criam e compartilham plugins. Esses plugins estendem as funcionalidades do Zotero, permitindo personalizações específicas e integrações com outras ferramentas (Behera & Jain, 2023).

O plugin [Better BibTeX](#), por exemplo, oferece recursos avançados de exportação e formatação de bibliografias, tornando-o uma escolha popular para usuários que trabalham com LaTeX, Markdown, HTML, e outras linguagens de marcação.² O ecossistema de

²Outro plugin discutido é a integração com o [SciHub](#) (Behera & Jain, 2023). Coloquei essa informação em nota, pois ele é questionável do ponto de vista ético, apesar de extensivamente utilizado no Brasil por estudantes de pós-graduação stricto sensu de diferentes áreas (Oddone & Souza, 2024). Ou se enxergarmos o problema sob outro ponto de vista, a ampla adoção do SciHub no Brasil e em todo o mundo reflete a resposta dos cientistas ao desgastado sistema de comunicação científica mantido pelas

plugins é tão ativo que já inclui diversas integrações com ferramentas de Inteligência Artificial (IA) para sumarização e análise de artigos (A.I.R.A., PapersGPT, ZotAi, entre outros).

A mensagem principal que pretendemos passar no curso sobre esse tópico é para você conceber os gerenciadores de referências e bibliotecas, especialmente o Zotero, no contexto do processo de pesquisa, e não apenas para citações e referências. Usuários avançados aproveitam o suporte que a maioria dos sistemas de gerenciamento de referências oferece para o ciclo da pesquisa reprodutível (Proske et al., 2023).

3.3 O Zotero no Ciclo de Pesquisa

O Zotero pode ser integrado desde a fase de revisão sistemática ou exploratória. Você organiza referências em coleções temáticas e utiliza tags para categorizar estágios do processo. Tags como “Para Ler”, “Lido”, “Importante”, ou “Artigo X” transformam o gerenciador em sistema de rastreamento do progresso da leitura e análise. Coleções aninhadas permitem estruturar a literatura por tema, metodologia ou relevância, criando uma arquitetura de conhecimento que cresce organicamente com a pesquisa.




Figura 3.2: Exemplos de organização de coleções no Zotero

As notas e marcações em PDF não servem apenas para lembrar trechos. Elas alimentam análises qualitativas e sínteses de literatura. Cada anotação pode ser exportada, revisitada e reorganizada conforme o argumento do seu texto se desenvolve. A integração entre leitura, anotação e escrita torna-se dinâmica. O Zotero pode funcionar como repositório vivo de ideias, não apenas de referências bibliográficas.

Ferramentas de gestão de conhecimento como [Obsidian](#) e [Notion](#) podem ser integradas ao Zotero, criando redes de notas interconectadas. Suas anotações no Zotero alimentam bases de conhecimento pessoal, onde conceitos de diferentes artigos dialogam entre si. Isso transforma a revisão de literatura em processo iterativo de construção de sentido.

editoras internacionais. Reforça, também, a relevância dos princípios da Ciência Aberta (Oddone & Souza, 2024).

3.4 Integração com Fluxos de Trabalho Reprodutíveis

O fluxo de trabalho de pesquisa reprodutível exige ferramentas que se integram com documentos dinâmicos, como Quarto e RStudio. As citações são gerenciadas por chaves BibTeX, conceito que será central na aula. O plugin [Better BibTeX](#), como já comentado, viabiliza essa integração de forma transparente.

O [Better BibTeX](#) permite criar e atualizar automaticamente arquivos `.bib` que se sincronizam com seus documentos dinâmicos. Você adiciona uma referência no Zotero, e o arquivo `.bib` reflete a mudança instantaneamente. Trabalho manual é eliminado. A gestão de referências e a escrita do manuscrito acontecem em paralelo, sem retrabalho entre coleta de literatura e produção de texto.

Manter seu arquivo `.bib` no GitHub junto com seus scripts garante que colegas possam reproduzir exatamente as mesmas citações. Versionamento de referências torna-se parte do controle de versão do projeto. Quando você compartilha o repositório, compartilha também a biblioteca bibliográfica exata que usou - rastreabilidade completa da cadeia de conhecimento.

Grupos do Zotero permitem compartilhar bibliotecas completas com equipes de pesquisa. Colaboração e transparência se expandem: todos os membros do grupo acessam as mesmas referências, anotações e anexos. Mudanças feitas por um membro sincronizam automaticamente com os demais. Projetos colaborativos ganham uma base bibliográfica unificada.

Gerenciadores preservam DOIs, abstracts e metadados que facilitam a citação correta e rastreabilidade das fontes. Metadados completos permitem que outros pesquisadores localizem rapidamente os materiais citados. Isso é requisito para pesquisa aberta e transparente - não basta citar, é preciso facilitar o acesso à fonte original.

3.5 IA e Descoberta de Literatura

Fluxos de trabalho baseados em RAGs (Retrieval-Augmented Generation) com LLMs locais ou ferramentas como [PapersGPT](#) podem ser alimentados diretamente pela sua biblioteca Zotero. RAGs na nuvem, como o [NotebookLM](#) do Google, também são mais facilmente acionados com a organização eficiente das coleções/pastas do Zotero. Você constrói assistentes de pesquisa personalizados que conhecem profundamente sua literatura, respondem perguntas contextualizadas e sugerem conexões entre artigos.

Plataformas de descoberta de literatura assistida por IA, como [ResearchRabbit](#), [Elicit](#) e [SciSpace](#), complementam o Zotero. [ResearchRabbit](#) descobre conexões importantes entre a literatura; [Elicit](#) automatiza revisões de literatura a partir de perguntas de pesquisa; [SciSpace](#) oferece explicações contextuais de artigos complexos. Essas ferramentas não substituem a leitura crítica, mas aceleram a triagem inicial e a identificação de estudos relevantes. Integradas ao Zotero, formam um ecossistema de pesquisa potencializado por IA.

3.6 Indo Além das Funcionalidades Básicas

Atualmente, gerenciadores de referências oferecem funcionalidades que incluem:

- Recursos para coletar referências com textos completos e organizá-las em pastas e/ou (sub)coleções;
- Marcar entradas de referência, fazer anotações e destacar o texto completo por meio de visualizadores de PDF integrados;
- Citar referências em diferentes estilos de citação por meio de complementos para software de processamento de texto ou criando e atualizando automaticamente arquivos `.bib` para outras linguagens de marcação;
- Sincronizar referências entre o aplicativo de desktop e a versão móvel, bem como entre diferentes computadores; e
- Compartilhar referências (Proske et al., 2023)

Mas o Zotero permite ir além. Plugins como Zotero Attanger automatizam a renomeação e o armazenamento de PDFs. Você define padrões de nomenclatura - por exemplo, “Autor_Ano_Título” - e o plugin renomeia todos os arquivos de forma consistente. PDFs podem ser organizados em pastas externas no OneDrive, Google Drive ou Dropbox, sincronizando automaticamente entre dispositivos e contornando a limitação de armazenamento oficial do Zotero nas nuvens.

Essa automação transforma a desorganização de centenas de PDFs mal nomeados em biblioteca estruturada. Arquivos tornam-se localizáveis por nome, navegáveis por pastas temáticas, e acessíveis em qualquer dispositivo conectado à sua nuvem. A organização deixa de ser tarefa manual e passa a ser processo sistemático.

A integração entre Zotero e ferramentas de gestão de conhecimento cria camadas adicionais de valor. O [Obsidian](#), por exemplo, pode importar metadados e notas do Zotero, permitindo que você construa redes de conceitos interligados. Cada artigo torna-se nó em uma rede maior de ideias, conectado a outros artigos, a conceitos teóricos e a seus próprios insights. O [Notion](#) oferece alternativa visual, organizando referências em bancos de dados relacionais que você personaliza conforme a necessidade do projeto.

Um conteúdo básico é abordado em detalhes no trabalho de Thomas (2023), e veremos algumas dessas funcionalidades na aula. No entanto, daremos ênfase em outras funcionalidades do Zotero 7, especialmente sua integração no workflow reproduzível, por exemplo, com o RStudio/Quarto para citações/referências em documentos dinâmicos.

3.7 Preparação para a Aula

! Pré-requisitos

Antes da aula síncrona, certifique-se de completar **todos** os passos abaixo. Um vídeo com instruções detalhadas está disponível na [página de pré-trabalho do curso](#).

Checklist de Preparação:

1. ☒ Realizar o cadastro no [Zotero.org](#)
2. ☒ Instalar o [software Zotero](#) no seu computador
3. ☒ Instalar o [Zotero Connector](#) no seu navegador (Chrome, Firefox, Edge ou

Safari)

4. ☒ Configurar a sincronização entre instalação local e nuvem Zotero
5. ☒ Instalar o “[Add-on Market for Zotero](#)” (gerenciador de plugins)
6. ☒ Instalar o estilo de citação [Better BibTeX](#)

Capítulo 4

Organização de Projetos

4.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender a importância da organização padronizada de projetos de pesquisa no contexto da Ciência Aberta
- Reconhecer os seis domínios de boas práticas propostos por Wilson et al. (2017) para pesquisa computacional reprodutível
- Identificar as principais barreiras à reprodutibilidade em projetos de pesquisa
- Aplicar princípios de gerenciamento de dados, incluindo separação entre dados brutos e processados
- Estruturar projetos seguindo protocolos (templates) tal como o [ARTE](#) para uma reprodutibilidade adequada (Rogers & Limongi, 2025)
- Adotar práticas de nomenclatura consistente para arquivos e pastas
- Reconhecer o papel do controle de versão e documentação no ciclo de vida da pesquisa
- Avaliar alternativas de ferramentas e práticas para diferentes níveis de reprodutibilidade

4.2 Contextualização

Essa seção é o elo entre as seções anteriores e as próximas. Aqui, você vai receber algumas dicas de como organizar seus dados, pasta e scripts em um projeto de pesquisa. Talvez você se pergunte: porque eu preciso aprender a organizar meus arquivos e pasta? Já faço isso, do meu jeito, há anos, e nunca tive problemas em entender o que eu faço!

A resposta é simples: não trata somente de você entender e achar que o produto final da sua pesquisa (o artigo) seja suficiente. No contexto da Ciência Aberta (CA) o processo da análise, materiais e métodos, e que outros pesquisadores possam reproduzir seus resultados, são tão importantes quanto o produto final. Nesse sentido, deve haver uma padronização mínima de organização de arquivos, pastas e scripts para que outros pesquisadores possam entender e reproduzir seus achados.

Você pode compartilhar uma pasta compilada da sua pesquisa, via Google Drive ou One-Drive, no seu projeto do Open [Science Framework \(OSF\)](#), ou ainda publicar uma página no [Github](#), mas se a organização dos arquivos não seguir alguma lógica compreensível, de nada adianta compartilhar. É como disponibilizar um caderno com letra ilegível — o registro existe, mas será inacessível para terceiros e, possivelmente, você mesmo no futuro.

O texto desta seção é fundamentado nas “boas práticas” propostas por Wilson et al. (2017). Esse trabalho, implementado em 2024, no contexto do [Software Carpentry e Data Carpentry](#), estabeleceu um conjunto mínimo de práticas essenciais para pesquisa computacional reprodutível. Esse conjunto de práticas agrega o ferramental necessário para uma reprodutibilidade adequado, conforme espectro delineado por Rogers & Limongi (2025).

A filosofia subjacente a esse framework é pragmática: as práticas propostas não visam a perfeição absoluta, mas sim um equilíbrio viável entre rigor metodológico e aplicabilidade prática (Rogers & Limongi, 2025). São práticas “boas o suficiente” (*good enough*) para tornarem a pesquisa significativamente mais reprodutível sem exigirem expertise avançada em engenharia de software (Wilson et al., 2017). O objetivo é que qualquer pesquisador, independentemente de sua formação técnica, possa implementá-las gradualmente em seus projetos.

Wilson et al. (2017) organizam suas recomendações em seis domínios fundamentais e na aula presencial, exploraremos cada um desses domínios em detalhes, compreendendo como eles se articulam para formar um fluxo de trabalho coerente e adequadamente reprodutível (Rogers & Limongi, 2025). Por ora, apresentaremos uma visão geral dessas práticas, destacando seus princípios centrais e justificativas metodológicas.

4.3 Gerenciamento de Dados

O gerenciamento adequado de dados parte de um princípio fundamental: dados brutos são imutáveis. Uma vez coletados, os dados originais devem ser preservados intactos, sem qualquer modificação. Essa regra, aparentemente simples, é violada com frequência - seja pela tentação de “corrigir um valor manualmente”, seja pela ausência de separação física entre dados originais e processados.

A prática recomendada consiste em armazenar dados brutos em um diretório específico, idealmente configurado como somente leitura (*read-only*). Todas as transformações - limpeza, recodificação, cálculo de variáveis derivadas - devem ser realizadas por meio de scripts, gerando novos arquivos de dados processados. Essa separação não apenas previne perda acidental de informação, mas torna explícita a distinção entre “fatos” (dados coletados) e “interpretações” (dados transformados).

Complementarmente, Wickham (2014) formalizou o conceito de *Tidy Data* - uma estrutura de organização tabular onde cada variável forma uma coluna, cada observação forma uma linha, e cada tipo de unidade observacional forma uma tabela separada. Embora possa parecer uma convenção trivial, essa estrutura resolve inúmeros problemas práticos de análise e integra-se naturalmente com ferramentas modernas de ciência de dados (Wickham et al., 2023). A conversão entre formatos *wide* e *long* não é mera reformatação, mas uma reorganização conceitual que facilita ou dificulta determinadas operações analíticas (Wickham et al., 2023).

Outro aspecto crucial é a preferência por formatos de arquivo abertos e não-proprietários. Arquivos CSV, JSON ou TSV garantem interoperabilidade (podem ser lidos por múltiplas ferramentas), longevidade (independem de software específico) e auditabilidade (podem ser inspecionados em editores de texto simples) (Weidmann, 2023). Formatos proprietários como XLS ou arquivos SPSS, embora convenientes no curto prazo, criam dependências tecnológicas que comprometem o acesso futuro aos dados.

4.4 Código e Software

Na pesquisa computacional contemporânea, o código não é uma ferramenta auxiliar - ele é a especificação precisa do método. Enquanto um artigo pode descrever genericamente “realizamos regressão logística controlando por variáveis demográficas”, o código especifica exatamente qual implementação foi usada, quais parâmetros foram configurados, quais transformações prévias foram aplicadas. Portanto, a legibilidade do código é, fundamentalmente, um requisito metodológico (Pruim et al., 2023).

A adoção de *style guides* - convenções de estilo de código como o [Tidyverse Style Guide](#) - representa uma maturidade da computação científica como disciplina, com suas próprias normas (Pruim et al., 2023). Assim como convenções de citação bibliográfica facilitam a navegação em textos acadêmicos, *style guides* tornam o código previsível e compreensível. Nomenclaturas descritivas (`participant_age` em vez de `x`), uso consistente de espaçamento e indentação, e estruturas organizacionais padronizadas não são “perfeccionismo”, mas práticas de comunicação eficaz (Pruim et al., 2023).

A modularização de análises complexas em scripts separados é outra prática essencial. Em vez de um único script de 2000 linhas, análises devem ser decompostas em unidades funcionais: um script para importação de dados brutos, outro para limpeza, outro para análises exploratórias, outro para modelagem estatística. Cada módulo torna-se testável independentemente, reutilizável em outros projetos, e processado em paralelo em contextos colaborativos.

4.5 Colaboração

Projetos de pesquisa são, crescentemente, empreendimentos colaborativos - seja entre coautores, seja entre o pesquisador presente e seu “eu futuro” (que terá esquecido detalhes após alguns meses). A colaboração efetiva exige documentação que torne projetos autossuficientes, reduzindo dependência de conhecimento tácito.

O arquivo `README.md` funciona como o “cartão de visitas” do projeto (Zandonella Callegher & Massidda, 2022). Deve responder perguntas básicas: O que é este projeto? Qual o objetivo da pesquisa? Como os arquivos estão organizados? Como reproduzir as análises? Quem contatar para dúvidas? Um `README` bem escrito permite que qualquer pessoa - incluindo revisores de periódicos, colaboradores futuros, ou o próprio autor após um tempo - compreenda rapidamente a estrutura e propósito do projeto. Caso haja necessidade, pode-se cogitar um detalhamento mais apurado através de arquivos `README.md`'s por subdiretórios, como proposto pelo [Protocolo TIER 4.0](#).

Além da documentação narrativa, é essencial explicitar questões legais e de atribuição. Um arquivo `LICENSE` define como o trabalho pode ser usado (por exemplo, licenças

MIT, GPL, ou Creative Commons), enquanto um arquivo `CITATION` especifica como o trabalho deve ser creditado.

A documentação técnica do ambiente computacional também é fundamental. Listar explicitamente as versões de software, pacotes e sistema operacional utilizados permite que outros reproduzam o ambiente exato onde as análises foram executadas. Ferramentas como `sessionInfo()` no R ou `pip freeze` no Python automatizam essa documentação, capturando instantâneos do ambiente computacional.

4.6 Organização de Projetos

Estruturas de pastas padronizadas desempenham papel análogo às convenções de estrutura de artigos científicos. Assim como leitores esperam encontrar Introdução, Métodos e Resultados em seções específicas, usuários de projetos de pesquisa beneficiam-se de estruturas previsíveis que facilitam navegação cognitiva.

Uma estrutura mínima recomendada inclui:

- Um diretório `Data/` subdividido em `InputData/` (dados originais, imutáveis) e `AnalysisData/` (dados transformados, gerados por scripts).
- Um diretório `Scripts/` contendo todo o código de análise.
- Um diretório `Results/` ou `Output/` para produtos das análises (tabelas, gráficos).
- A raiz do projeto com os manuscritos e relatórios ou num diretório `Doc/`.
- Um arquivo `README.md` na raiz do projeto.

Protocolos mais formais, como o **TIER 4.0** (*Teaching Integrity in Empirical Research*), detalham estruturas mais granulares, especificando inclusive separação entre scripts de processamento de dados e scripts de análise estatística, ou a inclusão de diretórios específicos para metadados. O **Protocolo TIER**, originalmente desenvolvido no contexto da economia, estabelece quatro princípios fundamentais para reprodutibilidade: *sufficiency* (suficiência de informação), *soup-to-nuts* (completude do início ao fim), *portability* (portabilidade entre sistemas), e *(almost) one-click reproducibility* (reprodução quase automática) (Domingos & Batista, 2021).

Esses protocolos não devem ser entendidos como prescrições rígidas, mas como *templates* adaptáveis a contextos disciplinares e necessidades específicas de cada projeto. Nesse sentido, implementações práticas como o **ARTE** (*Article Reproducibility Template & Environment*) (Rogers & Limongi, 2025) traduzem os princípios do TIER 4.0 para o ecossistema específico de ferramentas R/Quarto (Figura 4.1). O **ARTE** oferece uma estrutura pronta de pastas, scripts iniciais e documentação modelo que operacionalizam as boas práticas discutidas por Limongi & Rogers (2025a) e Limongi & Rogers (2025b), facilitando sua adoção por pesquisadores que trabalham com essas ferramentas. Ao longo do curso, exploraremos como o **ARTE** (Rogers & Limongi, 2025) materializa alguns dos conceitos desse módulo (reprodutibilidade adequada) e ajuda a implementar uma reprodutibilidade máxima para seus projetos.

A nomenclatura consistente de arquivos complementa a organização de pastas. Convenções úteis incluem: uso de prefixos numéricos para indicar ordem de execução (`01-import.R`, `02-clean.R`) (Wickham et al., 2023), datas no formato ISO (YYYY-MM-DD) para ordenação cronológica automática, nomes descritivos em vez de genéricos (`clean-survey-data.R` em vez de `script2.R`), e evitação de espaços ou caracteres especiais que causam problemas em linha de comando (Weidmann, 2023).

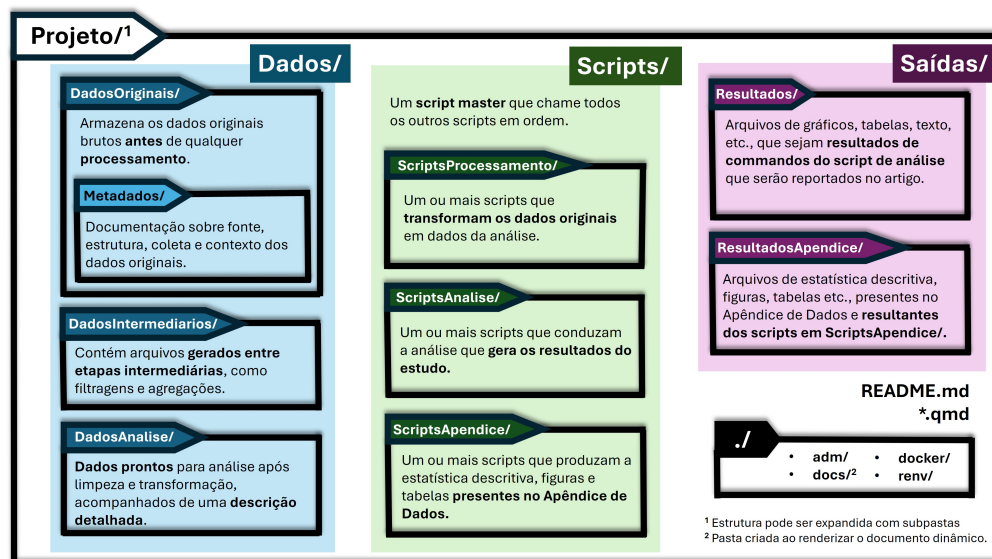


Figura 4.1: Estrutura de pastas do ARTE (Article Reproducibility Template & Environment). Ilustração disponível em: <https://doi.org/10.5281/zenodo.17496183>

4.7 Controle de Mudanças

Pesquisa é processo iterativo. Análises são refinadas, dados são atualizados, erros são corrigidos, novos testes são explorados. Sem um sistema de controle de versão, essas iterações geram proliferação caótica de arquivos (`analise_final.R`, `analise_final2.R`, `analise_final_FINAL_revisado.R`) e perda de rastreabilidade sobre o que mudou, quando e por quê.

Sistemas de controle de versão como [Git](#), que veremos no próximo módulo, funcionam como um “caderno de laboratório digital”, registrando não apenas o estado atual do projeto, mas todo seu histórico de desenvolvimento (Vuorre & Curley, 2018). Cada *commit* (registro de mudança) captura: o que mudou (diferenças linha por linha), quando mudou (timestamp), quem mudou (autoria) e por que mudou (mensagem descritiva). Essa “memória” permite reversão de erros, compreensão de decisões passadas e atribuição precisa de crédito em colaborações (Gilroy & Kaplan, 2019).

Práticas essenciais incluem realizar commits frequentes e focados (mudanças pequenas e logicamente coesas), escrever mensagens descritivas (“Adiciona análise de robustez ao modelo 3” em vez de “update”), e usar *branches* (ramificações) para experimentar abordagens alternativas sem comprometer a versão estável do projeto (Bryan, 2018).

É importante distinguir controle de versão de backup e arquivamento (Wilson et al., 2017). Backup (cópias redundantes em Google Drive, Dropbox) protege contra perda física de dados. Controle de versão registra histórico de mudanças. Arquivamento de longo prazo (repositórios como Zenodo ou OSF) preserva versões específicas com identificadores persistentes (DOIs) para citação. Essas três práticas são complementares, não substitutas.

4.8 Redação de Manuscritos

A integração entre análise e redação culmina num fluxo de trabalho reprodutível. Abordagens tradicionais - executar análises em software estatístico, copiar manualmente resultados para processador de texto - introduzem múltiplos pontos de falha: erros de transcrição, dessincronia quando análises são refeitas, e falta de transparência sobre a origem exata de cada número reportado (Wilson et al., 2017).

Documentos dinâmicos (RMarkdown, Quarto, Jupyter Notebooks) implementam o conceito de *literate programming* (Pruim et al., 2023; Rodrigues, 2023): intercalar código executável e narrativa em um documento único (Zandonella Callegher & Massidda, 2022). Tabelas e gráficos são gerados automaticamente a partir dos dados, garantindo consistência perfeita entre análise e relatório. Quando dados ou código mudam, o documento inteiro pode ser regenerado, propagando automaticamente todas as atualizações (Zandonella Callegher & Massidda, 2022).

Além da eliminação de erros, essa abordagem torna explícita a conexão entre afirmações e evidências. Cada estatística reportada pode ser rastreada até o código exato que a produziu, permitindo verificação e crítica metodológica em nível de detalhe antes impossível.

4.9 Começando de Onde Você Está

A transição para essas práticas não precisa ser abrupta ou completa. Alessandrini & Byers-Heinlein (2022) enfatizam a adoção incremental: implemente algumas práticas no projeto atual, adicione outras no próximo, e assim progressivamente. Um projeto 50% reprodutível é infinitamente superior a 0% - a perfeição não deve paralisar o progresso.

Para pesquisadores que não vão adotar as ferramentas discutidas nesse curso imediatamente, existem alternativas intermediárias (Limongi & Rogers, 2025b).

- Ferramentas como [JASP](#) e [jamovi](#) oferecem interfaces gráficas, *point-and-click*, para análises estatísticas, que registram as seleções metodológicas com os dados acoplados, e podem ser uma solução inicial para um workflow reprodutível (D. H. Baker et al., 2023).
- Se adicionar o [OpenRefine](#) ao fluxo, a limpeza visual de dados tabulares com log automático das transformações, oferecerá mais transparência às análises (Li et al., 2021).
- [KNIME](#) e [Orange](#) possibilitam construção de pipelines analíticos por meio de diagramas de fluxo, exportáveis para documentação, que também aliadas ao [OpenRefine](#), podem tornar pesquisas baseadas em machine learning mais reprodutíveis.

Mesmo em Excel - ferramenta frequentemente criticada mas amplamente utilizada - é possível adotar práticas mais rigorosas. Broman & Woo (2018) e Hertz & McNeill (2024) estabeleceram diretrizes específicas: uma tabela retangular por aba, cabeçalhos apenas na primeira linha, sem células mescladas, e uso de validação de entrada para prevenir erros, são algumas das principais (Figura 4.2). Essas práticas, embora não alcancem a reprodutibilidade total de scripts, representam alguma melhoria sobre usos sem padronização de planilhas.

Se só for possível adotar três práticas inicialmente, priorize: (1) nunca modificar dados brutos diretamente - sempre criar cópias para transformação; (2) documentar minima-

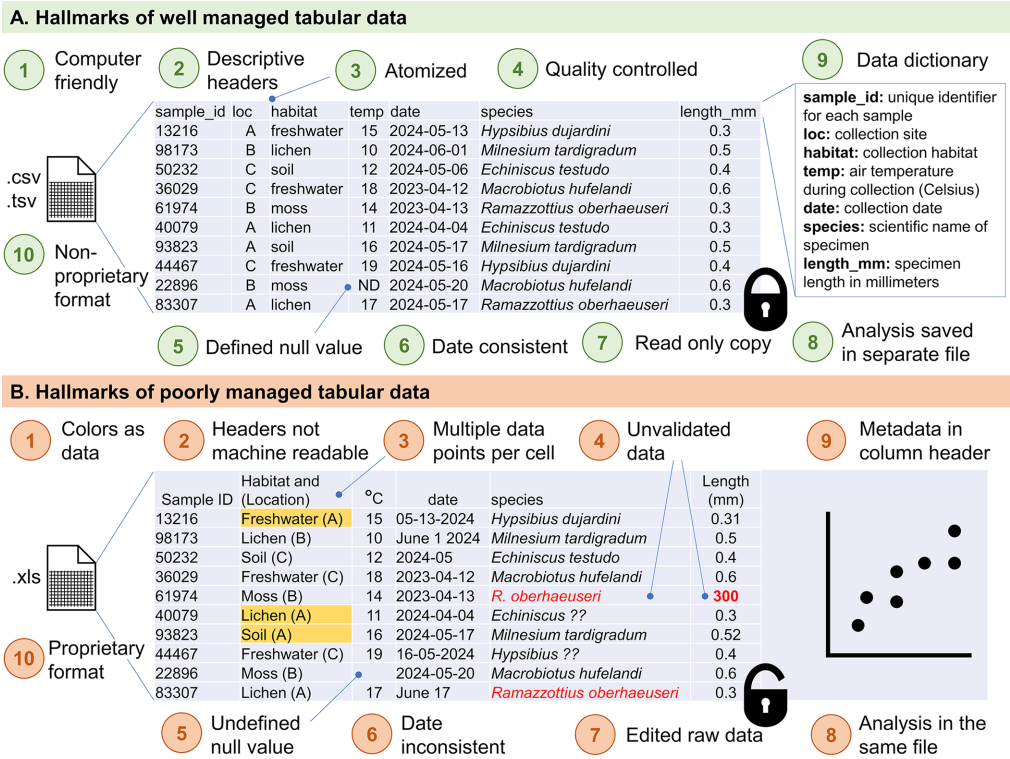


Figura 4.2: 10 dicas para dados tabulares. Ilustração disponível em: <https://doi.org/10.1371/journal.pcbi.1012604.g001>

mente o que foi feito - um README básico é melhor que nenhum; (3) usar nomenclatura consistente e descritiva para arquivos e pastas. Essas três práticas já colocam o projeto em patamar superior de organização e reprodutibilidade.

4.10 Considerações Finais

As práticas discutidas nesta seção não são imposições externas, mas ferramentas de autodefesa do pesquisador. Protegem contra o próprio esquecimento futuro, contra exigências imprevistas de revisores solicitando dados e código, contra perda de trabalho por problemas técnicos. O investimento inicial em organização retorna dividendos progressivos: redução de erros e retrabalho no curto prazo, colaboração facilitada no médio prazo, e construção de um corpus de trabalho auditável e extensível no longo prazo (Wilson et al., 2017).

A mensagem central é otimista: melhorias são possíveis e acessíveis. Não requerem expertise técnica extraordinária, mas compromisso com práticas sistemáticas (D. H. Baker et al., 2023). Na aula presencial, detalharemos como essas práticas se concretizam em ferramentas, templates e fluxos de trabalho específicos, sempre fornecendo referências para aprofundamento posterior.

4.11 Preparação para a Aula

! Pré-requisitos

Para melhor aproveitamento da aula, recomendamos que você realize os seguintes preparativos:

1. Baixar o Template ARTE

O **ARTE** (*Article Reproducibility Template & Environment*) é um template de projeto que implementa as práticas discutidas neste módulo. Durante o curso, utilizaremos esse template como exemplo prático de estrutura reprodutível.

Como baixar:

1. ☒ Acesse o repositório oficial: <https://github.com/phdpablo/article-template/>
2. ☒ Clique no botão verde Code (no canto superior direito) e selecione Download ZIP
3. ☒ Extraia o arquivo ZIP em uma pasta de fácil acesso no seu computador.
4. ☒ Familiarize-se com a estrutura de pastas navegando pelos diretórios e lendo os arquivos README em cada subpasta.

2. Tidyverse Style Guide

Se familiarize com as convenções do [Tidyverse Style Guide](#), pelo menos àquelas concernentes para análises estatísticas. Para direcionar sua leitura, preparamos uma [CheatSheet](#) que resume a prática diária de um analista/cientista de dados típico.

Apesar de algumas orientações serem as mesmas, excluimos dessa [CheatSheet](#) o tópico relacionado com o desenvolvimento de pacotes.

5. ☒ Dê uma olhada na [CheatSheet](#)

Capítulo 5

Controle de versão

5.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender a importância de sistemas de controle de versão robustos no contexto da Ciência Aberta
- Distinguir Git (sistema de controle de versão distribuído) de GitHub (plataforma colaborativa baseada em Git)
- Reconhecer limitações de ferramentas simples de versionamento (processadores de texto, armazenamento em nuvem) para pesquisa reprodutível
- Identificar cenários apropriados para diferentes workflows: Git Workflow Simplificado versus Trunk-Based Development
- Configurar repositórios locais e remotos para projetos de pesquisa
- Realizar operações básicas de controle de versão: commits, branches, push, pull
- Integrar Git/GitHub com RStudio para fluxo de trabalho reprodutível
- Avaliar quando manter projetos locais versus quando sincronizar com repositórios remotos públicos

5.2 Contextualização

Você em algum grau utiliza um sistema para versionar seu trabalho. Seja ele um simples `Ctrl + Z` ou `Cmd + Z` para desfazer a última ação, ou sistemas mais elaborados, como i) o controle de alterações do seu processador de texto ou ii) o histórico de versões do seu aplicativo de armazenamento nas nuvens (**OneDrive**, **Google Drive** ou **Dropbox**), você já está familiarizado com a ideia de controle de versão. Qual estudante ou pesquisador nunca se deparou com uma situação parecida da Figura 5.1?

No entanto, essas soluções simples são limitadas e inadequadas para gerenciar projetos de pesquisa — complexos ou simples — pois no contexto da CA, falham nos quesitos de reprodutibilidade e transparência. Para superar essas limitações, é necessário um sistema de controle de versão (VCS) mais robusto, como o Git. O Git é um VCS



Figura 5.1: Situação amadora de controle de versão

distribuído que armazena o histórico completo de alterações em repositórios locais e remotos, permitindo que você controle versões de seus arquivos e compartilhe-os com outras pessoas. Amplamente utilizado em projetos de desenvolvimento de software, o Git também é uma ferramenta valiosa para pesquisadores que desejam gerenciar e compartilhar seus ativos de pesquisa de forma transparente e rastreável (Braga et al., 2023; Bryan, 2018; Gilroy & Kaplan, 2019; Vuorre & Curley, 2018).

A [literatura sobre controle de versão](#), especialmente Git e Github, é “farta”. Tanto em inglês como em português. Uma pesquisa simples vai achar muitas referências a blogs e textos de profissionais especializados, inclusive, [para os nossos fins](#). No Youtube existem muitos vídeos sobre o tema. Seja o que escrevêssemos por aqui, seria de pouca contribuição adicional. Dessa forma, buscamos contextualizar o versionamento de arquivos num empreendimento de pesquisa de nosso dia a dia: um pesquisador com viés quantitativo, envolvido em pesquisas com pouca colaboração, mas que encontrou no controle de versão uma solução singular para diversas demandas preconizadas pela CA.

5.3 Por Que Ferramentas Simples Não Bastam

Controles de versionamento mais simples, como os oferecidos por processadores de texto e soluções de armazenamento em nuvem, são insuficientes para workflows de pesquisa empírica no contexto da CA. Em projetos que envolvem múltiplos colaboradores, ferramentas simples dificultam o rastreamento e a fusão de contribuições de vários pesquisadores. O Git, por outro lado, oferece gerenciamento eficientes de branches e fusão de código, permitindo colaboração mais organizada (Braga et al., 2023; Vuorre & Curley, 2018).

Processadores de texto e armazenamento em nuvem oferecem histórico de versões limitado e pouco detalhado. Em contraste, o Git permite rastreamento minucioso de cada alteração, incluindo autor e propósito de cada mudança, facilitando auditorias e revisões (Scroggie et al., 2023; Weberpals & Wang, 2024). Pesquisas empíricas frequentemente envolvem scripts de análise e grandes volumes de dados que necessitam de versionamento adequado. Ferramentas simples não são otimizadas para esses tipos de arquivos, enquanto o Git gerencia código e dados de maneira eficiente, garantindo integridade e reprodutibilidade das análises (Vuorre & Curley, 2018; Weberpals & Wang, 2024).

Em ambientes de CA, automatizar testes e validações é crucial para garantir qualidade e reprodutibilidade dos resultados. Soluções como GitHub Actions permitem implementação de pipelines de integração contínua (CI), automatizando testes e outras tarefas - algo impossível com controles de versão simples (Gilroy & Kaplan, 2019). O Git e o GitHub incentivam documentação detalhada através de commit messages e issues, promovendo transparência e compreensão do progresso e decisões do projeto (Braga et al., 2023; Scroggie et al., 2023). Ferramentas simples de versionamento não oferecem mecanismos equivalentes para documentar o processo de desenvolvimento de forma estruturada.

Em projetos complexos, conflitos de versão são inevitáveis. Sistemas simples podem não oferecer ferramentas adequadas para resolver conflitos de maneira eficiente. O Git proporciona ferramentas avançadas de merge e resolução de conflitos, minimizando risco de perda de dados ou inconsistências (Rodrigues, 2023; Vuorre & Curley, 2018). Ferramentas simples mantêm histórico limitado, focado em versões específicas de documentos. O Git mantém histórico completo e analítico de todas as mudanças, permitindo análises detalhadas do desenvolvimento do projeto ao longo do tempo (Bryan, 2018; Gilroy &

Kaplan, 2019).

5.4 Git e GitHub: Ferramentas Complementares

Git e GitHub são ferramentas intimamente relacionadas, mas oferecem soluções distintas para versionamento, atendendo a diferentes necessidades dos pesquisadores (Vuorre & Curley, 2018).

Git é um sistema de controle de versão distribuído que permite rastrear alterações em arquivos e coordenar trabalho em projetos colaborativos. Uma das principais vantagens do Git é a capacidade de operar de forma totalmente local. Isso significa que pesquisadores podem manter histórico completo de alterações em seus arquivos sem necessidade de conexão com internet ou servidor externo - particularmente útil para quem prefere manter dados em ambiente controlado e privado (Bryan, 2018; Vuorre & Curley, 2018).

Git oferece funcionalidades avançadas de branching e merging, permitindo que diferentes linhas de trabalho sejam desenvolvidas simultaneamente e depois combinadas de maneira controlada. Essa flexibilidade é essencial para experimentações e desenvolvimentos paralelos, comuns em projetos de pesquisa. O rastreamento detalhado é outra característica fundamental: cada commit no sistema é identificado de forma única e inclui metadados sobre quem fez a alteração e uma mensagem descritiva, permitindo histórico minucioso das mudanças. Caso necessário, Git permite reverter para estados anteriores do projeto, recuperando versões passadas sem perder o histórico de alterações (Vuorre & Curley, 2018).

GitHub é uma plataforma baseada na web que utiliza Git como backend e adiciona funcionalidades colaborativas e de gerenciamento de projetos. Uma das maiores vantagens do GitHub é a hospedagem de repositórios Git, permitindo que pesquisadores façam backup de seus projetos na nuvem e colaborem com outros usuários de qualquer lugar do mundo - facilitando colaboração extensiva, aspecto crucial no contexto da CA (Braga et al., 2023; Gilroy & Kaplan, 2019).

GitHub também fornece ferramentas como pull requests e reviews de código, que simplificam colaboração entre diferentes pesquisadores. Essas ferramentas permitem que propostas de mudanças sejam discutidas, revisadas e integradas de forma estruturada, promovendo fluxo de trabalho colaborativo e transparente. Além disso, GitHub Actions oferece suporte à automação de testes, builds e outras tarefas, garantindo que cada alteração seja verificada e validada automaticamente: funcionalidade vital para assegurar reprodutibilidade e qualidade do projeto, aspectos centrais da CA (Braga et al., 2023; Gilroy & Kaplan, 2019).

A plataforma GitHub também se destaca em termos de documentação e comunicação. Issues, wikis e páginas de projetos proporcionam meios para documentação detalhada, rastreamento de problemas e comunicação eficiente entre membros da equipe. O controle de acesso e permissões permite que gestores de projetos configurem quem pode fazer alterações ou revisar código, assegurando integridade do trabalho. A hospedagem de projetos no GitHub aumenta significativamente a visibilidade da pesquisa, facilitando disseminação de resultados e colaboração com a comunidade científica global, promovendo cultura de transparência e compartilhamento de conhecimento (Braga et al., 2023; Gilroy & Kaplan, 2019; Vuorre & Curley, 2018).

Em resumo, enquanto o Git fornece solução robusta para controle de versão local, ideal

para quem necessita de ambiente privado e eficiente, o GitHub expande essas capacidades com ferramentas que promovem colaboração, automação, documentação e visibilidade pública. No contexto da CA, o GitHub se alinha melhor com princípios de transparência, colaboração e reprodutibilidade, oferecendo conjunto de ferramentas que suportam e amplificam as boas práticas da pesquisa científica (Braga et al., 2023; Gilroy & Kaplan, 2019; Weberpals & Wang, 2024).

5.5 Workflows de Controle de Versão para Pesquisa Reprodutível

Git e GitHub têm sido fundamentais em projetos de grande escala, como o desenvolvimento do kernel do Linux e projetos de software de código aberto como o TensorFlow, mantido pelo Google. Estes projetos envolvem milhares de colaboradores ao redor do mundo, exigindo sistema robusto de controle de versão que possa lidar com vasta quantidade de alterações simultâneas, fusões complexas e alto nível de coordenação e colaboração. A capacidade do Git de gerenciar branches de forma eficiente e a integração contínua proporcionada pelo GitHub são elementos cruciais para o sucesso desses projetos. A Figura 5.2 ilustra um diagrama hipotético do fluxo de trabalho em um ambiente de desenvolvimento de software típico, com diversos ramos, e como a complexidade de gerenciamento de versões, apesar de tratada pelo Git e GitHub, pode escalar.




Figura 5.2: Diagrama GitFlow hipotético num ambiente de desenvolvimento de software típico

Apesar dessa reputação consolidada em grandes projetos colaborativos, as funcionalidades dessas ferramentas são plenamente adaptáveis ao cotidiano de pesquisadores individuais ou de pequenos grupos. A escolha do workflow mais adequado depende do contexto específico da pesquisa, do número de colaboradores e das preferências da equipe.

Diferentes comunidades de desenvolvimento de software têm adotado estratégias distintas de organização de branches. Duas abordagens se destacam pela sua simplicidade e

efetividade: o **Git Workflow Simplificado**, adequado para equipes pequenas que priorizam clareza sobre quem trabalha em quê, e o **Trunk-Based Development (TBD)**, que enfatiza integração contínua em um branch principal. Ambas são válidas e podem ser adotadas conforme as demandas e preferências do pesquisador ou grupo de pesquisa.

5.5.1 Git Workflow Simplificado: Colaboração com Rastreabilidade Clara

O Git Workflow Simplificado é particularmente útil quando a equipe de pesquisa valoriza a **documentação clara de contribuições individuais** e a **revisão estruturada por pares** antes da integração das mudanças ao trabalho principal. A Figura 5.3 ilustra um exemplo hipotético dessa abordagem com três autores colaborando em um projeto de pesquisa (Ram, 2013).




Figura 5.3: Um fluxo de trabalho hipotético do Git para uma colaboração científica envolvendo três autores. Cada círculo representa um commit e as cores indicam commits específicos do autor. Setas bidirecionais indicam uma sincronização (um push e pull na terminologia Git). Setas unidirecionais indicam uma atualização de uma ramificação para outra. As setas horizontais indicam o desenvolvimento ao longo de um ramo específico. Ilustração disponível em: <<https://doi.org/10.5281/zenodo.12165926>>.

Neste cenário, cada autor cria um branch a partir do main para trabalhar em uma tarefa específica: um pode estar ajustando análises estatísticas, outro refinando a redação, um terceiro organizando dados brutos. Cada branch representa uma “linha de trabalho” claramente identificável, facilitando o acompanhamento de quem está fazendo o quê (Ram, 2013). Antes de integrar suas mudanças ao branch principal, o autor abre um pull request, que permite revisão por pares e discussão estruturada das contribuições (Braga et al., 2023; Gilroy & Kaplan, 2019). Essa prática é essencial em pesquisa, onde validação e feedback dos colaboradores são fundamentais antes da integração. Uma vez aprovado e testado (se aplicável), o pull request é aceito (pelo pesquisador líder, por exemplo) e o branch é integrado ao main.

Essa estrutura preserva a transparência sobre contribuições, facilita auditoria do histórico do projeto e mantém a rastreabilidade de decisões (Ram, 2013). Com três branches de curta a média duração, o gerenciamento dessa hipotética pesquisa não introduz complexidade significativa e oferece um equilíbrio prático entre organização e simplicidade (Scroggie et al., 2023; Vuorre & Curley, 2018).

5.5.2 Trunk-Based Development: Integração Contínua Centralizada

O Trunk-Based Development (TBD) oferece uma alternativa que prioriza a **integração rápida e frequente** ao branch principal, minimizando a divergência entre versões e facilitando a detecção imediata de conflitos (Rodrigues, 2023). Em TBD, todos os colaboradores trabalham diretamente no main (ou em branches de muito curta duração: horas, não dias) e realizam integrações contínuas. O histórico do projeto torna-se linear e fácil de auditar, e a necessidade de sincronizações complexas entre múltiplos branches é eliminada.

Para um pesquisador trabalhando de forma individual, TBD oferece uma solução elegante e direta (Rodrigues, 2023). A Figura 5.4 ilustra um cenário onde um único pesquisador mantém o branch principal para o desenvolvimento do projeto e, conforme necessário, cria branches temporários para experimentos ou novas ideias. Cada commit é documentado com uma mensagem descritiva, permitindo que o pesquisador rastreie o progresso e o propósito de cada alteração (Rodrigues, 2023; Vuorre & Curley, 2018). Esse processo garante que o projeto seja desenvolvido de forma estruturada, com um histórico detalhado que pode ser acompanhado, revisado e auditado por qualquer pessoa interessada. Neste cenário, o overhead de gerenciamento de branches é mínimo, e a reprodutibilidade é naturalmente alcançada através da documentação metódica de cada etapa (Rodrigues, 2023; Weberpals & Wang, 2024).




Figura 5.4: Um fluxo de trabalho hipotético do Git para a execução de uma pesquisa solo. Cada círculo representa um commit específico do autor. Setas bidirecionais indicam uma sincronização (um push ou pull na terminologia Git). Setas unidirecionais indicam uma atualização de uma ramificação para outra. As setas horizontais indicam o desenvolvimento ao longo de um ramo específico. Nesse fluxo de trabalho o autor optou por sincronizar o repositório local com o repositório remoto (Github) desde as etapas iniciais da pesquisa. Nessa perspectiva o repositório remoto funciona como um armazenamento de backup, e se público, para tornar a evolução do trabalho do pesquisador disponível para quem deseja acompanhar. Ilustração disponível em: <<https://doi.org/10.5281/zenodo.12165926>>

Alternativamente, como ilustrado na Figura 5.5, um pesquisador pode optar por tornar público seu trabalho (dados, materiais e histórico de mudanças) somente quando necessário submeter o artigo para publicação. Neste workflow, o pesquisador desenvolve seu projeto localmente utilizando Git para controle de versões em um repositório privado, realizando commits frequentes diretamente no main local. Apenas quando há necessidade de conformidade com políticas de reprodutibilidade ou publicação em repositórios

abertos, o pesquisador vincula o repositório local com um repositório remoto, tornando o histórico completo publicamente disponível. Essa estratégia oferece flexibilidade: permite que o pesquisador mantenha privacidade durante o desenvolvimento exploratório, enquanto garante que, ao final, todo o histórico de mudanças esteja disponível e auditável (Rodrigues, 2023; Vuorre & Curley, 2018).




Figura 5.5: Um fluxo de trabalho hipotético do Git para a execução de uma pesquisa solo. Cada círculo representa um commit específico do autor. Setas bidirecionais indicam uma sincronização (um push ou pull na terminologia Git). Setas unidirecionais indicam uma atualização de uma ramificação para outra. As setas horizontais indicam o desenvolvimento ao longo de um ramo específico. Nesse fluxo de trabalho o autor optou por sincronizar o repositório local com o repositório remoto (Github) somente quando finalizou o artigo. Nessa perspectiva o repositório remoto só faz sentido se para publicar os dados, materiais da pesquisa e o histórico de mudanças, pois como backup, o autor pode utilizar um serviço de armazenamento nas nuvens (OneDrive, GoogleDrive, DropBox, etc.). Ilustração disponível em: <<https://doi.org/10.5281/zenodo.12165926>>

5.5.3 Escolhendo o Workflow Mais Adequado

A escolha entre essas abordagens não é questão de uma ser “correta” e outra “incorreta”. O **Git Workflow Simplificado** é particularmente apropriado quando:

- A equipe é pequena e valoriza clareza sobre contribuições individuais
- Revisão por pares estruturada antes da integração é desejável
- Histórico de branches proporciona documentação valiosa do processo decisório

O **Trunk-Based Development** é mais adequado quando:

- O pesquisador trabalha individualmente ou em um contexto onde integração contínua é prioritária
- Simplicidade do histórico e linearidade são valorizadas
- Conflitos são rapidamente detectados e resolvidos

No contexto da CA, ambas as abordagens, quando bem implementadas, promovem reprodutibilidade, transparência e colaboração eficiente (Braga et al., 2023; Gilroy & Kaplan, 2019; Vuorre & Curley, 2018; Weberpals & Wang, 2024). A integração com ferramentas de automação, como GitHub Actions, potencializa ambos os workflows, permitindo testes, verificações e validações automáticas a cada novo commit ou pull request (Braga et al., 2023).

Em suma, o Git e o GitHub fornecem as ferramentas necessárias para suportar workflows

que se adequam a diferentes contextos de pesquisa. Seja adotando um Git Workflow Simplificado para colaborações estruturadas ou Trunk-Based Development para pesquisa individual, a introdução de práticas robustas de controle de versão desde o início de um projeto científico, como enfatizado por Vuorre & Curley (2018), torna o fluxo de trabalho mais eficiente, transparente e reproduzível, alinhando-se com os princípios fundamentais da CA (Braga et al., 2023; Rodrigues, 2023; Weberpals & Wang, 2024).

5.6 Preparação para a Aula

! Pré-requisitos

Antes da aula síncrona, certifique-se de completar **todos** os passos abaixo. Instruções detalhadas estão disponíveis na [página de pré-trabalho do curso](#).

Checklist de Preparação:

1. ☒ Instalar o [Git](#) no seu computador
2. ☒ Criar conta no [GitHub](#)
3. ☒ Configurar Git localmente com seu nome e e-mail (via terminal ou RStudio)
4. ☒ Verificar se o RStudio reconhece a instalação do Git (Tools > Global Options > Git/SVN)
5. ☒ Criar um Personal Access Token (PAT) no GitHub para autenticação via RStudio
6. ☒ Familiarizar-se com a interface básica do GitHub navegando por repositórios públicos

Capítulo 6

Documentos Reprodutíveis

6.1 Objetivos de aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender o papel dos documentos dinâmicos no fluxo de trabalho científico reprodutível
- Entender o funcionamento do Quarto como sistema de publicação científica
- Reconhecer a integração entre narrativa, código e dados em um documento reprodutível
- Aplicar o conceito de “reprodutibilidade adequada” através do template ARTE
- Preparar o ambiente de trabalho (RStudio, Git, Zotero) para criar documentos dinâmicos
- Explorar o template ARTE em sua versão publicada
- Utilizar os editores Source e Visual do RStudio para criar e formatar documentos `.qmd`
- Integrar referências bibliográficas do Zotero diretamente nos documentos Quarto
- Praticar a transição de um manuscrito Word tradicional para o formato reprodutível Quarto
- Incorporar códigos de análise (*chunks*) e gerar saídas dinâmicas (tabelas, gráficos)
- Compilar e publicar o projeto através do GitHub Pages

6.2 Contextualização

A reprodutibilidade e a transparência são princípios fundamentais da Ciência Aberta (CA), independentemente da abordagem metodológica adotada pelo pesquisador (Limongi & Rogers, 2025a). Seja você um pesquisador qualitativo, quantitativo ou misto, as ferramentas e práticas discutidas neste módulo podem ser aplicadas para organizar, documentar e compartilhar seu projeto de pesquisa de forma mais transparente e

verificável.

Como discutido nos módulos anteriores, dominar a plataforma [OSF](#), o [Zotero](#) e um protocolo de organização como o [Protocolo TIER](#) pode ser suficiente para estabelecer um nível básico de reprodutibilidade (Limongi & Rogers, 2025b). A integração dessas soluções com outras ferramentas já utilizadas no dia a dia (armazenamento em nuvens, processadores de texto, softwares específicos de análise) já capacita o pesquisador para ter um projeto organizado e documentado, minimamente, segundo as boas práticas da CA.

Para pesquisadores que preferem interfaces gráficas em vez de programação, existem soluções *no-code* compatíveis com os princípios da CA. Softwares como [JASP](#) e [Jamovi](#) oferecem interfaces amigáveis para análises estatísticas, mantendo os outputs salvos junto com os dados, facilitando a reprodutibilidade (Rogers & Limongi, 2025). Adicionalmente, ferramentas como [KNIME](#), [Orange](#) e [OpenRefine](#) fornecem ambientes visuais para limpeza, transformação e análise de dados através de workflows baseados em nós, sem exigir programação. Embora essas alternativas ainda apresentem limitações quanto ao controle de versões e à amplitude de análises disponíveis, representam opções válidas, uma porta de entrada, para pesquisadores que buscam aderir aos princípios da CA sem dominar linguagens de programação.

6.3 Quarto: Sistema de Publicação Científica

O foco deste módulo é apresentar o Quarto como ferramenta para criação de documentos dinâmicos reprodutíveis. O [Quarto](#) é um sistema de publicação científica de código aberto que permite a integração de narrativa, código e resultados em um único documento (Limongi & Rogers, 2025b). Através do Quarto, pesquisadores podem criar documentos com texto, imagens, tabelas, gráficos, equações e referências bibliográficas, com pouca necessidade de programação, especialmente quando utilizado apenas como editor de documentos dinâmicos.

O Quarto é integrado ao RStudio, facilitando sua utilização por pesquisadores já familiarizados com o ambiente R. Entretanto, o Quarto suporta múltiplas linguagens de programação (R, Python, Julia e Observable). No RStudio, os usuários escrevem narrativas e códigos, e o Quarto processa esse conteúdo, exportando o resultado em diferentes formatos como HTML, PDF e DOCX, facilitando a disseminação em múltiplas plataformas.

6.3.1 Markdown: A Linguagem Base

O Quarto utiliza Markdown como linguagem de marcação para formatação de texto (Limongi & Rogers, 2025b). Markdown é uma sintaxe leve e intuitiva que permite formatar texto de forma simples, utilizando caracteres especiais para indicar títulos, listas, ênfases, links e outros elementos. Por exemplo, **texto** produz **texto em negrito**, **## Título** cria um título de segundo nível, e [\[link\]](#) (`url`) gera um hiperlink. Esta simplicidade torna o Markdown acessível mesmo para pesquisadores sem experiência em programação.

Neste módulo, não nos aprofundaremos extensivamente na sintaxe Markdown, pois existem recursos excelentes disponíveis. Recomendamos consultar a documentação oficial do Quarto sobre [Markdown Basics](#) e o [R Markdown Cheat Sheet](#) da Posit/RStudio para

referência rápida. Durante a aula prática, demonstraremos os elementos mais utilizados na escrita científica, e você poderá consultar esses recursos conforme necessário.

6.3.2 Arquitetura e Fluxo de Trabalho

As quatro figuras apresentadas a seguir ilustram, em camadas progressivas, como o Quarto organiza e integra texto, código e dados para gerar documentos dinâmicos e reprodutíveis. A sequência é pedagógica: cada figura aprofunda o entendimento do fluxo de trabalho.

A primeira figura (Figura 6.1) apresenta a visão geral da arquitetura do Quarto. No lado esquerdo, múltiplas linguagens de programação (R, Python, Julia, Observable) podem ser utilizadas como entrada. O Quarto, representado ao centro, atua como plataforma de integração que combina códigos dessas diferentes linguagens para criar documentos ricos em conteúdo. À direita, o sistema pode exportar para diversos formatos de saída (HTML para web, PDF para documentos portáteis, DOCX para edição), oferecendo flexibilidade na distribuição do conteúdo (Limongi & Rogers, 2025b).




Figura 6.1: Integração do Quarto

A segunda figura (Figura 6.2) detalha o fluxo analítico de processamento. O processo inicia com um arquivo `.qmd` (Quarto Markdown) que contém texto, código e elementos dinâmicos. Este arquivo é processado por ferramentas como knitr (pacote R para integração de código e texto) ou Jupyter (ambiente interativo para múltiplas linguagens), gerando um arquivo Markdown intermediário. Em seguida, o Pandoc, ferramenta poderosa de conversão de documentos, transforma o Markdown nos formatos finais desejados (HTML, PDF, DOCX). Esta camada de processamento garante a conversão adequada do conteúdo dinâmico para formatos estáticos ou interativos.

A terceira figura (Figura 6.3) oferece uma visão sintética e didática dos passos práticos. O usuário (1) abre um novo arquivo `.qmd`, (2) escreve o conteúdo usando sintaxe Quarto, (3) incorpora código (por exemplo, R) que gera saídas a serem incluídas no relatório, e




Figura 6.2: Workflow analítico do Quarto

(4) renderiza o documento, substituindo o código por suas saídas e gerando o documento final no formato desejado (slides, PDF, HTML ou MS Word). Esta sequência ilustra a simplicidade do workflow para o usuário final.

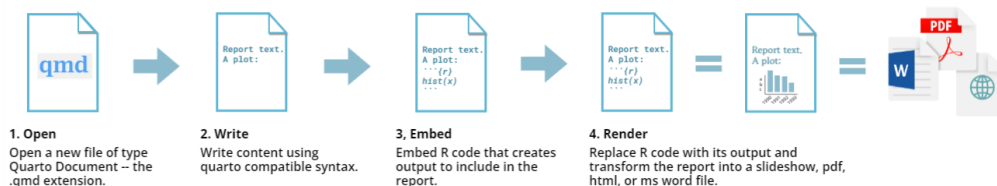


Figura 6.3: Workflow sintético do Quarto

Por fim, a quarta figura (Figura 6.4) contextualiza o uso do Quarto em uma pesquisa científica empírica completa. A narrativa científica (introdução, metodologia, resultados, discussão), o código de análise e os dados (sob controle de versão para rastreabilidade) são combinados em um editor de texto plano. O código embutido é executado, gerando saídas (gráficos, tabelas, estatísticas) automaticamente incorporadas ao documento. Após aplicação de template e conversão pelo Pandoc, o resultado pode ser um artigo PDF estático para submissão a revistas ou um website dinâmico onde leitores podem interagir com gráficos e visualizações (Rogers & Limongi, 2025). Este fluxo demonstra como o Quarto integra todo o ciclo de produção científica, da concepção à publicação, promovendo transparência e reprodutibilidade.

6.4 ARTE: Da Reprodutibilidade Mínima à Adequada

No módulo de organização de projetos, foi apresentado o conceito de “reprodutibilidade mínima”, fundamentado na estruturação adequada de pastas (Protocolo TIER), documentação clara (arquivos README) e compartilhamento de materiais em repositórios como o OSF. Esse nível básico garante que dados, scripts e manuscritos estejam organizados logicamente e disponíveis para verificação (Limongi & Rogers, 2025b).




Figura 6.4: Workflow de uma pesquisa empírica utilizando Quarto

O template [ARTE](#) (*Article Reproducibility Template & Environment*) avança para o que denominamos “reprodutibilidade adequada”, incorporando ferramentas adicionais que garantem maior rigor e controle (Rogers & Limongi, 2025). O ARTE mantém a estrutura TIER como fundação, mas adiciona:

- **Controle de versão com Git/GitHub:** rastreamento rigoroso de todas as mudanças no projeto, permitindo retornar a versões anteriores e colaborar de forma transparente
- **Documentos dinâmicos com Quarto:** integração entre análise e escrita, eliminando erros de cópia manual de resultados
- **Gerenciamento de dependências com renv:** registro das versões exatas de pacotes utilizados, garantindo que o ambiente computacional possa ser recriado
- **Integração com Zotero:** gestão automatizada de referências bibliográficas diretamente no fluxo de trabalho

Esta transição representa a evolução de um projeto bem organizado (reprodutibilidade mínima) para um projeto computacionalmente reprodutível (reprodutibilidade adequada), onde outros pesquisadores podem não apenas acessar os materiais, mas também executar as análises e gerar os mesmos resultados (Rogers & Limongi, 2025). O ARTE ainda oferece a opção de “reprodutibilidade completa” através de containerização com Docker, encapsulando todo o ambiente computacional (sistema operacional, versões de software, dependências), mas este nível será explorado no módulo seguinte.

6.5 Preparação para a Aula

! Pré-requisitos

Para aproveitar ao máximo este módulo, certifique-se de ter completado **todas** as etapas de preparação descritas na seção de [pré-requisitos](#):

Checklist de Preparação:

1. ☒ **R e RStudio:** Certifique-se de ter o R e o RStudio instalados em seu computador

2. ☒ **Git e GitHub:** Instale o Git em seu computador e crie uma conta no GitHub. Configure a integração do Git/GitHub com o RStudio conforme as instruções do módulo anterior
3. ☒ **Zotero:** Instale o Zotero e o plugin Better BibTeX para gerenciamento de referências bibliográficas

Capítulo 7

Controle de Ambiente

7.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender as diferenças e aplicações de Máquinas Virtuais, Containers e ferramentas de controle de ambiente (renv, Conda) no contexto da reprodutibilidade científica
- Configurar e utilizar o pacote **renv** para isolar e gerenciar dependências de pacotes R em projetos de pesquisa
- Operar o Docker Desktop via interface gráfica para criar, executar e gerenciar containers
- Implementar workflows reprodutíveis combinando renv e Docker para garantir reprodutibilidade completa do ambiente computacional
- Aplicar os conceitos aprendidos no template ARTE (Article Reproducibility Template Environment) para criar artigos científicos completamente reprodutíveis
- Compartilhar ambientes de pesquisa utilizando imagens Docker e arquivos de configuração

7.2 Contextualização

Imagine a seguinte situação: você publicou uma pesquisa quantitativa, disponibilizando o código e os dados para que outros pesquisadores possam reproduzir os resultados. Um pesquisador entra em contato e diz que não conseguiu replicar seus resultados. Você como bom mineiro, responde: “Uai, comigo funcionou!”. Prestativo como é sugere para o pesquisador, da Polônia, que venha até sua casa para que você possa ajudá-lo, e aproveitar para tomar um café e comer um pão de queijo. O pesquisador, educadamente, responde que não pode ir até sua casa, pois está do outro lado do mundo.

Então, prestativo como é, você sugere que vai enviar uma imagem do seu HD para ele. O pesquisador, educadamente, responde que não pode aceitar, pois o arquivo da imagem é muito grande e ele não tem espaço suficiente para armazenar a imagem. Além do mais,

ele não entende muito bem (e não tem!) a infraestrutura para poder acessar seu HD. Inclusive, ele utiliza um sistema operacional (e estrutura de hardware) diferente do seu.

Pois bem, essa situação poderia ser a única saída alguns anos atrás. No entanto, hoje em dia, com os serviços de armazenamento em nuvem, as soluções de virtualização (máquinas virtuais), containers e controle de ambiente, é possível compartilhar o ambiente de desenvolvimento de forma mais simples e eficiente.

7.3 Soluções para Controle do Ambiente

A reprodutibilidade computacional, a capacidade de obter resultados consistentes e verificáveis a partir de um experimento computacional quando os mesmos dados de entrada, código e ambiente de software são utilizados, tornou-se central para muitos projetos de pesquisa (Moreau et al., 2023). Pesquisadores que tentam reproduzir ou construir sobre trabalhos existentes frequentemente enfrentam desafios que, na melhor das hipóteses, atrasam projetos científicos ou, em casos extremos, podem impedir completamente a reutilização ou colaboração (Wiebels & Moreau, 2021). Containers e ferramentas de controle de ambiente fornecem respostas a esses desafios.

7.3.1 Máquinas Virtuais (VMs)

Máquinas virtuais (VM) são ambientes que emulam um sistema operacional (SO) completo sobre um hardware físico, permitindo a execução de múltiplos sistemas operacionais em uma única máquina. Elas oferecem um alto nível de isolamento e controle, pois cada VM inclui seu próprio SO, bibliotecas e aplicativos. As VMs podem ser classificadas em dois tipos: *Type 1 Hypervisor* e *Type 2 Hypervisor*. Tipo 1 Hypervisor roda diretamente sobre o hardware, gerenciando várias VMs sem a necessidade de um SO subjacente, o que proporciona melhor desempenho e eficiência. Já o *Type 2 Hypervisor* roda sobre um SO existente, sendo menos eficiente, mas mais fácil de configurar e utilizar em ambientes de desktop (Figura 7.1).

Exemplos de soluções de virtualização Tipo 1 podemos elencar:

- **VMware ESXi**: Uma solução comercial amplamente utilizada em ambientes corporativos para criar e gerenciar VMs. Oferece alta performance e várias funcionalidades avançadas de gerenciamento.
- **Microsoft Hyper-V**: Integrado ao Windows, é uma solução comercial que também pode ser usada gratuitamente com recursos limitados. Hyper-V é amplamente utilizado em ambientes Windows.
- **Xen**: Uma solução open-source popular em ambientes de nuvem, como o Amazon Web Services (AWS). Xen é altamente eficiente e suportado por várias distribuições Linux.

Exemplos de Tipo 2 incluem:

- **VMware Workstation**: Uma solução comercial usada principalmente em desktops e laptops para executar múltiplos SOs. VMware Workstation é conhecido pela sua estabilidade e facilidade de uso. Recentemente ele passou a ser gratuito.
- **Oracle VirtualBox**: Uma solução open-source amplamente utilizada para virtualização em desktops. VirtualBox é gratuito e suporta uma vasta gama de SOs




Figura 7.1: Soluções para controle do ambiente de desenvolvimento. Ilustração disponível em: <https://doi.org/10.5281/zenodo.12521134>

convidados.

- **Parallels Desktop:** Uma solução comercial popular entre usuários de Mac, permitindo que eles rodem Windows, Linux e outros no macOS de maneira integrada.

As vantagens das VMs incluem um alto isolamento e segurança, além da flexibilidade para rodar diferentes SOs. No entanto, elas consomem muitos recursos, como CPU, memória e armazenamento, e as imagens são grandes e difíceis de compartilhar. Nesse sentido, para a reprodutibilidade das pesquisas empíricas no âmbito da CA o emprego de VMs pode ser impraticável. Para nosso dia a dia enquanto pesquisadores e professores pode ser uma ferramenta extremamente útil. **Esse curso está organizado dentro de uma VM.**

7.3.2 Containers

Por outro lado, os containers são uma tecnologia de virtualização a nível de SO, mais leve que as VMs, que compartilham o mesmo kernel do SO hospedeiro, mas ainda assim oferecem isolamento para aplicações (Moreau et al., 2023). [Docker](#), [Kubernetes](#), [OpenShift](#) e [Podman](#) são algumas das ferramentas mais populares para criar e gerenciar containers. Ao contrário das VMs, os containers contêm apenas a aplicação e suas dependências, compartilhando o kernel do SO hospedeiro. Isso torna os containers mais leves e eficientes em termos de recursos, e ainda são rápidos na inicialização e execução. Além disso, são fáceis de distribuir e compartilhar.

Os contêineres estão ganhando força na pesquisa científica (Moreau et al., 2023; Zandonella Callegher & Massidda, 2022) e o Docker despontado como uma das soluções mais populares para controle de ambiente em pesquisas empíricas quantitativas (Wiebels & Moreau, 2021).

Containers resolvem o problema conhecido como “dependency hell” ao empacotar todo o código e dependências necessários para garantir que as análises sejam executadas de maneira confiável em uma variedade de sistemas operacionais e versões de software (Wiebels & Moreau, 2021). Eles permitem “empacotar” (isolar) todo o ambiente de computação de forma que qualquer pessoa em qualquer computador possa examinar e replicar o trabalho, independentemente do software instalado, drivers e sistemas operacionais.

Uma analogia útil é pensar em uma imagem Docker como uma receita de bolo e o container Docker correspondente como um bolo acabado (Wiebels & Moreau, 2021). A receita contém as instruções para fazer o bolo, pode ser usada para fazer quantos bolos você quiser e pode ser compartilhada para permitir que outros façam o mesmo bolo.

7.3.3 Controle de Dependências

Por fim, temos as ferramentas de controle de ambiente como [Conda](#) e [renv](#), que ajudam a gerenciar pacotes e dependências em ambientes de desenvolvimento, sem a necessidade de virtualização completa. Conda, por exemplo, gerencia pacotes, dependências e ambientes virtuais para linguagens como Python e R, permitindo criar ambientes isolados com versões específicas de pacotes e dependências. Já o [renv](#) é específico para projetos R, criando um ambiente de desenvolvimento reproduzível ao nível de pacotes.

Essas ferramentas oferecem a vantagem de menor sobrecarga de recursos e são fáceis de configurar e utilizar, promovendo a reprodutibilidade de ambientes de desenvolvimento

para linguagens específicas. No entanto, oferecem menor isolamento comparado às VMs e containers e dependem da compatibilidade do sistema operacional e das versões dos pacotes. Por exemplo, o pacote `renv` (Wiebels & Moreau, 2021) gerencia dependências em R armazenando o código-fonte de todos os pacotes R usados em um projeto. No entanto, essa abordagem não lida com dependências do sistema ou dependências de outras linguagens de programação e pacotes de software.

7.4 Combinando Soluções: `renv` + Docker

A recomendação para os pesquisadores que desejem ter seus trabalhos transparentes e reprodutíveis é que eles entendam das duas últimas soluções: containers + `renv` no ambiente R. Na verdade, essas duas soluções devem caminhar juntas, pois no contexto da maioria dos workflows (pipelines) de pesquisa a construção de containers é facilitada pela aplicação correta dos pacotes de controle de ambiente (Conda, `renv`, etc.) (Moreau et al., 2023; Rodrigues, 2023).

O gerenciamento de dependências mitiga o problema da incompatibilidade, mas a contêinerização o resolve completamente (Wiebels & Moreau, 2021; Zandonella Callegher & Massidda, 2022). O controle de ambiente vai além ao criar ambientes computacionais completamente isolados que encapsulam não apenas os pacotes, mas também o sistema operacional e todas as suas configurações. O [Rocker Project](#) fornece imagens Docker prontas e otimizadas para usuários de R. Ao empacotar todo o ambiente de análise, o Docker garante que ele possa ser fielmente recriado por qualquer pessoa, em qualquer lugar, a qualquer momento, superando as limitações de soluções como o pacote `renv` do R.

7.4.1 O Pacote `renv`

O `renv` trabalha criando uma biblioteca de pacotes privada e específica do projeto (Rodrigues, 2023; Zandonella Callegher & Massidda, 2022). Quando você inicializa o `renv` em um projeto, ele cria um arquivo `renv.lock` que registra as versões exatas de todos os pacotes utilizados. Isso permite que outros pesquisadores, ou você mesmo no futuro, restaurem exatamente o mesmo ambiente de pacotes, garantindo que o código execute da mesma forma.

Principais funcionalidades do `renv`:

- **Isolamento:** Cada projeto tem sua própria biblioteca de pacotes, evitando conflitos entre projetos diferentes
- **Reprodutibilidade:** O arquivo `renv.lock` documenta todas as versões de pacotes utilizadas
- **Portabilidade:** Outros pesquisadores podem restaurar o ambiente exato usando `renv::restore()`
- **Eficiência:** Utiliza um cache global de pacotes, evitando downloads duplicados

Embora o `renv` registre a versão do R utilizada no projeto, ele não gerencia automaticamente a instalação dessa versão específica (Rodrigues, 2023). Além disso, fatores como sistema operacional, bibliotecas do sistema e compiladores podem afetar a reprodutibilidade dos resultados. É aqui que a combinação com Docker se torna essencial para garantir reprodutibilidade completa.

7.4.2 Docker Desktop para Pesquisadores

O Docker Desktop oferece uma interface gráfica (GUI) amigável para gerenciar containers, tornando-o ideal para pesquisadores com baixa literacia computacional. Através da GUI, é possível:

- Visualizar e gerenciar containers em execução
- Iniciar e parar containers com um clique
- Acessar logs e informações de containers
- Gerenciar imagens Docker
- Configurar recursos (CPU, memória) alocados para containers

Para pesquisadores em ciências sociais aplicadas, o Docker Desktop remove a necessidade de memorizar comandos complexos de linha de comando, permitindo focar no trabalho científico. A possibilidade de executar o RStudio dentro de um container através do navegador web oferece uma experiência familiar, mas com todas as garantias de reprodutibilidade que a contêinerização proporciona (Zandonella Callegher & Massidda, 2022).

7.5 Soluções em Nuvem

No entanto, a computação em nuvem também nos agraciou com outras soluções que facilitam a reprodutibilidade, transparência e colaboração em pesquisas empíricas. Plataformas de notebooks na nuvem como [Google Colab](#) e [Posit Cloud](#) (anteriormente conhecido como RStudio Cloud) permitem compartilhar notebooks rodando num mesmo hardware, mas os usuários precisam garantir que as dependências e versões de pacotes sejam corretamente especificadas e gerenciadas (Moreau et al., 2023).

No [JupyterHub](#) temos proposta parecida, mas ele nos dá um controle melhor sobre o ambiente, já que um administrador pode configurar e manter as dependências necessárias de um projeto colaborativo. O [Binder](#) é uma plataforma open-source que transforma repositórios Git em ambientes executáveis, focando principalmente em notebooks Jupyter. Ele facilita a execução de notebooks a partir de repositórios Git e garante que as dependências especificadas no repositório sejam instaladas, mas depende da configuração correta dos arquivos de dependências.

O [Code Ocean](#) e [Nextjournal](#) são soluções específicas para a reprodutibilidade de pesquisas científicas, focando na facilidade de uso e na acessibilidade para a comunidade acadêmica (Moreau et al., 2023). O Code Ocean permite que os cientistas agrupem código, dados, resultados, metadados e um ambiente computacional em um único lugar, chamado de “cápsula”, cujos resultados podem ser reproduzidos por qualquer pessoa num simples botão. O Nextjournal é uma plataforma de colaboração e publicação de notebooks interativos, que permite a execução de código em diferentes linguagens, como o Code Ocean, e a criação de artigos científicos interativos. Essas duas soluções oferecem um ambiente integrado, com interface gráfica intuitiva para configurar ambientes de desenvolvimento e execução, o que facilita para pesquisadores sem conhecimento técnico avançado. No entanto, são soluções comerciais e podem ter limitações em termos de recursos e personalização.

As soluções apresentadas sobrepostas à nuvem do lado direito na Figura 7.1 podem ser consideradas soluções intermediárias aos containers tradicionais, no sentido de que elas utilizam contêinerização para criar ambientes reprodutíveis, mas abstraem a complexidade

técnica e fornecem interfaces mais amigáveis e específicas para a comunidade científica (Wiebels & Moreau, 2021). Elas são ideais para pesquisadores que buscam simplicidade e reprodutibilidade sem a necessidade de se aprofundar nos detalhes técnicos dos containers. Essas plataformas tornam a poderosa tecnologia de containerização acessível e aplicável ao contexto da pesquisa científica.

Podemos dizer que em termos de níveis de reprodutibilidade, Google Colab e Posit Cloud atendem a um nível básico, porque a reprodutibilidade pode ser limitada pela variabilidade das dependências das sessões e cabe ao usuário uma configuração cuidadosa dos pacotes e versões. Binder e JupyterHub fornecem um nível intermediário de reprodutibilidade, pois apesar de um melhor controle sobre o ambiente, requer configuração e manutenção adequadas das dependências. Por fim, Code Ocean e Nextjournal oferecem um alto nível de reprodutibilidade, pois são ambientes integrados para criar, executar e compartilhar projetos de pesquisa reprodutíveis (Moreau et al., 2023).

7.6 ARTE: Implementando Reprodutibilidade Completa

O template ARTE (*Article Reproducibility Template Environment*), disponível em <https://github.com/phdpablo/article-template>, operacionaliza os princípios de CA utilizando as tecnologias apresentadas neste módulo (Limongi & Rogers, 2025a, 2025b; Rogers & Limongi, 2025). O ARTE é uma concepção metodológica desenvolvida para ser um ecossistema que integra ferramentas dedicadas, padrões da comunidade e atende aos cinco pilares da reprodutibilidade computacional.

Na base do template está a adoção do [protocolo TIER](#), um padrão da comunidade para organização de projetos de pesquisa. O ARTE foi projetado para acomodar um espectro de práticas de reprodutibilidade (Rogers & Limongi, 2025). A reprodutibilidade mínima (TIER Protocol 4.0 + OSF) foi apresentada no [módulo 4](#). A reprodutibilidade adequada (+ Git/Gitub + RStudio + Quarto + `renv`) foi abordada nos [módulos 5 e 6](#). Nesse módulo discutiremos a proposta de reprodutibilidade completa (+ Docker) do ARTE.

O padrão ouro da reprodutibilidade utiliza tecnologia de containerização, como Docker, para encapsular todo o ambiente computacional (sistema operacional, versões de software e todas as dependências). Isso garante que a análise execute da mesma forma em qualquer máquina, a qualquer momento (Rogers & Limongi, 2025). A adoção dessa opção garante reprodutibilidade computacional completa.

O ARTE facilita a implementação desse nível mais alto de reprodutibilidade através de scripts `start.bat` e `stop.bat` (no Windows) ou `start.sh` e `stop.sh` (no Linux/Mac) que automatizam o processo de criação e execução do container. Esses scripts utilizam o `Dockerfile` e `docker-compose.yml` incluídos no template, que definem o ambiente computacional completo necessário para o projeto.

7.7 Preparação para a Aula

! Pré-requisitos

Antes da aula síncrona, certifique-se de completar **todos** os passos abaixo. Vídeos com instruções detalhadas estão disponíveis na [página de pré-trabalho do curso](#).

Checklist de Preparação:

1. ☒ Instalar e configurar o [Git](#) no seu computador
2. ☒ Criar conta no [GitHub](#) e configurar credenciais no RStudio
3. ☒ Verificar instalação do [RStudio](#)
4. ☒ Instalar o [Docker Desktop](#) e verificar que está executando corretamente
5. ☒ Familiarizar-se com a interface do Docker Desktop (Opcional)
6. ☒ Explorar o repositório do [ARTE](#) e sua [documentação](#) (Opcional)

Nota importante: A instalação do Docker Desktop pode levar algum tempo e, em alguns sistemas Windows, pode requerer habilitação de recursos de virtualização no BIOS. Certifique-se de realizar essas configurações com antecedência.

Capítulo 8

IA Aplicada à Pesquisa Reprodutível

8.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender o papel da inteligência artificial no contexto da ciência aberta e pesquisa reprodutível
- Identificar aplicações práticas da IA em diferentes etapas do processo de pesquisa
- Avaliar criticamente os desafios de transparência, reprodutibilidade e viés algorítmico no uso de IA
- Propor adaptações dos princípios FAIR para integração com ferramentas de IA
- Implementar declarações transparentes do uso de IA em projetos de pesquisa
- Distinguir entre níveis básico, intermediário e avançado de integração entre IA e ciência aberta

8.2 Contextualização

A integração entre IA e CA está gerando discussões crescentes em editoras científicas e universidades, sendo fundamental para a criação de uma cultura de pesquisa transparente e reprodutível. A discussão sobre CA representa uma mudança cultural necessária.

A crise de reprodutibilidade afeta diversas áreas científicas de forma independente, com periódicos tendo dificuldades crescentes em garantir que pesquisas publicadas possam ser replicadas por outros pesquisadores. Um problema significativo é a dificuldade de encontrar bases de dados organizadas em artigos publicados nos principais periódicos, o que compromete tanto o ensino quanto a formação de novos pesquisadores.

As cinco principais editoras científicas (Wiley, Taylor & Francis, entre outras) controlam 50% da produção científica mundial, criando um ciclo vicioso que dificulta o avanço da

CA. O governo brasileiro recentemente aumentou contratos com editoras para pagar taxas de APC (*Article Processing Charges*) aos autores, o que aumentou o faturamento das editoras sem necessariamente beneficiar o desenvolvimento da CA.

Este cenário levanta questões fundamentais sobre equidade de acesso e sustentabilidade do modelo atual de publicação científica, especialmente quando combinado com o uso crescente de ferramentas de IA que também apresentam custos significativos.

8.3 Aplicações Práticas da IA na Pesquisa

8.3.1 Documentação e Organização

A IA demonstra grande eficácia no trabalho com documentação, frequentemente um gargalo significativo para pesquisadores. É possível utilizar ferramentas de IA para documentar trabalhos já realizados, criando pastas, codebooks de variáveis e estruturas organizacionais, mantendo-se dentro dos direitos autorais do pesquisador.

Essa aplicação representa uma perspectiva de treinamento, permitindo que pesquisadores aprendam execuções de processos ao solicitar que a IA gere documentação a partir de sites ou materiais existentes. O uso de IA para documentação é considerado eticamente aceitável, pois a ferramenta está trabalhando dentro do conteúdo e dos direitos autorais do próprio pesquisador.

8.3.2 Geração e Otimização de Código

A IA pode auxiliar significativamente na perspectiva de códigos, especialmente para pesquisadores com dificuldades em programação. Algumas revistas permitem que pesquisadores utilizem plataformas como [Google Colab](#), inserindo códigos e utilizando ferramentas como Gemini para executar processos completos, facilitando o compartilhamento de código.

Essa capacidade de gerar código automaticamente pode ser crucial para garantir que outros pesquisadores consigam replicar análises, mesmo sem conhecimento profundo de programação. A geração de código por IA permite que mais pesquisadores participem de práticas de CA, democratizando o acesso às metodologias quantitativas.

8.3.3 Tradução de Textos Científicos

A tradução representa uma aplicação considerada totalmente aceitável no uso de IA para pesquisa científica. Por exemplo, os instrutores desse curso costumam adotar o seguinte fluxo de trabalho: primeiro utiliza o [Google Tradutor](#), seguido por refinamento com IA para ajustar a linguagem conforme a área específica, e finalmente revisão parágrafo por parágrafo utilizando ferramentas como [Grammarly](#) ou [quillboot](#).

Alternativas incluem ferramentas como [PaperPal](#), desenvolvida por editoras. Editores de revistas de alto impacto consideram bem aceitável usar IA para tradução, especialmente para falantes não nativos como mecanismo de coesão textual, desde que monitorada pelos autores.

8.4 Transparência e Questões Éticas

8.4.1 Declaração de Uso

Embora a IA juridicamente não possa ser coautora de trabalhos científicos, a questão da transparência sobre seu uso permanece central. Uma proposta é utilizar os “credit roles” (papéis de crédito) já existentes em submissões de artigos para declarar de forma transparente onde e como a IA foi utilizada no processo de pesquisa.

Documentar o uso de IA na seção de métodos deve especificar como e quando a ferramenta foi utilizada. Registrar versões, prompts e outputs de forma similar ao que se faz com bases de dados e códigos de análise. Sempre que possível, utilizar ferramentas abertas, dependendo da viabilidade orçamentária.

8.4.2 Desafios das Plataformas *Point-and-Click*

As principais plataformas de IA no ambiente de pesquisa científica são basicamente “*point and click*”, executando processos sem oferecer total confiabilidade sobre a execução, o que pode se tornar um dilema ético e metodológico.

Quanto mais se utiliza plataformas que apenas executam comandos sem mostrar o processo, mais se terceiriza o conhecimento científico. Isso cria uma barreira significativa para a CA, pois grande parte da IA usada para pesquisa científica são aquelas em que não há acesso ao algoritmo subjacente.

8.4.3 Modelos Abertos versus Proprietários

Existem discussões crescentes sobre o uso de modelos abertos versus proprietários. A integração com IA levanta questões sobre acessibilidade e equidade. Plataformas como [Semantic Scholar](#) oferecem APIs abertas para conectar bases de dados diretamente, com tokens acessíveis, permitindo formatar prompts e compartilhar na rede de forma controlada.

Modelos proprietários podem ampliar ou reduzir a equidade de acesso. Quando se usa IA gratuita, na verdade está-se ajudando a treinar o modelo para que usuários pagos depois utilizem versões mais validadas. A discussão central envolve quem tem acesso a ferramentas de IA na ciência, considerando os custos crescentes das plataformas que passaram de assinaturas para pagamento por crédito.

8.5 Proposta de Integração: FAIR + IA

Os princípios FAIR (*Findable, Accessible, Interoperable, Reusable*) são amplamente reconhecidos em CA. Uma proposta emergente sugere adaptar esses princípios para incluir integração com IA.

8.5.1 F - Findable (Encontrável)

A IA pode enriquecer metadados através de *deep research* na internet, encontrando informações com maior velocidade. O desafio é garantir acesso ao output da IA, já que muitas plataformas entregam apenas o resultado final, não o processo. Uma estratégia para acessar o processo é utilizar “cadeia de pensamento” (*chain of thought*) em prompts.

8.5.2 A - Accessible (Acessível)

A questão da acessibilidade envolve repositórios abertos e licenças claras. A integração com IA levanta questões sobre modelos abertos versus proprietários, com implicações diretas para quem tem acesso a ferramentas de IA na ciência.

8.5.3 I - Interoperable (Interoperável)

A interoperabilidade requer padrões de dados e vocabulário controlado. APIs abertas facilitam a integração, mas surge a questão: como garantir reprodutibilidade com diferentes IAs, considerando que cada IA tem algoritmo e treinamento próprios?

8.5.4 R - Reusable (Reutilizável)

A documentação através de logs de uso e versionamento de prompts (etapa um, dois, três) é fundamental, embora seja difícil reutilizar prompts de forma exata. Quando um modelo é atualizado (exemplo: do GPT 5.1 para 5.2), nunca se chega ao mesmo resultado, exigindo estudo de nova teoria e novos prompts.

8.6 Níveis de Integração com Ciência Aberta

A integração entre IA e ciência aberta pode ser concebida em três níveis de maturidade crescente:

8.6.1 Nível Básico

Trabalho disponível em CA com declaração de uso de IA para documentação e código. Especificação das etapas onde IA foi utilizada, com políticas mínimas de controle estabelecidas.

Neste nível, o foco está em transparência básica sobre onde e como a IA foi empregada no processo de pesquisa.

8.6.2 Nível Intermediário

Disponibilização de dados e código com versionamentos ou prompts tecnicamente documentados. Ações concretas incluem treinamento de pesquisadores com experiência de outros usuários das plataformas de IA.

Este nível envolve não apenas declaração, mas documentação técnica completa que permita rastreamento do processo.

8.6.3 Nível Avançado

Pré-registro e *peer review* aberto integrados com modelo aberto e pipeline reproduzível. Requer infraestrutura adequada (computador e organização). A referência seria uma ciência integrada à comunidade, com IA como colaboradora mostrando todas as etapas.

Algoritmos como o [AI Scientist](#) demonstram que todo o fluxo de geração de pesquisa deve ter supervisão humana, com IA entrando como colaboradora e sempre havendo quem está fazendo e avaliando a pesquisa de maneira integrada.

8.7 Boas Práticas e Recomendações

8.7.1 Para Uso Ético

As principais recomendações para uso ético de IA em pesquisa incluem:

- Documentar o uso de IA na seção de métodos, especificando como e quando foi utilizada
- Registrar versões, prompts e outputs, similar ao que se faz com bases de dados e códigos de análise
- Sempre que possível, utilizar ferramentas abertas, dependendo da viabilidade orçamentária
- Ser transparente sobre as limitações e incertezas associadas ao uso de IA

8.7.2 Para Ensino

No contexto educacional, recomenda-se que estudantes compartilhem prompts para entender como chegaram aos resultados, aplicando a mesma perspectiva de IA generativa à CA. Plataformas como [ChatGPT](#) e [Gemini](#) oferecem modos de aprendizado e estudo específicos, representando um dos principais caminhos para trabalhar com o próprio aprendizado.

É importante estabelecer diretrizes claras sobre o que pode ou não ser feito com IA em trabalhos acadêmicos, promovendo uso responsável ao invés de proibição. A transparência por parte de educadores sobre seu próprio uso de IA também é fundamental para criar um ambiente de confiança e aprendizado.

8.8 Aplicações da IA neste Curso

Este curso adota o uso de **Inteligência Artificial Generativa (IA)**  como ferramenta de apoio metodológico e pedagógico, alinhado às diretrizes éticas e responsáveis propostas por Sampaio et al. (2024). A IA é utilizada exclusivamente em funções complementares, que ampliam a eficiência do trabalho científico e a acessibilidade dos conteúdos, **sem substituir o trabalho intelectual, crítico e autoral dos pesquisadores**.

Consideramos que o uso da IA generativa na pesquisa científica representa um **caminho sem volta**. Por isso, o ensino de CA e reprodutibilidade deve incorporar essa realidade — tanto no processo de **produção do conhecimento**, quanto na **transmissão e avaliação** do aprendizado. Ignorar essa transformação tecnológica seria negligenciar o potencial de inovação, transparência e inclusão que ela oferece para a prática da CA.

Seguindo os princípios de **preservação da agência humana, transparência e uso eticamente orientado** preconizados por Sampaio et al. (2024), a IA tem sido empregada nas seguintes funções ao longo do desenvolvimento e execução deste curso:

1.  **Resumo de materiais didáticos:** Síntese de artigos científicos, documentações técnicas e materiais extensos para facilitar a compreensão inicial e identificação de pontos-chave, sempre com revisão e contextualização humana.
2.  **Auxílio na codificação:** Suporte para escrita, depuração e otimização de códigos em R, Python e outras linguagens, acelerando o desenvolvimento de exemplos práticos e soluções técnicas.

3. ☞ **Reflexão e estruturação de conteúdos:** Apoio na concepção de roteiros didáticos, organização lógica de tópicos e desenvolvimento de sequências de aprendizagem mais coerentes.
4. 🔍 **Busca e seleção de literatura:** Identificação preliminar de referências relevantes, mapeamento de debates atuais e descoberta de fontes complementares, sempre com curadoria humana final.
5. 🎨 **Elaboração de imagens e vídeos:** Criação de elementos visuais e recursos multimídia para enriquecer a experiência de aprendizado e tornar conceitos complexos mais acessíveis. Nessa função utilizamos “com força”, pois temos zero habilidade artística ou sensibilidade estética 😊.
6. ☑ **Revisão de conteúdo:** Suporte na revisão gramatical, clareza textual e coerência argumentativa dos materiais didáticos, mantendo a autoria e decisão final humanas.
7. 🌐 **Tradução de literatura:** Tradução preliminar de materiais em idiomas estrangeiros para ampliar o acesso a recursos internacionais, com revisão técnica posterior.
8. 🎓 **Ensino preliminar de tópicos:** Exploração inicial de áreas fora da zona de conhecimento consolidado dos instrutores, servindo como ponto de partida para aprofundamento posterior com fontes especializadas.

8.8.1 Princípios Norteadores

Conforme Sampaio et al. (2024), a IA deve ser utilizada como **apoio à expressão humana** — e não como substituto da reflexão, da análise crítica ou da autoria. É essa perspectiva que orienta todas as aplicações tecnológicas neste curso. Os autores destacam que a **supervisão humana contínua** é essencial para evitar que a IA incorpore erros, vieses ou problemas de integridade acadêmica.

Ademais, seguimos os princípios práticos estabelecidos no guia:

- ✨ **Transparência:** Documentar quando e como a IA foi utilizada na produção de materiais
- 🛡 **Integridade acadêmica:** Garantir originalidade, evitar plágio e preservar direitos autorais
- 👤 **Agência humana:** Manter o pesquisador/instrutor como responsável final por todas as decisões
- 🧠 **Letramento em IA:** Desenvolver compreensão crítica sobre limitações e potencialidades das ferramentas
- 📌 **Uso complementar:** Empregar a IA como ferramenta auxiliar, nunca como substituta do trabalho científico

8.8.2 Contexto da Ciência Aberta

O uso transparente e documentado de ferramentas de IA pode alinhar-se perfeitamente com os princípios da **CA** 🏠: **transparência**, **reprodutibilidade** e **compartilhamento** de processos e recursos. Ao adotar IA de forma ética e responsável, contribuímos para uma cultura científica mais eficiente, inclusiva e, sobretudo, **transparente sobre seus métodos e ferramentas**.

Nenhum conteúdo deve ser gerado de forma integral ou automatizada sem supervisão docente. Todo material deve passar por processo de curadoria, validação e contextualização humana, respeitando os princípios de autoria, originalidade e responsabilidade acadêmica (Sampaio et al., 2024).

8.9 Um Exemplo Prático: A Elaboração dessa Página

Este módulo representa um exemplo concreto de integração entre IA e CA no processo de produção de material educacional. O texto que está sendo lido foi elaborado a partir da transcrição da [aula síncrona do módulo](#), seguindo um fluxo de trabalho que ilustra os conceitos discutidos ao longo deste módulo.

8.9.1 Fluxo de Trabalho Utilizado

Etapa 1 - Obtenção da Transcrição: A aula síncrona foi gravada, a transcrição automática foi obtida via YouTube, copiada para documento Word e posteriormente convertida para PDF.

Etapa 2 - Processamento com IA: A transcrição em PDF foi fornecida a uma ferramenta de IA conversacional (Perplexity AI) com o seguinte prompt inicial:

“Crie um resumo detalhado e objetivo da transcrição em anexo sobre IA em Pesquisas Reprodutíveis. Extraia apenas o conteúdo científico e pedagógico, excluindo identificação de falantes e interações entre participantes. Organize por seções temáticas.”

Etapa 3 - Estruturação do Conteúdo: Após o resumo inicial, foi solicitado à IA que estruturasse o conteúdo seguindo o padrão dos módulos anteriores do curso, com as seções: Objetivos de Aprendizagem, Contextualização e Preparação para a Aula.

Etapa 4 - Refinamento Iterativo: O processo envolveu múltiplas iterações de refinamento, com prompts específicos para: - Remover marcas de oralidade e referências temporais - Eliminar menções aos palestrantes e participantes - Tornar o texto impessoal e acadêmico - Ajustar o conteúdo para focar exclusivamente no que foi discutido na transcrição

Etapa 5 - Supervisão Humana: Todo o processo foi supervisionado por humano, com revisão crítica de cada versão gerada, correção de imprecisões, adequação ao contexto do curso e validação do conteúdo final.

8.9.2 Transparência e Documentação

Este exemplo demonstra os princípios discutidos no módulo:

- **Declaração de uso:** IA foi utilizada para extração, organização e formatação do conteúdo
- **Versionamento:** múltiplas iterações foram necessárias, cada uma com prompt específico
- **Supervisão humana:** decisões sobre estrutura, ênfase e adequação pedagógica permaneceram sob controle humano
- **Limitações reconhecidas:** a IA não criou conhecimento novo, apenas reorganizou conteúdo existente

- **Documentação do processo:** este relato permite que outros compreendam como o material foi produzido

8.9.3 Reflexões sobre o Processo

Este caso ilustra como IA pode ser ferramenta valiosa para documentação e organização de conhecimento, especialmente quando:

1. Há conteúdo rico mas não estruturado (transcrição de aula)
2. Necessita-se transformar oralidade em texto acadêmico
3. Deve-se manter fidelidade ao conteúdo original enquanto se adequa a formato específico
4. A supervisão humana garante qualidade, precisão e adequação pedagógica

Também evidencia limitações: a IA não pode capturar nuances, exemplos visuais mostrados na aula, ou contextos implícitos. A transcrição automática pode conter erros que se propagam no processo. E, fundamentalmente, a qualidade final depende da qualidade da supervisão humana e dos prompts fornecidos.

8.10 Preparação para a Aula

! Pré-requisitos (Opcional)

Para uma compreensão mais profunda sobre o uso ético da IA no contexto acadêmico e científico, recomenda-se a leitura de Sampaio et al. (2024), que discute fundamentos importantes para o tema abordado neste módulo.

Referências

- Abreu, R. de A. dos S. (2022). Ciência Aberta e Periódicos Científicos: desafios do novo modelo de comunicar a ciência. *Revista Fitos*, 16(1), 6–8. <https://doi.org/10.32712/2446-4775.2022.1445>
- Albagli, S., & Maciel, M. L. (2004). Informação e conhecimento na inovação e no desenvolvimento local. *Ciência da Informação*, 33, 9–16. <https://doi.org/10.1590/s0100-19652004000300002>
- Albano, C. S., Pedroso, P. de O., & Caetano, D. O. (2023). Ciência Aberta: Um Panorama Sobre as Publicações No Cenário Brasileiro. *Saber Científico*, 12(1), 1–12.
- Alessandroni, N., & Byers-Heinlein, K. (2022). Ten Strategies to Foster Open Science in Psychology and Beyond. *Collabra: Psychology*, 8(1), 57545. <https://doi.org/10.1525/collabra.57545>
- Alston, J. M., & Rick, J. A. (2021). A Beginner’s Guide to Conducting Reproducible Research. *The Bulletin of the Ecological Society of America*, 102(2), e01801. <https://doi.org/10.1002/bes2.1801>
- Baker, D. H., Berg, M., Hansford, K., Quinn, B. P. A., Segala, F. G., & English, E. (2023). *ReproduceMe: Lessons from a Pilot Project on Computational Reproducibility* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/k8d4u>
- Baker, M. (2016). 1,500 Scientists Lift the Lid on Reproducibility. *Nature*, 533(7604), 452–454. <https://doi.org/10.1038/533452a>
- Bechi, D., & Almeida, M. D. L. P. D. (2024). A Privatização Exógena e os Avanços do Capitalismo Acadêmico no Brasil e na Argentina. *Educação em Revista*, 40, e40036. <https://doi.org/10.1590/0102-469840036>
- Behera, P. K., & Jain, S. J. (2023). *Zotero – An Open-Source Reference Management Software: A Practical Manual*. OSF. <https://doi.org/10.17605/OSF.IO/8S73R>
- Bernard, C. (2023). Stop Reproducing the Reproducibility Crisis. *Eneuro*, 10(2), ENEURO.0032–23.2023. <https://doi.org/10.1523/ENEURO.0032-23.2023>
- Bezjak, S., Clyburne-Sherin, A., Conzett, P., Fernandes, P., Görögh, E., Helbig, K., Kramer, B., Labastida, I., Niemeyer, K., Psomopoulos, F., Ross-Hellauer, T., Schneider, R., Tennant, J., Verbakel, E., Brinken, H., & Heller, L. (2018). *Open Science Training Handbook*. Zenodo. <https://doi.org/10.5281/ZENODO.1212496>
- Braga, P. H. P., Hébert, K., Hudgins, E. J., Scott, E. R., Edwards, B. P. M., Sánchez Reyes, L. L., Grainger, M. J., Foroughirad, V., Hillemann, F., Binley, A. D., Brookson, C. B., Gaynor, K. M., Shafiei Sabet, S., Güncan, A., Weierbach, H., Gomes, D. G. E., & Crystal-Ornelas, R. (2023). Not just for programmers: How GitHub can accelerate collaborative and reproducible research in ecology and evolution. *Methods in Ecology and Evolution*, 14(6), 1364–1380. <https://doi.org/10.1111/2041-210X.14108>
- Broman, K. W., & Woo, K. H. (2018). Data Organization in Spreadsheets. *The American*

- Statistician*, 72(1), 2–10. <https://doi.org/10.1080/00031305.2017.1375989>
- Bryan, J. (2018). Excuse Me, Do You Have a Moment to Talk About Version Control? *The American Statistician*, 72(1), 20–27. <https://doi.org/10.1080/00031305.2017.1399928>
- Caballero-Rivero, A., Sánchez-Tarragó, N., & Santos, R. N. M. dos. (2019). Práticas de Ciência Aberta da comunidade acadêmica brasileira: estudo a partir da produção científica. *Transinformação*, 31, e190029. <https://doi.org/10.1590/2318-0889201931e190029>
- Chopik, W. J., Bremner, R. H., Defever, A. M., & Keller, V. N. (2018). How (and Whether) to Teach Undergraduates About the Replication Crisis in Psychological Science. *Teaching of Psychology*, 45(2), 158–163. <https://doi.org/10.1177/0098628318762900>
- Clyburne-Sherin, A., Fei, X., & Green, S. A. (2019). Computational Reproducibility via Containers in Psychology. *Meta-Psychology*, 3. <https://doi.org/10.15626/MP.2018.892>
- Committee on Reproducibility and Replicability in Science, Board on Behavioral, Cognitive, and Sensory Sciences, Committee on National Statistics, Division of Behavioral and Social Sciences and Education, Nuclear and Radiation Studies Board, Division on Earth and Life Studies, Board on Mathematical Sciences and Analytics, Committee on Applied and Theoretical Statistics, Division on Engineering and Physical Sciences, Board on Research Data and Information, Committee on Science, Engineering, Medicine, and Public Policy, Policy and Global Affairs, & National Academies of Sciences, Engineering, and Medicine. (2019). *Reproducibility and Replicability in Science* (p. 25303). National Academies Press. <https://doi.org/10.17226/25303>
- Crüwell, S., Van Doorn, J., Etz, A., Makel, M. C., Moshontz, H., Niebaum, J. C., Orben, A., Parsons, S., & Schulte-Mecklenbeck, M. (2019). Seven Easy Steps to Open Science: An Annotated Reading List. *Zeitschrift für Psychologie*, 227(4), 237–248. <https://doi.org/10.1027/2151-2604/a000387>
- Dogucu, M., & Çetinkaya-Rundel, M. (2022). Tools and Recommendations for Reproducible Teaching. *Journal of Statistics and Data Science Education*, 30(3), 251–260. <https://doi.org/10.1080/26939169.2022.2138645>
- Domingos, A., & Batista, I. R. (2021). A map for transparency and replicability in empirical social science: the TIER Protocol. *Revista Política Hoje*, 30(1), 40–86. <https://doi.org/10.51359/1808-8708.2021.245776>
- European Commission. Directorate General for Research and Innovation. (2017). *Providing Researchers with the Skills and Competencies They Need to Practise Open Science*. Publications Office. <https://data.europa.eu/doi/10.2777/121253>
- Fanelli, D. (2018). Is Science Really Facing a Reproducibility Crisis, and Do We Need It To? *Proceedings of the National Academy of Sciences*, 115(11), 2628–2631. <https://doi.org/10.1073/pnas.1708272114>
- Freedman, L. P., Cockburn, I. M., & Simcoe, T. S. (2015). The Economics of Reproducibility in Preclinical Research. *PLOS Biology*, 13(6), e1002165. <https://doi.org/10.1371/journal.pbio.1002165>
- Gilroy, S. P., & Kaplan, B. A. (2019). Furthering Open Science in Behavior Analysis: An Introduction and Tutorial for Using GitHub in Research. *Perspectives on Behavior Science*, 42(3), 565–581. <https://doi.org/10.1007/s40614-019-00202-5>
- Guimarães Furtado, R., & Evangelista Cunha, S. (2024). Inteligência artificial, data centers e colonialismo digital: Impactos socioambientais e geopolíticos a partir do Sul Global. *Liinc em Revista*, 20(2). <https://doi.org/10.18617/liinc.v20i2.7272>

- Heinz, M., & Miranda, M. (2024). Ciência Aberta: Argumentos e Desafios Para Sua Legitimação Científica. *Em Questão*, 30. <https://doi.org/10.1590/1808-5245.30.135618>
- Hertz, M. I., & McNeill, A. S. (2024). Eleven quick tips for properly handling tabular data. *PLOS Computational Biology*, 20(11), e1012604. <https://doi.org/10.1371/journal.pcbi.1012604>
- Janz, N. (2015). Bringing the Gold Standard into the Classroom: Replication in University Teaching. *International Studies Perspectives*, n/a–n/a. <https://doi.org/10.1111/insp.12104>
- Kathawalla, U.-K., Silverstein, P., & Syed, M. (2021). Easing Into Open Science: A Guide for Graduate Students and Their Advisors. *Collabra: Psychology*, 7(1), 18684. <https://doi.org/10.1525/collabra.18684>
- Klein, O., Hardwicke, T. E., Aust, F., Breuer, J., Danielsson, H., Mohr, A. H., IJzerman, H., Nilsson, G., Vanpaemel, W., & Frank, M. C. (2018). A Practical Guide for Transparency in Psychological Science. *Collabra: Psychology*, 4(1), 20. <https://doi.org/10.1525/collabra.158>
- Kronbauer, J., & Oliveira, R. S. de. (2024). Tecnologias de reconhecimento facial e colonialismo de dados no Brasil. *Revista Jurídica Cesumar - Mestrado*, 24(2), 387–398. <https://doi.org/10.17765/2176-9184.2024v24n2.e12166>
- Li, L., Parulian, N., & Ludäscher, B. (2021). Automatic Module Detection in Data Cleaning Workflows: Enabling Transparency and Recipe Reuse. *International Journal of Digital Curation*, 16(1), 11–11. <https://doi.org/10.2218/ijdc.v16i1.771>
- Limongi, R., & Rogers, P. (2025a). Open Science in Three Acts: Foundations, Practice, and Implementation - First Act. *BAR - Brazilian Administration Review*, 22(1), e250079. <https://doi.org/10.1590/1807-7692bar2025250079>
- Limongi, R., & Rogers, P. (2025b). Open Science in Three Acts: Foundations, Practice, and Implementation - Second Act. *BAR - Brazilian Administration Review*, 22(2), e250116. <https://doi.org/10.1590/1807-7692bar2025250116>
- McAleer, P., Stack, N., Woods, H., DeBruine, L. M., Paterson, H., Nordmann, E., Kuepper-Tetzl, C. E., & Barr, D. J. (2022). *Embedding Data Skills in Research Methods Education: Preparing Students for Reproducible Research* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/hq68s>
- Mendes-Da-Silva, W. (2023). What Lectures and Research in Business Management Need to Know About Open Science. *Revista de Administração de Empresas*, 63(4), e0000–0033. <https://doi.org/10.1590/s0034-759020230408x>
- Moreau, D., Wiebels, K., & Boettiger, C. (2023). Containers for Computational Reproducibility. *Nature Reviews Methods Primers*, 3(1), 50. <https://doi.org/10.1038/s43586-023-00236-9>
- Munafò, M. R., Nosek, B. A., Bishop, D. V. M., Button, K. S., Chambers, C. D., Percie Du Sert, N., Simonsohn, U., Wagenmakers, E.-J., Ware, J. J., & Ioannidis, J. P. A. (2017). A Manifesto for Reproducible Science. *Nature Human Behaviour*, 1(1), 0021. <https://doi.org/10.1038/s41562-016-0021>
- Neto, S. C., Willinsky, J., & Alperin, J. P. (2016). Measuring, Rating, Supporting, and Strengthening Open Access Scholarly Publishing in Brazil. *Education Policy Analysis Archives*, 24, 54–54. <https://doi.org/10.14507/epaa.24.2391>
- Neubert, P. D. S., & Rodrigues, R. S. (2021). Oligopólios e publicação científica: a busca por impacto na América Latina. *Transinformação*, 33, e200069. <https://doi.org/10.1590/2318-0889202133e200069>
- Oddone, N., & Souza, L. V. R. L. (2024). Acesso ao conhecimento no contexto da ciência

- aberta: o segredo da popularidade do Sci-Hub. *Revista Digital de Biblioteconomia e Ciência da Informação*, 22. <https://doi.org/https://doi.org/10.20396/rdbci.v22i00.8673883>
- Olson, E., Pfeiffer, N., Call, M., & Steger, D. (2022). *Getting Started on OSF*. <https://doi.org/10.17605/OSF.IO/YAQE8>
- Proske, A., Wenzel, C., & Queitsch, M. B. (2023). Reference Management Systems. Em O. Kruse, C. Rapp, C. M. Anson, K. Benetos, E. Cotos, A. Devitt, & A. Shibani (Eds.), *Digital Writing Technologies in Higher Education* (pp. 215–230). Springer International Publishing. https://doi.org/10.1007/978-3-031-36033-6_14
- Protzko, J., Krosnick, J., Nelson, L., Nosek, B. A., Axt, J., Berent, M., Buttrick, N., DeBell, M., Ebersole, C. R., Lundmark, S., MacInnis, B., O'Donnell, M., Perfecto, H., Pustejovsky, J. E., Roeder, S. S., Walleczek, J., & Schooler, J. W. (2023). High Replicability of Newly Discovered Social-Behavioural Findings Is Achievable. *Nature Human Behaviour*. <https://doi.org/10.1038/s41562-023-01749-9>
- Pruim, R., Gîrjău, M.-C., & Horton, N. J. (2023). Fostering better coding practices for data scientists. *Harvard Data Science Review*, 5(3). <https://doi.org/10.1162/99608f92.97c9f60f>
- Ram, K. (2013). Git Can Facilitate Greater Reproducibility and Increased Transparency in Science. *Source Code for Biology and Medicine*, 8(7), 8. <https://doi.org/10.1186/1751-0473-8-7>
- Rezende, L. V. R., & Falgueras, E. A. (2020). Estado Da Arte Dos Marcos Regulatórios Brasileiros Rumo à Ciência Aberta. *Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação*, 25, 01–25. <https://doi.org/10.5007/1518-2924.2020.e71370>
- Rodrigues, B. (2023). *Building reproducible analytical pipelines with R*. <https://raps-with-r.dev/>
- Rogers, P., & Limongi, R. (2025). Open Science in Three Acts: Foundations, Practice, and Implementation - Third Act. *BAR - Brazilian Administration Review*, 22(3), e250162. <https://doi.org/10.1590/1807-7692bar2025250162>
- Sampaio, R. C., Sabbatini, M., & Limongi, R. (2024). *Diretrizes para o uso ético e responsável da inteligência artificial generativa: um guia prático para pesquisadores*. Sociedade Brasileira de Estudos Interdisciplinares da Comunicação - Intercom. <https://portcom.intercom.org.br/ebooks/detalheEbook.php?id=57203>
- Scroggie, K., Burrell-Sander, K., Rutledge, P., & Motion, A. (2023). *GitHub as an open electronic laboratory notebook for real-time sharing of knowledge and collaboration*. <https://doi.org/10.1039/D3DD00032J>
- Silva, F. C. C. D., & Silveira, L. D. (2019). O Ecossistema Da Ciência Aberta. *Transformação*, 31, e190001. <https://doi.org/10.1590/2318-0889201931e190001>
- Silveira, L. D., Calixto Ribeiro, N., Melero, R., Mora-Campos, A., Piraquive-Piraquive, D. F., Uribe Tirado, A., Machado Borges Sena, P., Polanco Cortés, J., Santillán-Aldana, J., Couto Corrêa Da Silva, F., Ferreira Araújo, R., Enciso Betancourt, A. M., & Fachin, J. (2023). Taxonomia Da Ciência Aberta: Revisada e Ampliada. *Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação*, 28. <https://doi.org/10.5007/1518-2924.2023.e91712>
- Silveira, L. D., Ribeiro, N. C., Salas, D., Penabad-Camacho, L., Córdoba González, S., Rogel-Salazar, R., Espinoza De Los Monteros, M. A. T., Abedrapo Rosen, I., Polanco-Cortés, J., Ruz Fuenzalida, C., & al., et. (2025). Ameaça velada ao acesso aberto diamante: quando os indicadores se tornam armas de exclusão. *Ciência da Informação Express*, 6, 1–12. <https://doi.org/10.60144/v6i.2025.152>

- Sinãni, M. C. F., & Accorssi, A. (2023). Colonialismo digital e processos de disputas: as mídias como «sistemas educativos» da população. *Liinc em Revista*, 19(2), e6646. <https://doi.org/10.18617/liinc.v19i2.6646>
- Soderberg, C. K. (2018). Using OSF to Share Data: A Step-by-Step Guide. *Advances in Methods and Practices in Psychological Science*, 1(1), 115–120. <https://doi.org/10.1177/2515245918757689>
- Sullivan, I., DeHaven, A., & Mellor, D. (2019). Open and Reproducible Research on Open Science Framework. *Current Protocols Essential Laboratory Techniques*, 18(1), e32. <https://doi.org/10.1002/cpet.32>
- Thomas, P. A. (2023). *Using Zotero for Citation Management: A Step-by-Step Guide to Organizing and Citing Your Research*. University of Kansas Libraries. <https://kuscholarworks.ku.edu/handle/1808/34983>
- Toelch, U., & Ostwald, D. (2018). Digital Open Science—Teaching Digital Tools for Reproducible and Transparent Research. *PLOS Biology*, 16(7), e2006022. <https://doi.org/10.1371/journal.pbio.2006022>
- UNESCO. (2021). *UNESCO Recommendation on Open Science*. UNESCO. <https://doi.org/10.54677/MNMH8546>
- Vicente-Saez, R., & Martinez-Fuentes, C. (2018). Open Science Now: A Systematic Literature Review for an Integrated Definition. *Journal of Business Research*, 88, 428–436. <https://doi.org/10.1016/j.jbusres.2017.12.043>
- Vuorre, M., & Curley, J. P. (2018). Curating Research Assets: A Tutorial on the Git Version Control System. *Advances in Methods and Practices in Psychological Science*, 1(2), 219–236. <https://doi.org/10.1177/2515245918754826>
- Weberpals, J., & Wang, S. V. (2024). The FAIRification of research in real-world evidence: A practical introduction to reproducible analytic workflows using Git and R. *Pharmacoepidemiology and Drug Safety*, 33(1), e5740. <https://doi.org/https://doi.org/10.1002/pds.5740>
- Weidmann, N. B. (2023). *Data Management for Social Scientists: From Files to Databases* (1.^a ed.). Cambridge University Press. <https://doi.org/10.1017/9781108990424>
- Wickham, H. (2014). Tidy Data. *Journal of Statistical Software*, 59, 1–23. <https://doi.org/10.18637/jss.v059.i10>
- Wickham, H., Cetinkaya-Rundel, M., & Grolemund, G. (2023). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media. <https://r4ds.hadley.nz/>
- Wiebels, K., & Moreau, D. (2021). Leveraging Containers for Reproducible Psychological Research. *Advances in Methods and Practices in Psychological Science*, 4(2), 251524592110178. <https://doi.org/10.1177/25152459211017853>
- Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>
- Zandonella Callegher, C., & Massidda, D. (2022). *The open science manual: Make your scientific research accessible and reproducible*. <https://doi.org/10.5281/zenodo.6521850>
- Zaragozí, B. M., Trilles, S., & Navarro-Carrión, J. T. (2020). Leveraging Container Technologies in a GIScience Project: A Perspective from Open Reproducible Research. *ISPRS International Journal of Geo-Information*, 9(3), 138. <https://doi.org/10.3390/ijgi9030138>
- Zarghani, M., Nemati-Anaraki, L., Sedghi, S., Noroozi Chakoli, A., & Rowhani-Farid, A. (2023). The Application of Open Science Potentials in Research Processes: A

Comprehensive Literature Review. *Libri*, 73(2), 167–186. <https://doi.org/10.1515/libri-2022-0007>

