


Artigo à Prova de Futuro: Jornada de Open Science na Prática



Artigo à Prova de Futuro
Jornada de Open Science na Prática

Pablo Rogers
nov, 2025

Índice

 O Curso	1
Instrutores	1
Objetivos	1
Ementa	2
Metodologia	2
Mudanças	3
Citação	4
Licença	4
 Agenda	5
 Pré-requisitos	6
Github	6
Git	6
Zotero	7
OSF	7
Zenodo	7
RStudio	7
Docker	8
Máquinas Virtuais	8
1 Introdução à Ciência Aberta	9
2 Repositórios da Ciência Aberta	16
2.1 Objetivos de Aprendizagem	16
2.2 Contextualização	16
2.3 Pré-registro e Transparência Metodológica	19
2.4 Identificadores Persistentes e Rastreabilidade	20
2.5 OSF no Ecossistema de Ferramentas	20
2.6 Quando Não Usar OSF	21
2.7 Preparação para a Aula	21
3 Gerenciamento de Referências e Bibliotecas	22
3.1 Objetivos de Aprendizagem	22
3.2 Contextualização	22
3.3 O Zotero no Ciclo de Pesquisa	24
3.4 Integração com Fluxos de Trabalho Reprodutíveis	25

3.5	IA e Descoberta de Literatura	25
3.6	Indo Além das Funcionalidades Básicas	25
3.7	Preparação para a Aula	26
4	Organização de Projetos	28
4.1	Objetivos de Aprendizagem	28
4.2	Contextualização	28
4.3	Gerenciamento de Dados	29
4.4	Código e Software	30
4.5	Colaboração	30
4.6	Organização de Projetos	31
4.7	Controle de Mudanças	32
4.8	Redação de Manuscritos	33
4.9	Começando de Onde Você Está	33
4.10	Considerações Finais	35
4.11	Preparação para a Aula	35
5	Controle de versão	37
6	Documentos Reprodutíveis	47
7	Controle de Ambiente	54
8	IA Aplicada à Pesquisa Reprodutível	60
8.1	📋 Aplicações da IA neste Curso	60
	Referências	62

O Curso

Material didático do curso “**Artigo à Prova de Futuro: Jornada de Open Science na Prática**”. Nesse ebook você encontrará um conteúdo programático sobre Ciência Aberta (CA) e Pesquisa Reprodutível, com resumo de textos, recursos didáticos (notas de aulas e vídeos) e sugestões de leitura (artigos e livros).

Instrutores

O curso é coordenado e ministrado por [Pablo Rogers](#), Doutor em Administração pela Universidade de São Paulo (FEA/USP) e professor de finanças e métodos quantitativos desde 2005. Em sua [página de perfil do Github](#) você encontra informações de seus trabalhos recentes, e no seu [site pessoal](#), detalhes sobre suas formações, competências, trajetória e projetos.

O curso tem a parceria do Prof. Ricardo Limongi, Doutor em Administração pela Fundação Getúlio Vargas (FGV-SP), professor de marketing e métodos quantitativos desde 2008 e atual editor chefe da Brazilian Administration Review (BAR). Em seu [perfil do Instagram](#) é possível acompanhar sua agenda de atividades, cursos e palestras sobre Inteligência Artificial (IA) aplicada aos negócios e pesquisa. Em seu [canal do YouTube](#), você encontra vídeos das suas atividades: congressos, palestras, aulas, etc.

Objetivos

O curso tem objetivo de introduzir os conceitos relacionados com a Ciência Aberta (CA) e a Prática da Pesquisa Reprodutível. O curso aborda temas introdutórios sobre CA, com foco no ferramental disponível para tornar a pesquisa mais transparente, reprodutível e acessível.

Ao final pretendemos que os pesquisadores e estudantes de pós-graduação estejam gabaritados para implementar o [ARTE \(Article Reproducibility Template & Environment\)](#), por exemplo, e os professores empenhados em desenvolver um Recurso Didático Aberto (REA), tal como o exemplo dessa disciplina: [Finanças Corporativas de Curto Prazo](#).

O protagonista do curso é o professor e/ou pesquisador brasileiro que deseja aprimorar a qualidade e a transparência de suas aulas e pesquisa, e que busca ferramentas para tornar-lás mais eficiente e acessível.

Trata-se de um curso intermitente programado para acontecer em 8 encontros de 2 horas/aula, totalizando 16 horas/aula. Para alcançar um número maior de interessadosO

o curso é remoto e síncrono. Ele poderá acontecer mais de uma vez no ano, com datas e horários a serem definidos. Para o calendário atual do curso, consulte a seção [Agenda](#).

O curso é gratuito e com de certificado de extensão pela Universidade Federal de Uberlândia (UFU). As inscrições são feitas por meio de um [formulário](#) intermediado pelo projeto [Psico&Econo_METRIA](#). Quando da previsão das datas ou início do curso, uma campanha de e-mail marketing divulgará para os inscritos na [lista de espera](#) e para coordenações de pós-graduações selecionadas.

As vagas são limitadas e a seleção será feita por ordem de inscrição. Após o preenchimento das vagas, os demais interessados serão inscritos automaticamente numa lista de espera e, tempestivamente, serão avisados sobre a próxima edição do curso. Após selecionados, os inscritos receberão um e-mail com instruções para acesso à plataforma de aulas síncronas e para a realização das atividades prévias ao curso.

Ementa

Introdução da Ciência Aberta / Repositórios da Ciência Aberta / Gerenciamento de Referências e Bibliotecas / Gestão de Projetos, Dados e Scripts / Controle de Versão / Documentos Dinâmicos e Reprodutíveis / Controle de Ambiente / IA Aplicada à Pesquisa Reprodutível.

Metodologia

O curso foi concebido para acontecer de forma remota e síncrona, com aulas expositivas, porém em grande medida, o conteúdo é essencialmente prático. As aulas serão gravadas e disponibilizadas no [canal do YouTube do projeto Psico&Econo_METRIA](#) (se inscreva ). O conteúdo principal do curso é síncrono, e pode mudar de edição para edição, no entanto, algumas aulas, principalmente para cadastros e instalações das ferramentas utilizadas, podem ser disponibilizadas de forma assíncrona, tal como na página [Pré-requisitos](#).

A proposta do curso busca seguir de perto a mensagem de Dogucu & Çetinkaya-Rundel (2022) e ser um **Recurso Educacional Aberto (REA)**. Nesse artigo as autoras abordam a importância da reprodutibilidade na ciência de dados, tanto na pesquisa quanto no ensino. Elas recomendam que os professores-pesquisadores adotem fluxos de trabalho reprodutíveis em suas pesquisas e ensinem esses fluxos de trabalho aos seus alunos. Elas propõem uma dimensão para as práticas de reprodutibilidade, focada exclusivamente nas ferramentas para o ensino (todos os materiais de ensino devem ser computacionalmente reprodutíveis, bem documentados e abertos).

O REA aqui proposto é para orientação e contextualização dos participantes do curso sobre cada um dos módulos ministrados. Dessa forma, esperamos que em cada uma das aulas (módulos) os alunos façam uma leitura prévia da página do conteúdo a ser ministrado, para que possam acompanhar melhor as explicações e demonstrações feitas durante as aulas síncronas.

Este curso adota o uso de **Inteligência Artificial Generativa (IA)**  como ferramenta de apoio metodológico e pedagógico, alinhado às diretrizes éticas e responsáveis propostas por Sampaio et al. (2024). A IA é utilizada exclusivamente em funções complementares — como resumo de materiais, auxílio na codificação, estruturação de conteúdos, busca

de literatura, elaboração de recursos visuais, revisão e tradução — **sem substituir o trabalho intelectual, crítico e autoral do pesquisador**. Consideramos que o uso ético e transparente de IA alinha-se perfeitamente com os princípios da **Ciência Aberta** : transparência, reprodutibilidade e compartilhamento de processos. Para conhecer em detalhes as aplicações específicas da IA neste curso e os princípios norteadores dessa prática, consulte a seção final **“Uso de Inteligência Artificial no Curso”**.

Mudanças

As principais mudanças previstas para serem implementadas nesta edição do curso em relação à edição anterior:

- 1 **OSF atualizado** – exploraremos a nova estrutura e layout do repositório.
- 2 **Zotero 7** – avançando em relação à versão 6 trabalhada anteriormente
- 3 **Projeto TIER 4.0** – boas práticas para organização de pastas e arquivos.
- 4 **ARTE – Article Template Reproducibility & Environment** – modelo para artigos reprodutíveis.
- 5 **Containerização com Docker** – foco maior em ambientes portáteis.
- 6 **Inteligência Artificial aplicada à Pesquisa Reprodutível.**
- 7 **Material totalmente reformulado** – atualizado e implementado com recursos didáticos extras.

Citação

Se você utilizar o material desse curso em algum trabalho acadêmico, por favor, cite o livro do curso da seguinte forma:

Rogers, P. (2024). Artigo à Prova de Futuro: Jornada de Open Science na Prática (1.0). Disponível em: <https://phdpablo.github.io/curso-open-science/>.
<https://doi.org/10.5281/zenodo.12593928>

Licença

Artigo à Prova de Futuro: Jornada de Open Science na Prática by Pablo Rogers is licensed under CC BY-NC-SA 4.0

Agenda

Planejamento dos dias  e horários das aulas , conforme a ementa do curso. Na seção de cada uma das aulas temos materiais adicionais para o respectivo conteúdo. Quando disponível, por aqui, poderás acessar os slides utilizados nas aulas , aulas gravadas ou indicações de vídeo  e leituras básica sobre os conteúdos .

Aula/Conteúdo	Data	Material Principal	Instrutor
Introdução à CA	 18/11/25  20:30	  	Ricardo Limongi
Repositórios da CA	 13/11/25  19:00	  	Pablo Rogers
Gerenciamento de Referências	 25/11/25  19:00	  	Pablo Rogers
Gestão de Projetos	 27/11/27  19:00	  	Pablo Rogers
Controle de Versão	 02/12/25  19:00	  	Pablo Rogers
Documentos Dinâmicos	 04/12/25  19:00	  	Pablo Rogers
Controle de Ambiente	 09/12/25  19:00	  	Pablo Rogers
IA para Pesquisas Reprodutíveis	 11/12/25  19:00	  	Ricardo Limongi



Pré-requisitos

O curso não exige conhecimento prévio em programação, mas é recomendável que o aluno tenha familiaridade com o uso de computadores e com a escrita de textos científicos. Nesse sentido, não é necessário ter conhecimento prévio sobre as ferramentas e plataformas que utilizaremos no curso: Zotero, OSF, Zenodo, Git, Github, RStudio, Quarto/RMarkdown, Docker, etc; mas desejável que o aluno já as tenha instalado e/ou cadastro nas plataformas.

Abaixo descrevemos sucintamente o que é cada uma dessas ferramentas e plataformas, e como você pode se preparar para o curso. Também apresentamos um vídeo curto sobre a instalação e/ou cadastro em cada uma delas. A ideia é que você já tenha todas as ferramentas e plataformas instaladas e/ou cadastro antes do início do curso, para que possamos focar no conteúdo e prática durante as aulas síncronas.

Github

Primeiramente, se cadastre no Github: <https://github.com/signup>, pois com ele você poderá acessar o material do curso e interagir com os demais participantes. E com a conta do Github você também poderá se cadastrar em outras plataformas, como o Zenodo, OSF, etc. Algumas features que aprenderemos no curso exigem o vínculo entre as contas. Se for professor ou estudante, você pode solicitar o [GitHub Education](#) e ter acesso, por exemplo, ao Copilot, uma das ferramentas de IA mais interessante. Por isso, é importante que você se cadastre com um e-mail institucional. Use o mesmo e-mail para se cadastrar em todas plataformas.

<https://youtu.be/Nmjh9KsV6eU>

Git

Github não é a mesma coisa que Git. O Github é uma plataforma, e o Git é uma ferramenta. Instale a versão mais recente do Git: <https://git-scm.com/downloads>. O Git é uma ferramenta de controle de versão, e o Github é uma plataforma que utiliza o Git. O Git é uma ferramenta essencial para a prática da CA, e é uma das ferramentas mais importantes para o pesquisador que deseja tornar sua pesquisa mais transparente e reprodutível.

<https://youtu.be/XCa6mE0bEI0>

Zotero

Baixe a versão mais recente do Zotero: <https://www.zotero.org/download/> e cadastre uma conta: <https://www.zotero.org/user/register/>. Vamos discutir sobre o Zotero e diversos plugins que são úteis no dia-a-dia do pesquisador. Atualmente, o Zotero é a ferramenta mais completa para gerenciamento de referências e bibliotecas, e se integra nativamente com o RStudio e diversas ferramentas de IA.

<https://youtu.be/Nyi3moDTQ64>

OSF

Cadastre no Open Science Framework (OSF): <https://osf.io/register/>. Como veremos, essa plataforma é uma das mais importantes para a prática da CA. Ela está no começo (pré-registro) e no final (repositório de dados e pré-print) do ciclo de vida (workflow) de um projeto de pesquisa. O vídeo abaixo mostra o cadastro nessa plataforma antes das mudanças de outubro de 2025, mas o processo continua o mesmo.

<https://youtu.be/WQ4O-8O6MwI>

Zenodo

Apesar do Zenodo cumprir funções similares ao OSF e até mesmo ao Github, ele é mais voltado para a publicação de dados e publicações científicas pontuais. Cadastre no Zenodo: <https://zenodo.org/login/> e vincule sua conta com o Github. Isso será útil, principalmente, para geração de DOI de repositórios do Github.

<https://youtu.be/pZaqL3Auxb0>

RStudio

Baixe a versão mais recente do RStudio: <https://posit.co/download/rstudio-desktop/>. O RStudio é uma Integrated Development Environment (IDE) para a linguagem R. O RStudio é uma ferramenta essencial para a prática da CA em R, pois integra as principais soluções que abordaremos no curso (Zotero, Quarto, Git/Github, etc.). A empresa RStudio recentemente mudou o nome para Posit, com o objetivo refletir melhor a expansão da empresa para além do desenvolvimento de ferramentas para R, incluindo Python e outras linguagens. Nesse mesmo link você pode baixar o R, que é a linguagem de programação mais utilizada por cientistas. No curso utilizaremos as versões 4.5.1 do R, 2025.05.1+513 do RStudio e Quarto 1.6.42 (que já vem integrado no RStudio). Assim como o Quarto tem substituído o RMarkdown, a Posit está substituindo o RStudio pelo [Positron](#), que é um “misto” de RStudio + VS Code, e potencialmente veremos em edições futuras de nosso curso. Por hora, focaremos no RStudio.

<https://youtu.be/KM2jxaNIEUk>

Docker

Baixe a versão mais recente do Docker: <https://www.docker.com/products/docker-desktop>. Nesse mesmo link você cria uma conta. O Docker é uma plataforma para desenvolvimento, envio e execução de aplicativos. O Docker é uma ferramenta essencial para a prática da CA, pois permite a criação de ambientes reprodutíveis.

<https://youtu.be/WjXQxhTLlrQ>

Máquinas Virtuais

Embora o curso foque na utilização de containers via Docker para garantir ambientes reprodutíveis, muitos dos Recursos Educacionais Abertos (REA) apresentados ao longo da jornada foram organizados e testados dentro de uma máquina virtual (VM). Por isso, disponibilizamos abaixo uma sequência de vídeos que mostram como configurar uma VM no Windows 11, utilizando duas abordagens:

- **Sandbox:** ambiente temporário e isolado, ideal para testes rápidos.
- **Hyper-V:** solução mais robusta e permanente para virtualização.

Esses vídeos são opcionais e não serão abordados diretamente nas aulas, mas podem ser úteis para quem deseja explorar outras formas de garantir reprodutibilidade e organização dos seus REA.

Sandbox no Windows 11

- [Como habilitar o Sandbox no Windows 11 Pro Pro](#)
- [Como habilitar o Sandbox no Windows 11 Home Home](#)

Esses vídeos mostram como ativar o recurso de Sandbox, mesmo em versões onde ele não está disponível oficialmente. Ideal para quem quer testar rapidamente scripts ou softwares em ambiente isolado.

Hyper-V no Windows 11

- [Como habilitar o Hyper-V no Windows 11 Pro Pro](#)
- [Como habilitar o Hyper-V no Windows 11 Home Home](#)

Esses vídeos explicam como ativar o Hyper-V, mesmo em versões Home, permitindo a criação de ambientes virtuais persistentes e mais completos.

Configuração da Máquina Virtual

- [Como configurar sua primeira máquina virtual no Hyper-V](#)

Este vídeo mostra passo a passo como criar e configurar uma VM no Hyper-V, incluindo alocação de recursos e instalação do sistema operacional.

Capítulo 1

Introdução à Ciência Aberta

A pesquisa científica atual enfrenta vários desafios (Munafò et al., 2017). Problemas como o pequeno tamanho da amostra, pequenos tamanhos de efeito, p-hacking e HARKing (viés positivo de publicação), conflitos de interesse e a competição entre cientistas que trabalham isoladamente sem combinar seus esforços, têm sido apontados como catalizadores do que se convencionou chamar de “crise de reprodutibilidade” na ciência (M. Baker, 2016; Munafò et al., 2017).

Pesquisas apontam que mais de 70% de pesquisadores que tentaram, falharam em reproduzir os experimentos de outros cientistas, e mais da metade falhou em reproduzir seus próprios experimentos (M. Baker, 2016), com estimativa de que 85% dos esforços de pesquisas estejam sendo desperdiçados (Munafò et al., 2017), gerando custos econômicos bilionários (Freedman et al., 2015).

A despeito daqueles que advogam que não existe essa tal “crise de reprodutibilidade” (Bernard, 2023; Fanelli, 2018; Protzko et al., 2023), a grande maioria da comunidade científica concorda com sua existência e defende a melhoria da transparência, reprodutibilidade e eficiência na ciência (M. Baker, 2016).

Nesse contexto, o movimento da Ciência Aberta (CA) tem ganhado notoriedade e mudado a percepção sobre o cenário científico global (Crüwell et al., 2019). Ele busca tornar o conhecimento científico mais acessível, transparente e colaborativo. Se apresenta como uma coleção de práticas de democratização do conhecimento e ruptura com o formato único de divulgação do conhecimento científico (Crüwell et al., 2019; Heinz & Miranda, 2024; Munafò et al., 2017). Ele surge do embate entre aqueles que buscam compartilhar o conhecimento e aqueles que defendem mecanismos de apropriação privada para a produção científica (Heinz & Miranda, 2024).

A CA é um termo múltiplo e genérico (Vicente-Saez & Martinez-Fuentes, 2018), que representa diversas interpretações, e é considerada um novo modelo de divulgação e produção de resultados científicos por meio do acesso livre e irrestrito ao conhecimento (Heinz & Miranda, 2024). A CA não é apenas um conceito, mas uma prática multifacetada que influencia o ciclo de vida da pesquisa, desde a concepção até a disseminação dos resultados (Silva & Silveira, 2019).

Existem pelo menos cinco escolas de pensamento dentro da CA. Estas escolas abrangem

desde a arquitetura tecnológica necessária para suportar a ciência até a inclusão do público geral na criação de conhecimento, passando pela medição do impacto alternativo, acesso ao conhecimento como um direito humano, e a pesquisa colaborativa como inovação aberta (Silva & Silveira, 2019).

A taxonomia proposta pela **FOSTER** (Facilitate Open Science Training for European Research), e sua releitura revisada e ampliada para o contexto latino americano por Silveira et al. (2023), tendo em vista as recomendações da UNESCO (2021), nos dá uma dimensão da complexidade do assunto (vide ilustração em: <https://doi.org/10.5281/zenodo.7836884>).

Existem vários argumentos que sustentam a importância da CA (Heinz & Miranda, 2024). Primeiramente, a CA pode trazer benefícios sociais significativos, pois contribui para o avanço do conhecimento, a inovação, a educação, a transparência e a participação cidadã. Além disso, a CA pode trazer benefícios científicos ao aumentar a qualidade, a reprodutibilidade, a eficiência e o impacto da pesquisa científica. Ela também facilita a colaboração, a comunicação e a interdisciplinaridade entre os pesquisadores. Por fim, a CA pode trazer benefícios éticos ao promover a integridade, a responsabilidade, a equidade e a diversidade na ciência, além de respeitar os direitos dos autores, dos participantes e da sociedade como um todo.

Esses argumentos são fundamentais para legitimar a CA e destacar sua importância no mundo atual (Heinz & Miranda, 2024), principalmente, como potencial transformador para reduzir desigualdades existentes em tecnologias de informação e comunicação – reduzir exclusões digitais, tecnológicas e de conhecimento –, e acelerar o progresso rumo à implementação da Agenda 2030 e realização dos Objetivos de Desenvolvimento Sustentável (UNESCO, 2021).

O movimento da CA no Brasil está em uma fase transitória (Rezende & Falgueras, 2020) – ainda consolidando o acesso aberto – com o governo desempenhando um papel crucial nesse processo. O Brasil tem ganhado destaque por sua abordagem única na implementação da CA. Esta abordagem é moldada por marcos regulatórios que se estendem desde o governo até as instituições e agências de financiamento. Os regulamentos brasileiros, particularmente aqueles que promovem a abertura de dados governamentais, têm um impacto direto na prática científica. Eles incentivam a transparência e facilitam o acesso a dados científicos originados de instituições públicas (Rezende & Falgueras, 2020).

A trajetória brasileira rumo à CA inicia com a abertura de dados na esfera governamental entre 2009 e 2016, evoluindo para a criação de um grupo de trabalho em 2017 pelo Ministério da Ciência, Tecnologia, Inovações e Comunicações (MCTIC) para desenvolver uma política nacional para a CA. Este esforço concentrou ênfase no reconhecimento dos dados de pesquisa como ativos de desenvolvimento científico, econômico e social, buscando facilitar seu acesso, compartilhamento e reutilização (Rezende & Falgueras, 2020).

Talvez por esse motivo, as políticas institucionais brasileiras revelam um cenário ainda muito influenciado pela “via verde” do movimento de acesso aberto, caracterizado pelo depósito de dados em repositórios digitais abertos, e que o comprometimento efetivo do Brasil com a CA ainda é incipiente. As regulamentações atuais favorecem principalmente o acesso aberto, sem abordar de maneira abrangente outros aspectos da CA (Rezende & Falgueras, 2020). O Brasil é um dos líderes mundiais no fornecimento de acesso universal às suas pesquisas e estudos (Neto et al., 2016), com crescimento estável de sua produção

científica disponível em acesso aberto, principalmente, as áreas de Agricultura e Ciência & Tecnologia (Caballero-Rivero et al., 2019).

Em termos de pesquisa acadêmica sobre o tema no Brasil, os estudos são precoces e concentrados na área de Ciência da Informação (Albano et al., 2023). Apesar da maturidade da CA no Brasil, a importância do tema – materializada na quantidade de produção acadêmica – tem aumentado vertiginosamente (Albano et al., 2023), e a dispersão de autores e respectivas instituições que publicam sobre o assunto, parece ser a situação predominante.

Apesar de importantes atores nacionais, tais como CAPES, CNPq e Scielo, defenderem o crescimento de iniciativas de CA (Mendes-Da-Silva, 2023), o assunto no Brasil parece estar circunscrito em iniciativas de importantes periódicos nacionais sobre dados aberto, capitaneados pelas orientações da Scielo. Não foi encontrada nenhuma pesquisa empírica, sobre a prática da CA no Brasil.

Por prática de CA entende-se a perspectiva micro da CA, relacionadas com as terminologias e conhecimento em torno do fluxo de trabalho do gerador de conhecimento científico aberto (Figura 1.1), ou seja, o cientista que se propõe tornar sua pesquisa transparente, reprodutível e replicável.




Figura 1.1: Perspectiva micro da CA. Taxonomia relacionada com terminologias e conhecimento em torno da prática (fluxo de trabalho) do gerador de conhecimento científico aberto. Ilustração disponível em: <https://doi.org/10.5281/zenodo.10835001>.

Exclui-se a perspectiva macro, relacionadas com as ramificações conceituais da CA concernentes às políticas públicas, infraestrutura, envolvimento aberto de atores sociais e diálogo aberto com outros sistemas de conhecimento (Figura 1.2). Essa última perspectiva está fora do escopo da discussão do curso, que se concentra em algumas das dimensões da perspectiva micro, particularmente, as ferramentas disponíveis para compilação dos produtos científicos que integram a publicação científica (UNESCO, 2021).

Apesar de uma verossímil expectativa desabonadora, tendo em vista o contexto da CA no Brasil, o diagnóstico da situação da prática da CA se mostra importante, *per se*, pois:

1. ajuda a compreender a natureza exata do problema, suas causas, efeitos e riscos;
2. auxilia a alocação eficiente de recursos pelos atores envolvidos (e.g., os programas



3. orienta indicadores de desempenho e metas realistas, o que facilita a avaliação do progresso e a eficácia das ações tomadas;
4. permite que os atores envolvidos aprendam com os problemas enfrentados, adaptando-se e melhorando suas estratégias e processos para o futuro; e
5. torna possível desenvolver soluções ou intervenções que sejam diretamente direcionadas ao problema em questão, aumentando as chances de sucesso.

A referida crise não deriva de má conduta científica, mas principalmente da confusão entre replicar conclusões, replicar resultados, falta de educação em estatística, lógica científica, método científico, alfabetização de dados, etc. Para combater essas questões é necessário investir em educação e disseminação de boas práticas de investigação para uma mudança de cultura (D. H. Baker et al., 2023; Bezjak et al., 2018; Chopik et al., 2018; Crüwell et al., 2019; Dogucu & Çetinkaya-Rundel, 2022; Janz, 2015; McAleer et al., 2022; Munafò et al., 2017; Toelch & Ostwald, 2018).

Investir em recursos humanos, treinamento, educação, alfabetização digital, capacitação sistemática e contínua, e fomentar uma cultura científica de CA, têm sido apresentadas como algumas das principais medidas simultâneas para superar o cenário atual (Committee on Reproducibility and Replicability in Science et al., 2019; European Commission. Directorate General for Research and Innovation., 2017; UNESCO, 2021). A proposta

do curso pode contribuir para a literatura da CA no Brasil, pois pretende perseguir dois objetivos concomitantes: 1) diagnosticar sua prática junto aos pesquisadores brasileiros; e 2) promover o desenvolvimento de uma intervenção educacional sobre a prática (work-flow) e principais ferramentas para compilação dos produtos científicos que integram uma publicação científica aberta.

i *A Practical Guide for Transparency in Psychological Science*

O artigo (Klein et al., 2018) é um guia prático para pesquisadores que desejam compartilhar os produtos de sua pesquisa. Os autores argumentam que as práticas de pesquisa transparentes são essenciais para melhorar a credibilidade e a cumulatividade da ciência.

O artigo fornece recomendações específicas sobre como compartilhar os seguintes produtos de pesquisa:

- Protocolo de estudo
- Materiais
- Dados e metadados
- Procedimento de análise
- Relatórios de pesquisa

As recomendações gerais dos autores são as seguintes:

- **Torne a transparência um padrão:** isso significa compartilhar o máximo possível de informações sobre sua pesquisa, desde o início do processo.
- **Não deixe que o perfeito seja inimigo do bom:** mesmo que você não possa compartilhar todos os detalhes de sua pesquisa, compartilhar alguma coisa é melhor do que nada.
- **Compartilhe e documente o que puder:** isso ajudará a garantir que sua pesquisa seja reproduzível e confiável.
- **Comece cedo:** começar a compartilhar informações sobre sua pesquisa no início do processo pode ajudá-lo a evitar problemas e economizar tempo.

Os autores também discutem algumas preocupações comuns que os pesquisadores têm sobre as práticas de pesquisa transparentes. Eles argumentam que essas preocupações são geralmente infundadas e que as práticas transparentes têm muitos benefícios.

Os principais benefícios das práticas de pesquisa transparentes são:

- **Melhor credibilidade da pesquisa:** os pesquisadores transparentes são mais propensos a serem vistos como confiáveis e honestos.
- **Maior cumulatividade da ciência:** os pesquisadores transparentes tornam mais fácil para outros pesquisadores construir sobre seu trabalho.
- **Mais oportunidades de colaboração e financiamento:** os pesquisadores transparentes são mais propensos a serem convidados para colaborar com outros pesquisadores e a receber financiamento.
- **Maior eficiência da pesquisa:** as práticas transparentes podem ajudar os pesquisadores a economizar tempo e recursos.

Em conclusão, o artigo fornece informações valiosas para pesquisadores que desejam compartilhar os produtos de sua pesquisa. As recomendações dos autores são

baseadas em evidências e podem ajudar os pesquisadores a melhorar a qualidade e a credibilidade de seu trabalho.

i *Easing Into Open Science: A Guide for Graduate Students and Their Advisors*

O artigo (Kathawalla et al., 2021) fornece um guia para ajudar estudantes de pós-graduação e seus orientadores a se envolverem na prática da ciência aberta (CA). A CA é descrita como um termo amplo que se refere a uma variedade de princípios e comportamentos relacionados à transparência, credibilidade, reprodutibilidade e acessibilidade.

O artigo sugere oito práticas de CA (das quais destaco sete) que estudantes de pós-graduação iniciantes podem começar a adotar hoje. Cada comportamento é classificado em termos de dificuldade (fácil, médio, difícil) e apresentado em ordem de adoção sugerida. Em cada prática, eles seguem o formato de o quê, por quê, como e preocupações.

Algumas das práticas sugeridas incluem:

1. **Fluxo de Trabalho do Projeto (Nível Fácil):** isso inclui a estrutura da pasta do arquivo, convenções de nomenclatura de documentos, controle de versão, armazenamento em nuvem e outros detalhes. Ter um sistema de fluxo de trabalho de projeto dedicado ajuda a manter sua pesquisa organizada, melhorando a reprodutibilidade, minimizando erros e facilitando colaborações com outros e com você no futuro.
2. **Preprints (Nível Fácil):** postar um manuscrito antes de submetê-lo a uma revista permite um feedback mais amplo do que o que é proporcionado pela revisão por pares e pode ajudar a melhorar um artigo antes da submissão, identificando quaisquer falhas importantes.
3. **Código Reprodutível (Nível Médio):** o código reprodutível para análise de dados e visualizações (por exemplo, tabelas, figuras) refere-se a uma versão detalhada e escrita do seu código que permitiria a outra pessoa (ou a você no futuro) gerar a mesma saída relatada em seu manuscrito.
4. **Compartilhamento de Dados (Nível Médio):** compartilhar dados refere-se a tornar o conjunto de dados desidentificado usado para um projeto disponível para outros pesquisadores.
5. **Escrita de Manuscrito Transparente (Nível Médio):** Para escrever um manuscrito transparente, claro e reprodutível, é útil seguir as diretrizes ou padrões de escrita de manuscritos.
6. **Pré-registro (Nível Médio):** o pré-registro refere-se à postagem de um esboço cronometrado das perguntas de pesquisa, hipóteses, método e plano de análise para um projeto específico antes da coleta de dados e/ou análise.
7. **Relatório Registrado (Nível Difícil):** os Relatórios Registrados envolvem um processo de submissão em duas partes, onde os autores primeiro enviam uma proposta de Estágio 1, que inclui a introdução, método e plano de análise - tudo antes que a coleta de dados e/ou análise tenha sido feita.

O artigo enfatiza que se envolver em uma prática de CA é melhor do que nenhuma e que a CA é apenas uma boa ciência. Além disso, sugere-se que se construa sobre o trabalho que já foi feito em vez de reinventar a roda. A maioria das práticas

sugeridas se concentra no uso do [Open Science Framework](#).

Capítulo 2

Repositórios da Ciência Aberta

2.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Criar e configurar projetos no OSF, incluindo metadados, componentes hierárquicos e integrações com serviços externos
- Conectar o OSF a armazenamentos em nuvem (OneDrive, Google Drive), gerenciadores de referências (Zotero) e repositórios de código (GitHub)
- Onde criar e submeter pré-registros utilizando templates apropriados ao desenho de pesquisa (OSF Preregistration, Secondary Data, Registered Reports)
- Distinguir entre preregistration e registration, compreendendo quando aplicar cada modalidade no ciclo de pesquisa
- Gerar DOIs para projetos e componentes, tornando materiais de pesquisa citáveis e rastreáveis permanentemente
- Compartilhar projetos com colaboradores, gerenciar permissões e criar links anônimos para revisão por pares
- Publicar preprints através do OSF Preprints ou serviços disciplinares (PsyArXiv, SocArXiv)
- Avaliar quando escolher OSF versus outras plataformas

2.2 Contextualização

No contexto da CA, existem diversos repositórios disponíveis, cada um com suas funções e propósitos específicos. Esses repositórios são essenciais para promover a transparência, acessibilidade e colaboração na pesquisa científica. Eles assumem um papel muito relevante na democratização do conhecimento e na promoção da colaboração científica. Cada qual com suas particularidades, oferecem aos pesquisadores ferramentas para armazenar, compartilhar e gerenciar dados, publicações e outros materiais de pesquisa, ou se preferir, todo o ciclo de vida da pesquisa.

- **Zenodo**: é um repositório gerido pelo CERN em colaboração com o projeto [OpenAIRE](#) da União Europeia. Oferece armazenamento gratuito e seguro para dados de pesquisa, com a capacidade de gerar DOIs para facilitar a citação dos dados.
- **Figshare**: é um repositório comercial que permite aos pesquisadores armazenar, compartilhar e descobrir dados de pesquisa. Oferece ferramentas para visualização de documentos, gráficos e outros tipos de dados diretamente no navegador, além de gerar DOIs para os projetos.
- **Mendeley Data**: é um repositório de dados de pesquisa da Elsevier, permitindo o armazenamento, compartilhamento e citação de conjuntos de dados. Ele suporta uma ampla gama de tipos de dados e está integrado com a plataforma de referência Mendeley.
- **Harvard Dataverse**: é uma rede de repositórios que permite aos pesquisadores compartilhar, armazenar e citar dados de pesquisa. Ele oferece ferramentas avançadas para a gestão de dados, incluindo controle de versões e metadados ricos, essenciais para o gerenciamento do ciclo de vida da pesquisa.
- **arXiv**: é um repositório de pré-impressões de artigos científicos em física, matemática, ciência da computação e outras áreas. Ele permite aos pesquisadores compartilhar seus trabalhos antes da revisão por pares, facilitando o acesso à pesquisa em estágios iniciais.
- **GitHub**: é uma plataforma de desenvolvimento colaborativo baseada em Git, amplamente utilizada por pesquisadores para compartilhar código, documentos e outros materiais de pesquisa. Ele oferece controle de versões, rastreamento de problemas e integração com outras ferramentas de desenvolvimento.

Além desses exemplos, poderíamos citar diversas outras soluções que cumprem papéis semelhantes ou focado em disciplinas específicas: [Databrary](#), [DataverseNO](#), [DataONE](#), [DataCite](#), [DataHub](#), [DataMed](#), [DataShare](#), [DataVerse](#), [Dryad](#), [EarthChem](#), [EUDAT](#), [European Nucleotide Archive \(ENA\)](#), [GenBank](#), [Google Dataset Search](#), [HathiTrust Research Center](#), [ICPSR](#), [JSTOR Data for Research](#), [National Center for Biotechnology Information \(NCBI\)](#), [National Institutes of Health \(NIH\) Data Sharing Repositories](#), [National Oceanographic Data Center \(NODC\)](#), [PLOS ONE](#), [PubMed Central](#), [Research Data Australia](#) e [UK Data Service](#); e em última instância, as redes sociais acadêmicas como [Academia.edu](#), [Google Scholar](#), [ORCID](#) e [ResearchGate](#), também podem ser usadas para compartilhar e descobrir pesquisas.

A despeito de todas essas opções, vamos focar na plataforma **Open Science Framework (OSF)** para a realização do nosso curso. O **OSF** é uma plataforma de código aberto para colaboração em pesquisa, que oferece uma estrutura para conectar os fluxos de trabalho de pesquisa, desde a concepção do projeto até a publicação. O **OSF** é mantido pelo [Center for Open Science \(COS\)](#), uma organização sem fins lucrativos com sede nos Estados Unidos. O **OSF** é um dos principais produtos do COS e é usado por pesquisadores de todo o mundo para colaborar em projetos de pesquisa.

O **OSF** oferece uma série de recursos para ajudar os pesquisadores a gerenciar seus projetos de pesquisa, incluindo:

- **Criar projetos de pesquisa**: organizar seus estudos, incluindo metadados, datasets, materiais de pesquisa e publicações.
- **Carregar e publicar dados**: armazenar e compartilhar seus dados de forma segura e acessível.

- **Colaboração em equipe:** convidar colaboradores para participar do projeto, atribuir tarefas e acompanhar o progresso.
- **Integração com outras ferramentas:** conectar a armazenamentos nas nuvens (Box, DropBox, Google Drive e OneDrive), gerenciadores de referências (Zotero e Mendeley) e outros repositórios (Dataverse, Github, figshare, etc).

O **OSF** tem um foco mais amplo em todo o ciclo de vida da pesquisa, desde a concepção da ideia até a publicação dos resultados (Figura 2.1). Já algumas das soluções citadas foca principalmente no compartilhamento de dados e publicações. O **OSF** oferece ferramentas mais robustas para colaboração em equipe, como wikis, painéis de discussão e ferramentas de gerenciamento de tarefas, e principalmente, possui uma comunidade mais ativa de pesquisadores e colaboradores.



Figura 2.1: OSF Research Lifecycle

Para os alunos que desejam uma leitura sobre o **OSF** na prática, indicamos os artigos de Sullivan et al. (2019) e Soderberg (2018). Apesar de o leitor poder encontrar *prints* das telas da plataforma desatualizadas, esses dois artigos podem ser um bom começo para entender a lógica da plataforma. E *off course*, recomendamos fortemente você dar uma olhada no [suporte do OSF](#), onde podemos encontrar vídeos introdutórios excelentes.

💡 *Duplicando um projeto*

Você sabia que é possível executar um “*duplicate*” e criar uma cópia do projeto existente ou duplicar apenas a estrutura do projeto e seus componentes de um projeto público no OSF?

Você que se interessa em iniciar seu próprio projeto OSF com um modelo, pode criar sua própria duplicata do projeto Olson et al. (2022) para começar!

Neste [projeto](#), existem templates e recursos básicos para diversos casos de uso encontrados no OSF; coordenação de equipes de pesquisa, planejamento de gerenciamento de dados, documentos reproduzíveis e até mesmo gerenciamento de cursos.

2.3 Pré-registro e Transparência Metodológica

Pré-registro documenta hipóteses e planos de análise antes da coleta de dados. A prática mitiga vieses de confirmação e decisões *post-hoc* que comprometem a validade dos resultados. Registrar decisões metodológicas antes de observar os dados torna explícito o que foi planejado versus o que foi exploratório - uma distinção que a ciência tradicional frequentemente obscurece.

O **OSF** distingue duas modalidades. *Preregistration* é criado antes da coleta ou análise de dados, quando os dados ainda não existem ou não foram observados. *Registration* documenta estudos já concluídos ou cria *snapshots* permanentes de projetos em qualquer estágio. Ambos geram registros imutáveis com timestamps, mas o timing difere. Preregistration tem maior valor para transparência metodológica porque compromete o pesquisador com um plano antes de conhecer os resultados.




Figura 2.2: OSF Registration

O **OSF** oferece múltiplos templates adaptados a diferentes desenhos. *OSF Preregistration* é o mais utilizado e abrangente, cobrindo hipóteses, métodos de coleta, planos de análise e critérios de exclusão. *Secondary Data Preregistration* é específico para análises de dados já coletados por outros ou por você em projetos anteriores - ele inclui questões sobre seu conhecimento prévio dos dados, tornando transparente o que já foi explorado. *Registered Report Protocol* é para submissão a periódicos que revisam protocolos antes da coleta (Stage 1), oferecendo aceitação provisória baseada na qualidade metodológica,

independentemente dos resultados futuros. *Generalized Systematic Review Registration* é voltado para revisões sistemáticas e meta-análises, documentando estratégias de busca, critérios de inclusão/exclusão e métodos de síntese.

Preregistros podem ser embargados por até quatro anos, permitindo trabalhar em projetos sem exposição prematura a concorrentes. O histórico de versionamento permanece preservado mesmo durante embargo. Após publicação, o registro torna-se imutável, mas você pode vincular outputs futuros (artigos, datasets, preprints) através da funcionalidade *Connected Resources*, criando uma rede rastreável entre protocolo e produtos finais.

2.4 Identificadores Persistentes e Rastreabilidade

DOIs tornam materiais de pesquisa citáveis permanentemente. O **OSF** gera DOIs para projetos e componentes individuais, transformando qualquer elemento do seu workflow em objeto citável com endereço permanente na web. Datasets, protocolos, códigos de análise, instrumentos - todos ganham identidade própria no registro acadêmico.

A integração com ORCID vincula automaticamente outputs ao perfil permanente do pesquisador. Cada DOI gerado no **OSF** pode ser associado ao seu ORCID, construindo um registro completo da sua produção que transcende afiliações institucionais. Metadados estruturados alimentam sistemas de descoberta como Google Scholar e DataCite, aumentando a visibilidade e o impacto dos materiais compartilhados.

Zenodo e OSF diferem na granularidade. Zenodo gera DOIs por versão de arquivo, permitindo citar exatamente a versão 1.2 de um dataset. OSF gera DOIs por projeto ou componente, citando o container que pode evoluir ao longo do tempo. A escolha depende das necessidades: Zenodo favorece imutabilidade estrita; OSF favorece flexibilidade e evolução do projeto com rastreamento de versões interno.

2.5 OSF no Ecossistema de Ferramentas

Você pode configurar o **OSF** para funcionar como hub central, conectando ferramentas especializadas do seu workflow acadêmico. Ele não compete com GitHub ou Zotero - integra-se a eles. GitHub gerencia controle de versão detalhado de código-fonte, rastreando cada mudança com granularidade de linha. Zotero organiza referências bibliográficas e PDFs anotados. OSF orquestra tudo, vinculando repositórios GitHub como componentes do projeto, sincronizando bibliotecas Zotero, conectando armazenamentos em nuvem onde os dados vivem.

Essa arquitetura modular respeita especializações. Use GitHub para o que ele faz melhor: versionamento de código e colaboração via pull requests. Use Zotero para gestão bibliográfica com plugins e automações. Use OneDrive ou Google Drive para arquivos grandes que excedem limites dos repositórios especializados. O OSF une tudo sob metadados estruturados, controle de acesso unificado e DOI citável que aponta para o projeto completo.

RStudio e Quarto, que serão discutidos em módulos posteriores, produzem documentos dinâmicos onde análises, código e narrativa coexistem. Hospedar esses projetos no GitHub, vinculá-los ao OSF e depositar versões finais no Zenodo com DOI cria pipeline completo: desenvolvimento transparente (GitHub), coordenação de projeto (OSF),

arquivo permanente versionado (Zenodo). Cada ferramenta contribui com sua força, nenhuma tenta fazer tudo.

2.6 Quando Não Usar OSF

GitHub é superior para projetos centrados em código onde colaboração via *issues*, *pull requests* e integração contínua são centrais. Desenvolvedores de software preferem GitHub porque ele foi desenhado para esse workflow. O OSF conecta-se ao GitHub, mas não substitui suas funcionalidades nativas de desenvolvimento colaborativo.

arXiv permanece padrão para física, matemática e ciência da computação por razões históricas e culturais. Submeter preprints ao arXiv sinaliza conformidade com normas disciplinares. O OSF oferece OSF Preprints e serviços disciplinares (PsyArXiv, SocArXiv), mas em campos onde arXiv domina, migrar traz pouco benefício.

Repositórios disciplinares específicos são exigidos por journals ou agências de fomento em algumas áreas como genômica (GenBank) e cristalografia (Protein Data Bank). Nesses casos, depositar no repositório mandatado é obrigatório. O OSF pode complementar, vinculando o projeto ao depósito externo via metadados e *Connected Resources*, mas não substitui requisitos formais.

Dados sensíveis com restrições éticas ou legais severas podem exigir infraestrutura institucional com controles de acesso mais rígidos que os oferecidos pelo OSF. Dados de saúde identificáveis, por exemplo, frequentemente precisam permanecer em servidores certificados pela instituição. O OSF pode hospedar metadados e documentação enquanto os dados permanecem em repositório restrito.

2.7 Preparação para a Aula

! Pré-requisitos

Antes da aula síncrona, certifique-se de completar **todos** os passos abaixo. Um vídeo com instruções detalhadas está disponível na [página de pré-trabalho do curso](#).

Checklist de Preparação:

1. ☒ Criar conta no [OSF](#)
2. ☒ Atualizar seu perfil no OSF (Opcional)
3. ☒ Explorar a interface inicial do OSF e familiarizar-se com a navegação
4. ☒ Dar uma “olhada” nos templates de preregistro disponíveis em [OSF Registries](#) (Opcional)

Capítulo 3

Gerenciamento de Referências e Bibliotecas

3.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Configurar o Zotero 7 com plugins essenciais (Better BibTeX, Zotero Attanger etc.) e sincronização com serviços de nuvem
- Organizar referências em coleções temáticas e utilizar tags para categorizar estágios do processo de pesquisa
- Criar anotações e marcações em PDF como material para análises qualitativas e sínteses de literatura
- Gerar arquivos `.bib` automatizados para integração com documentos dinâmicos (Quarto/RStudio)
- Produzir citações em documentos Word/LibreOffice e em documentos reprodutíveis via chaves BibTeX
- Compartilhar bibliotecas através de grupos do Zotero
- Automatizar renomeação de PDFs e contornar limitações de armazenamento usando nuvem externa
- Informar sobre as diversas possibilidades de integração do Zotero com ferramentas de IA (NotebookLM, Elicit, plugins de sumarização) e gestão de conhecimento (Obsidian, Notion)

3.2 Contextualização

Existem mais de 15 diferentes¹ gerenciadores de referências (Proske et al., 2023). Entre eles podemos indicar o [Citavi](#) e o [RefWorks](#). No entanto, os mais populares são o [EndNote](#), [Mendeley](#) e [Zotero](#). O primeiro é proprietário e descartamos enquanto opção para nosso workflow de Open Science. Os dois últimos são excelentes opções, no entanto,

¹[Esta lista](#) no Wikipedia, que é atualizada constantemente, faz uma comparação entre eles.

o Zotero se destaca por ser código aberto (totalmente gratuito), enquanto o Mendeley, embora gratuito, é propriedade da Elsevier, uma editora comercial. Isso significa que o Zotero não tem restrições de uso e não exige pagamento por recursos adicionais, exceto por maior armazenamento na nuvem, que inclusive, é um destaque do Mendeley (2Gb vs 300Mb).



Figura 3.1: Mapa de decisão para escolha do gerenciador de referências

Essa aparente desvantagem do Zotero é, na prática, contornável. O limite de 300Mb refere-se apenas à sincronização dos metadados (os dados da referência). O armazenamento dos arquivos PDF, que consomem mais espaço, pode ser direcionado para seu serviço de nuvem preferido (OneDrive, Google Drive, etc.) através de configurações e plugins específicos. Essa configuração, que será demonstrada na aula, resolve a limitação.

O Zotero tem uma comunidade ativa e fóruns de suporte, o que pode ser útil para solucionar problemas e compartilhar conhecimento com outros usuários. Como aqui valorizamos a liberdade de código aberto e uma comunidade engajada, o Zotero é nossa escolha.

Essa característica faz com que o Zotero se destaque em relação ao Mendeley, especialmente no que diz respeito ao **Ecosistema de Plugins**. O Zotero possui uma comunidade ativa de desenvolvedores e pesquisadores que criam e compartilham plugins. Esses plugins estendem as funcionalidades do Zotero, permitindo personalizações específicas e integrações com outras ferramentas (Behera & Jain, 2023).

O plugin [Better BibTeX](#), por exemplo, oferece recursos avançados de exportação e formatação de bibliografias, tornando-o uma escolha popular para usuários que trabalham com LaTeX, Markdown, HTML, e outras linguagens de marcação.² O ecossistema de

²Outro plugin discutido é a integração com o [SciHub](#) (Behera & Jain, 2023). Coloquei essa informação em nota, pois ele é questionável do ponto de vista ético, apesar de extensivamente utilizado no Brasil por estudantes de pós-graduação stricto sensu de diferentes áreas (Oddone & Souza, 2024). Ou se enxergarmos o problema sob outro ponto de vista, a ampla adoção do SciHub no Brasil e em todo o mundo reflete a resposta dos cientistas ao desgastado sistema de comunicação científica mantido pelas

plugins é tão ativo que já inclui diversas integrações com ferramentas de Inteligência Artificial (IA) para sumarização e análise de artigos (A.I.R.A., PapersGPT, ZotAi, entre outros).

A mensagem principal que pretendemos passar no curso sobre esse tópico é para você conceber os gerenciadores de referências e bibliotecas, especialmente o Zotero, no contexto do processo de pesquisa, e não apenas para citações e referências. Usuários avançados aproveitam o suporte que a maioria dos sistemas de gerenciamento de referências oferece para o ciclo da pesquisa reprodutível (Proske et al., 2023).

3.3 O Zotero no Ciclo de Pesquisa

O Zotero pode ser integrado desde a fase de revisão sistemática ou exploratória. Você organiza referências em coleções temáticas e utiliza tags para categorizar estágios do processo. Tags como “Para Ler”, “Lido”, “Importante”, ou “Artigo X” transformam o gerenciador em sistema de rastreamento do progresso da leitura e análise. Coleções aninhadas permitem estruturar a literatura por tema, metodologia ou relevância, criando uma arquitetura de conhecimento que cresce organicamente com a pesquisa.




Figura 3.2: Exemplos de organização de coleções no Zotero

As notas e marcações em PDF não servem apenas para lembrar trechos. Elas alimentam análises qualitativas e sínteses de literatura. Cada anotação pode ser exportada, revisitada e reorganizada conforme o argumento do seu texto se desenvolve. A integração entre leitura, anotação e escrita torna-se dinâmica. O Zotero pode funcionar como repositório vivo de ideias, não apenas de referências bibliográficas.

Ferramentas de gestão de conhecimento como [Obsidian](#) e [Notion](#) podem ser integradas ao Zotero, criando redes de notas interconectadas. Suas anotações no Zotero alimentam bases de conhecimento pessoal, onde conceitos de diferentes artigos dialogam entre si. Isso transforma a revisão de literatura em processo iterativo de construção de sentido.

editoras internacionais. Reforça, também, a relevância dos princípios da Ciência Aberta (Oddone & Souza, 2024).

3.4 Integração com Fluxos de Trabalho Reprodutíveis

O fluxo de trabalho de pesquisa reprodutível exige ferramentas que se integram com documentos dinâmicos, como Quarto e RStudio. As citações são gerenciadas por chaves BibTeX, conceito que será central na aula. O plugin [Better BibTeX](#), como já comentado, viabiliza essa integração de forma transparente.

O [Better BibTeX](#) permite criar e atualizar automaticamente arquivos `.bib` que se sincronizam com seus documentos dinâmicos. Você adiciona uma referência no Zotero, e o arquivo `.bib` reflete a mudança instantaneamente. Trabalho manual é eliminado. A gestão de referências e a escrita do manuscrito acontecem em paralelo, sem retrabalho entre coleta de literatura e produção de texto.

Manter seu arquivo `.bib` no GitHub junto com seus scripts garante que colegas possam reproduzir exatamente as mesmas citações. Versionamento de referências torna-se parte do controle de versão do projeto. Quando você compartilha o repositório, compartilha também a biblioteca bibliográfica exata que usou - rastreabilidade completa da cadeia de conhecimento.

Grupos do Zotero permitem compartilhar bibliotecas completas com equipes de pesquisa. Colaboração e transparência se expandem: todos os membros do grupo acessam as mesmas referências, anotações e anexos. Mudanças feitas por um membro sincronizam automaticamente com os demais. Projetos colaborativos ganham uma base bibliográfica unificada.

Gerenciadores preservam DOIs, abstracts e metadados que facilitam a citação correta e rastreabilidade das fontes. Metadados completos permitem que outros pesquisadores localizem rapidamente os materiais citados. Isso é requisito para pesquisa aberta e transparente - não basta citar, é preciso facilitar o acesso à fonte original.

3.5 IA e Descoberta de Literatura

Fluxos de trabalho baseados em RAGs (Retrieval-Augmented Generation) com LLMs locais ou ferramentas como [PapersGPT](#) podem ser alimentados diretamente pela sua biblioteca Zotero. RAGs na nuvem, como o [NotebookLM](#) do Google, também são mais facilmente acionados com a organização eficiente das coleções/pastas do Zotero. Você constrói assistentes de pesquisa personalizados que conhecem profundamente sua literatura, respondem perguntas contextualizadas e sugerem conexões entre artigos.

Plataformas de descoberta de literatura assistida por IA, como [ResearchRabbit](#), [Elicit](#) e [SciSpace](#), complementam o Zotero. [ResearchRabbit](#) descobre conexões importantes entre a literatura; [Elicit](#) automatiza revisões de literatura a partir de perguntas de pesquisa; [SciSpace](#) oferece explicações contextuais de artigos complexos. Essas ferramentas não substituem a leitura crítica, mas aceleram a triagem inicial e a identificação de estudos relevantes. Integradas ao Zotero, formam um ecossistema de pesquisa potencializado por IA.

3.6 Indo Além das Funcionalidades Básicas

Atualmente, gerenciadores de referências oferecem funcionalidades que incluem:

- Recursos para coletar referências com textos completos e organizá-las em pastas e/ou (sub)coleções;
- Marcar entradas de referência, fazer anotações e destacar o texto completo por meio de visualizadores de PDF integrados;
- Citar referências em diferentes estilos de citação por meio de complementos para software de processamento de texto ou criando e atualizando automaticamente arquivos `.bib` para outras linguagens de marcação;
- Sincronizar referências entre o aplicativo de desktop e a versão móvel, bem como entre diferentes computadores; e
- Compartilhar referências (Proske et al., 2023)

Mas o Zotero permite ir além. Plugins como Zotero Attanger automatizam a renomeação e o armazenamento de PDFs. Você define padrões de nomenclatura - por exemplo, “Autor_Ano_Título” - e o plugin renomeia todos os arquivos de forma consistente. PDFs podem ser organizados em pastas externas no OneDrive, Google Drive ou Dropbox, sincronizando automaticamente entre dispositivos e contornando a limitação de armazenamento oficial do Zotero nas nuvens.

Essa automação transforma a desorganização de centenas de PDFs mal nomeados em biblioteca estruturada. Arquivos tornam-se localizáveis por nome, navegáveis por pastas temáticas, e acessíveis em qualquer dispositivo conectado à sua nuvem. A organização deixa de ser tarefa manual e passa a ser processo sistemático.

A integração entre Zotero e ferramentas de gestão de conhecimento cria camadas adicionais de valor. O [Obsidian](#), por exemplo, pode importar metadados e notas do Zotero, permitindo que você construa redes de conceitos interligados. Cada artigo torna-se nó em uma rede maior de ideias, conectado a outros artigos, a conceitos teóricos e a seus próprios insights. O [Notion](#) oferece alternativa visual, organizando referências em bancos de dados relacionais que você personaliza conforme a necessidade do projeto.

Um conteúdo básico é abordado em detalhes no trabalho de Thomas (2023), e veremos algumas dessas funcionalidades na aula. No entanto, daremos ênfase em outras funcionalidades do Zotero 7, especialmente sua integração no workflow reprodutível, por exemplo, com o RStudio/Quarto para citações/referências em documentos dinâmicos.

3.7 Preparação para a Aula

! Pré-requisitos

Antes da aula síncrona, certifique-se de completar **todos** os passos abaixo. Um vídeo com instruções detalhadas está disponível na [página de pré-trabalho do curso](#).

Checklist de Preparação:

1. ☒ Realizar o cadastro no [Zotero.org](#)
2. ☒ Instalar o [software Zotero](#) no seu computador
3. ☒ Instalar o [Zotero Connector](#) no seu navegador (Chrome, Firefox, Edge ou

Safari)

4. ☒ Configurar a sincronização entre instalação local e nuvem Zotero
5. ☒ Instalar o “[Add-on Market for Zotero](#)” (gerenciador de plugins)
6. ☒ Instalar o estilo de citação [Better BibTeX](#)

Capítulo 4

Organização de Projetos

4.1 Objetivos de Aprendizagem

🔗 Ao final deste módulo, você será capaz de:

- Compreender a importância da organização padronizada de projetos de pesquisa no contexto da Ciência Aberta
- Reconhecer os seis domínios de boas práticas propostos por Wilson et al. (2017) para pesquisa computacional reprodutível
- Identificar as principais barreiras à reprodutibilidade em projetos de pesquisa
- Aplicar princípios de gerenciamento de dados, incluindo separação entre dados brutos e processados
- Estruturar projetos seguindo protocolos (templates) tal como o [ARTE](#) para uma reprodutibilidade adequada (Rogers & Limongi, 2025)
- Adotar práticas de nomenclatura consistente para arquivos e pastas
- Reconhecer o papel do controle de versão e documentação no ciclo de vida da pesquisa
- Avaliar alternativas de ferramentas e práticas para diferentes níveis de reprodutibilidade

4.2 Contextualização

Essa seção é o elo entre as seções anteriores e as próximas. Aqui, você vai receber algumas dicas de como organizar seus dados, pasta e scripts em um projeto de pesquisa. Talvez você se pergunte: porque eu preciso aprender a organizar meus arquivos e pasta? Já faço isso, do meu jeito, há anos, e nunca tive problemas em entender o que eu faço!

A resposta é simples: não trata somente de você entender e achar que o produto final da sua pesquisa (o artigo) seja suficiente. No contexto da Ciência Aberta (CA) o processo da análise, materiais e métodos, e que outros pesquisadores possam reproduzir seus resultados, são tão importantes quanto o produto final. Nesse sentido, deve haver uma padronização mínima de organização de arquivos, pastas e scripts para que outros pesquisadores possam entender e reproduzir seus achados.

Você pode compartilhar uma pasta compilada da sua pesquisa, via Google Drive ou OneDrive, no seu projeto do Open [Science Framework \(OSF\)](#), ou ainda publicar uma página no [Github](#), mas se a organização dos arquivos não seguir alguma lógica compreensível, de nada adianta compartilhar. É como disponibilizar um caderno com letra ilegível — o registro existe, mas será inacessível para terceiros e, possivelmente, você mesmo no futuro.

O texto desta seção é fundamentado nas “boas práticas” propostas por Wilson et al. (2017). Esse trabalho, implementado em 2024, no contexto do [Software Carpentry](#) e [Data Carpentry](#), estabeleceu um conjunto mínimo de práticas essenciais para pesquisa computacional reprodutível. Esse conjunto de práticas agrega o ferramental necessário para uma reprodutibilidade adequado, conforme espectro delineado por Rogers & Limongi (2025).

A filosofia subjacente a esse framework é pragmática: as práticas propostas não visam a perfeição absoluta, mas sim um equilíbrio viável entre rigor metodológico e aplicabilidade prática (Rogers & Limongi, 2025). São práticas “boas o suficiente” (*good enough*) para tornarem a pesquisa significativamente mais reprodutível sem exigirem expertise avançada em engenharia de software (Wilson et al., 2017). O objetivo é que qualquer pesquisador, independentemente de sua formação técnica, possa implementá-las gradualmente em seus projetos.

Wilson et al. (2017) organizam suas recomendações em seis domínios fundamentais e na aula presencial, exploraremos cada um desses domínios em detalhes, compreendendo como eles se articulam para formar um fluxo de trabalho coerente e adequadamente reprodutível (Rogers & Limongi, 2025). Por ora, apresentaremos uma visão geral dessas práticas, destacando seus princípios centrais e justificativas metodológicas.

4.3 Gerenciamento de Dados

O gerenciamento adequado de dados parte de um princípio fundamental: dados brutos são imutáveis. Uma vez coletados, os dados originais devem ser preservados intactos, sem qualquer modificação. Essa regra, aparentemente simples, é violada com frequência - seja pela tentação de “corrigir um valor manualmente”, seja pela ausência de separação física entre dados originais e processados.

A prática recomendada consiste em armazenar dados brutos em um diretório específico, idealmente configurado como somente leitura (*read-only*). Todas as transformações - limpeza, recodificação, cálculo de variáveis derivadas - devem ser realizadas por meio de scripts, gerando novos arquivos de dados processados. Essa separação não apenas previne perda acidental de informação, mas torna explícita a distinção entre “fatos” (dados coletados) e “interpretações” (dados transformados).

Complementarmente, Wickham (2014) formalizou o conceito de *Tidy Data* - uma estrutura de organização tabular onde cada variável forma uma coluna, cada observação forma uma linha, e cada tipo de unidade observacional forma uma tabela separada. Embora possa parecer uma convenção trivial, essa estrutura resolve inúmeros problemas práticos de análise e integra-se naturalmente com ferramentas modernas de ciência de dados (Wickham et al., 2023). A conversão entre formatos *wide* e *long* não é mera reformatação, mas uma reorganização conceitual que facilita ou dificulta determinadas operações analíticas (Wickham et al., 2023).

Outro aspecto crucial é a preferência por formatos de arquivo abertos e não-proprietários. Arquivos CSV, JSON ou TSV garantem interoperabilidade (podem ser lidos por múltiplas ferramentas), longevidade (independem de software específico) e auditabilidade (podem ser inspecionados em editores de texto simples) (Weidmann, 2023). Formatos proprietários como XLS ou arquivos SPSS, embora convenientes no curto prazo, criam dependências tecnológicas que comprometem o acesso futuro aos dados.

4.4 Código e Software

Na pesquisa computacional contemporânea, o código não é uma ferramenta auxiliar - ele é a especificação precisa do método. Enquanto um artigo pode descrever genericamente “realizamos regressão logística controlando por variáveis demográficas”, o código especifica exatamente qual implementação foi usada, quais parâmetros foram configurados, quais transformações prévias foram aplicadas. Portanto, a legibilidade do código é, fundamentalmente, um requisito metodológico (Pruim et al., 2023).

A adoção de *style guides* - convenções de estilo de código como o [Tidyverse Style Guide](#) - representa uma maturidade da computação científica como disciplina, com suas próprias normas (Pruim et al., 2023). Assim como convenções de citação bibliográfica facilitam a navegação em textos acadêmicos, *style guides* tornam o código previsível e compreensível. Nomenclaturas descritivas (`participant_age` em vez de `x`), uso consistente de espaçamento e indentação, e estruturas organizacionais padronizadas não são “perfeccionismo”, mas práticas de comunicação eficaz (Pruim et al., 2023).

A modularização de análises complexas em scripts separados é outra prática essencial. Em vez de um único script de 2000 linhas, análises devem ser decompostas em unidades funcionais: um script para importação de dados brutos, outro para limpeza, outro para análises exploratórias, outro para modelagem estatística. Cada módulo torna-se testável independentemente, reutilizável em outros projetos, e processado em paralelo em contextos colaborativos.

4.5 Colaboração

Projetos de pesquisa são, crescentemente, empreendimentos colaborativos - seja entre coautores, seja entre o pesquisador presente e seu “eu futuro” (que terá esquecido detalhes após alguns meses). A colaboração efetiva exige documentação que torne projetos autossuficientes, reduzindo dependência de conhecimento tácito.

O arquivo `README.md` funciona como o “cartão de visitas” do projeto (Zandonella Callegher & Massidda, 2022). Deve responder perguntas básicas: O que é este projeto? Qual o objetivo da pesquisa? Como os arquivos estão organizados? Como reproduzir as análises? Quem contatar para dúvidas? Um `README` bem escrito permite que qualquer pessoa - incluindo revisores de periódicos, colaboradores futuros, ou o próprio autor após um tempo - compreenda rapidamente a estrutura e propósito do projeto. Caso haja necessidade, pode-se cogitar um detalhamento mais apurado através de arquivos `README.md`'s por subdiretórios, como proposto pelo [Protocolo TIER 4.0](#).

Além da documentação narrativa, é essencial explicitar questões legais e de atribuição. Um arquivo `LICENSE` define como o trabalho pode ser usado (por exemplo, licenças

MIT, GPL, ou Creative Commons), enquanto um arquivo `CITATION` especifica como o trabalho deve ser creditado.

A documentação técnica do ambiente computacional também é fundamental. Listar explicitamente as versões de software, pacotes e sistema operacional utilizados permite que outros reproduzam o ambiente exato onde as análises foram executadas. Ferramentas como `sessionInfo()` no R ou `pip freeze` no Python automatizam essa documentação, capturando instantâneos do ambiente computacional.

4.6 Organização de Projetos

Estruturas de pastas padronizadas desempenham papel análogo às convenções de estrutura de artigos científicos. Assim como leitores esperam encontrar Introdução, Métodos e Resultados em seções específicas, usuários de projetos de pesquisa beneficiam-se de estruturas previsíveis que facilitam navegação cognitiva.

Uma estrutura mínima recomendada inclui:

- Um diretório `Data/` subdividido em `InputData/` (dados originais, imutáveis) e `AnalysisData/` (dados transformados, gerados por scripts).
- Um diretório `Scripts/` contendo todo o código de análise.
- Um diretório `Results/` ou `Output/` para produtos das análises (tabelas, gráficos).
- A raiz do projeto com os manuscritos e relatórios ou num diretório `Doc/`.
- Um arquivo `README.md` na raiz do projeto.

Protocolos mais formais, como o **TIER 4.0** (*Teaching Integrity in Empirical Research*), detalham estruturas mais granulares, especificando inclusive separação entre scripts de processamento de dados e scripts de análise estatística, ou a inclusão de diretórios específicos para metadados. O **Protocolo TIER**, originalmente desenvolvido no contexto da economia, estabelece quatro princípios fundamentais para reprodutibilidade: *sufficiency* (suficiência de informação), *soup-to-nuts* (completude do início ao fim), *portability* (portabilidade entre sistemas), e *(almost) one-click reproducibility* (reprodução quase automática) (Domingos & Batista, 2021).

Esses protocolos não devem ser entendidos como prescrições rígidas, mas como *templates* adaptáveis a contextos disciplinares e necessidades específicas de cada projeto. Nesse sentido, implementações práticas como o **ARTE** (*Article Reproducibility Template & Environment*) (Rogers & Limongi, 2025) traduzem os princípios do TIER 4.0 para o ecossistema específico de ferramentas R/Quarto (Figura 4.1). O **ARTE** oferece uma estrutura pronta de pastas, scripts iniciais e documentação modelo que operacionalizam as boas práticas discutidas por Limongi & Rogers (2025a) e Limongi & Rogers (2025b), facilitando sua adoção por pesquisadores que trabalham com essas ferramentas. Ao longo do curso, exploraremos como o **ARTE** (Rogers & Limongi, 2025) materializa alguns dos conceitos desse módulo (reprodutibilidade adequada) e ajuda a implementar uma reprodutibilidade máxima para seus projetos.

A nomenclatura consistente de arquivos complementa a organização de pastas. Convenções úteis incluem: uso de prefixos numéricos para indicar ordem de execução (`01-import.R`, `02-clean.R`) (Wickham et al., 2023), datas no formato ISO (`YYYY-MM-DD`) para ordenação cronológica automática, nomes descritivos em vez de genéricos (`clean-survey-data.R` em vez de `script2.R`), e evitação de espaços ou caracteres especiais que causam problemas em linha de comando (Weidmann, 2023).




Figura 4.1: Estrutura de pastas do ARTE (Article Reproducibility Template & Environment). Ilustração disponível em: <https://doi.org/10.5281/zenodo.17496183>

4.7 Controle de Mudanças

Pesquisa é processo iterativo. Análises são refinadas, dados são atualizados, erros são corrigidos, novos testes são explorados. Sem um sistema de controle de versão, essas iterações geram proliferação caótica de arquivos (`analise_final.R`, `analise_final2.R`, `analise_final_FINAL_revisado.R`) e perda de rastreabilidade sobre o que mudou, quando e por quê.

Sistemas de controle de versão como [Git](#), que veremos no próximo módulo, funcionam como um “caderno de laboratório digital”, registrando não apenas o estado atual do projeto, mas todo seu histórico de desenvolvimento (Vuorre & Curley, 2018). Cada *commit* (registro de mudança) captura: o que mudou (diferenças linha por linha), quando mudou (timestamp), quem mudou (autoria) e por que mudou (mensagem descritiva). Essa “memória” permite reversão de erros, compreensão de decisões passadas e atribuição precisa de crédito em colaborações (Gilroy & Kaplan, 2019).

Práticas essenciais incluem realizar commits frequentes e focados (mudanças pequenas e logicamente coesas), escrever mensagens descritivas (“Adiciona análise de robustez ao modelo 3” em vez de “update”), e usar *branches* (ramificações) para experimentar abordagens alternativas sem comprometer a versão estável do projeto (Bryan, 2018).

É importante distinguir controle de versão de backup e arquivamento (Wilson et al., 2017). Backup (cópias redundantes em Google Drive, Dropbox) protege contra perda física de dados. Controle de versão registra histórico de mudanças. Arquivamento de longo prazo (repositórios como Zenodo ou OSF) preserva versões específicas com identificadores persistentes (DOIs) para citação. Essas três práticas são complementares, não substitutas.

4.8 Redação de Manuscritos

A integração entre análise e redação culmina num fluxo de trabalho reprodutível. Abordagens tradicionais - executar análises em software estatístico, copiar manualmente resultados para processador de texto - introduzem múltiplos pontos de falha: erros de transcrição, dessincronia quando análises são refeitas, e falta de transparência sobre a origem exata de cada número reportado (Wilson et al., 2017).

Documentos dinâmicos (RMarkdown, Quarto, Jupyter Notebooks) implementam o conceito de *literate programming* (Pruim et al., 2023; Rodrigues, 2023): intercalar código executável e narrativa em um documento único (Zandonella Callegher & Massidda, 2022). Tabelas e gráficos são gerados automaticamente a partir dos dados, garantindo consistência perfeita entre análise e relatório. Quando dados ou código mudam, o documento inteiro pode ser regenerado, propagando automaticamente todas as atualizações (Zandonella Callegher & Massidda, 2022).

Além da eliminação de erros, essa abordagem torna explícita a conexão entre afirmações e evidências. Cada estatística reportada pode ser rastreada até o código exato que a produziu, permitindo verificação e crítica metodológica em nível de detalhe antes impossível.

4.9 Começando de Onde Você Está

A transição para essas práticas não precisa ser abrupta ou completa. Alessandrini & Byers-Heinlein (2022) enfatizam a adoção incremental: implemente algumas práticas no projeto atual, adicione outras no próximo, e assim progressivamente. Um projeto 50% reprodutível é infinitamente superior a 0% - a perfeição não deve paralisar o progresso.

Para pesquisadores que não vão adotar as ferramentas discutidas nesse curso imediatamente, existem alternativas intermediárias (Limongi & Rogers, 2025b).

- Ferramentas como [JASP](#) e [jamovi](#) oferecem interfaces gráficas, *point-and-click*, para análises estatísticas, que registram as seleções metodológicas com os dados acoplados, e podem ser uma solução inicial para um workflow reprodutível (D. H. Baker et al., 2023).
- Se adicionar o [OpenRefine](#) ao fluxo, a limpeza visual de dados tabulares com log automático das transformações, oferecerá mais transparência às análises (Li et al., 2021).
- [KNIME](#) e [Orange](#) possibilitam construção de pipelines analíticos por meio de diagramas de fluxo, exportáveis para documentação, que também aliadas ao [OpenRefine](#), podem tornar pesquisas baseadas em machine learning mais reprodutíveis.

Mesmo em Excel - ferramenta frequentemente criticada mas amplamente utilizada - é possível adotar práticas mais rigorosas. Broman & Woo (2018) e Hertz & McNeill (2024) estabeleceram diretrizes específicas: uma tabela retangular por aba, cabeçalhos apenas na primeira linha, sem células mescladas, e uso de validação de entrada para prevenir erros, são algumas das principais (Figura 4.2). Essas práticas, embora não alcancem a reprodutibilidade total de scripts, representam alguma melhoria sobre usos sem padronização de planilhas.

Se só for possível adotar três práticas inicialmente, priorize: (1) nunca modificar dados brutos diretamente - sempre criar cópias para transformação; (2) documentar minima-




Figura 4.2: 10 dicas para dados tabulares. Ilustração disponível em: <https://doi.org/10.1371/journal.pcbi.1012604.g001>

mente o que foi feito - um README básico é melhor que nenhum; (3) usar nomenclatura consistente e descritiva para arquivos e pastas. Essas três práticas já colocam o projeto em patamar superior de organização e reprodutibilidade.

4.10 Considerações Finais

As práticas discutidas nesta seção não são imposições externas, mas ferramentas de autodefesa do pesquisador. Protegem contra o próprio esquecimento futuro, contra exigências imprevistas de revisores solicitando dados e código, contra perda de trabalho por problemas técnicos. O investimento inicial em organização retorna dividendos progressivos: redução de erros e retrabalho no curto prazo, colaboração facilitada no médio prazo, e construção de um corpus de trabalho auditável e extensível no longo prazo (Wilson et al., 2017).

A mensagem central é otimista: melhorias são possíveis e acessíveis. Não requerem expertise técnica extraordinária, mas compromisso com práticas sistemáticas (D. H. Baker et al., 2023). Na aula presencial, detalharemos como essas práticas se concretizam em ferramentas, templates e fluxos de trabalho específicos, sempre fornecendo referências para aprofundamento posterior.

4.11 Preparação para a Aula

! Pré-requisitos

Para melhor aproveitamento da aula, recomendamos que você realize os seguintes preparativos:

1. Baixar o Template ARTE

O **ARTE** (*Article Reproducibility Template & Environment*) é um template de projeto que implementa as práticas discutidas neste módulo. Durante o curso, utilizaremos esse template como exemplo prático de estrutura reprodutível.

Como baixar:

1. ☒ Acesse o repositório oficial: <https://github.com/phdpablo/article-template/>
2. ☒ Clique no botão verde **Code** (no canto superior direito) e selecione **Download ZIP**
3. ☒ Extraia o arquivo ZIP em uma pasta de fácil acesso no seu computador.
4. ☒ Familiarize-se com a estrutura de pastas navegando pelos diretórios e lendo os arquivos **README** em cada subpasta.

2. Tidyverse Style Guide

Se familiarize com as convenções do **Tidyverse Style Guide**, pelo menos àquelas concernentes para análises estatísticas. Para direcionar sua leitura, preparamos uma **CheatSheet** que resume a prática diária de um analista/cientista de dados típico.

Apesar de algumas orientações serem as mesmas, excluimos dessa [CheatSheet](#) o tópico relacionado com o desenvolvimento de pacotes.

5. ☒ Dê uma olhada na [CheatSheet](#)

Capítulo 5

Controle de versão

Você¹ em algum grau utiliza um sistema para versionar seu trabalho. Seja ele um simples `Ctrl + Z` ou `Cmd + Z` para desfazer a última ação, ou sistemas mais elaborados, como i) o controle de alterações do seu processador de texto ou ii) o histórico de versões do seu aplicativo de armazenamento nas nuvens (`OneDrive`, `Google Drive` ou `Dropbox`), você já está familiarizado com a ideia de controle de versão. Qual estudante ou pesquisador nunca se deparou com uma situação parecida da Figura 5.1?

No entanto, essas soluções são limitadas e não são adequadas para gerenciar projetos de pesquisa complexos, ou mesmo simples, pois no contexto da Ciência Aberta (CA), falham nos quesitos para reprodutibilidade e transparência. Para isso, é necessário um sistema de controle de versão (VCS) mais robusto, como o `Git`. O `Git` é um VCS distribuído, ou seja, ele armazena o histórico de alterações em um repositório local e remoto, permitindo que você controle as versões de seus arquivos e compartilhe-os com outras pessoas. O `Git` é amplamente utilizado em projetos de desenvolvimento de software, mas também é uma ferramenta valiosa para pesquisadores que desejam gerenciar e compartilhar seus ativos de pesquisa.

Os controles² de versionamento mais simples, como os oferecidos por processadores de

¹A literatura sobre controle de versão, especialmente `Git` e `Github`, é “farta”. Tanto em inglês como em português. Uma pesquisa simples vai achar muitas referências a blogs e textos de profissionais especializados, inclusive, [para os nossos fins](#). No Youtube existem muitos vídeos sobre o tema. Seja o que escrevessemos por aqui, seria de pouca contribuição. Dessa forma, buscamos contextualizar o versionamento de arquivos num empreendimento de pesquisa de nosso dia a dia: um pesquisador com viés quantitativo, envolvido em pesquisas sem pouca colaboração, mas que achou no controle de versão uma solução impar para diversas demandas preconizadas pela Ciência Aberta.

²Como ressaltamos na nota anterior... nossa impressão era que não havia nada para dizer sobre o tema, haja vista a vasta literatura. Desse modo, resolvemos fazer um experimento e nessa nota documentamos para vocês. Dentro do enredo que adotamos para a aula e o roteiro dessa seção, conversamos com o `ChatGPT 4o` (em 2024-06-19) e me apropriamos de alguns de seus argumentos para escrever o resto dessa seção. Claro, com muitos, mas muitos ajustes! Inclusive, a parte final dessa seção, onde conversamos sobre um hipotético workflow (`Gitflow`) para uma colaboração científica é de nossa propriedade. Seguem nossas prompts:

- *Sou pesquisador em ciências sociais aplicadas e estou escrevendo um artigo em que discuto o controle de versão, através do `Git` e `Github`, como um importante aliado das boas práticas da Ciência Aberta. Comecei contextualizando os controles de versionamento mais simples, tais como o controle de alterações de um processador de texto e histórico de versões de soluções de armazenamento nas nuvens. Me indique situações em que esses tipos de versionamentos não*



Figura 5.1: Situação amadora de controle de versão

texto e soluções de armazenamento em nuvem, são insuficientes para um workflow de pesquisa empírica no contexto da CA:

1. Colaboração Extensiva:

- Em projetos que envolvem múltiplos colaboradores, as ferramentas simples de versionamento podem dificultar o rastreamento e a fusão de contribuições de vários pesquisadores. O Git, por outro lado, oferece um sistema robusto de gerenciamento de branches e fusão de código, permitindo uma colaboração mais eficiente e organizada.

2. Rastreamento Detalhado de Mudanças:

- Processadores de texto e armazenamento em nuvem geralmente oferecem um histórico de versões limitado e pouco detalhado. Em contraste, o Git permite um rastreamento minucioso de cada alteração, incluindo o autor e o propósito de cada mudança, facilitando auditorias e revisões.

3. Gerenciamento de Código e Dados:

- Pesquisas empíricas frequentemente envolvem scripts de análise e grandes volumes de dados que necessitam de versionamento. Ferramentas simples de controle de versão não são otimizadas para esses tipos de arquivos, enquanto o Git é projetado para gerenciar código e dados de maneira eficiente, garantindo a integridade e reprodutibilidade das análises.

4. Automação e Integração Contínua:

- Em um ambiente de CA, é crucial automatizar testes e validações para garantir a qualidade e a reprodutibilidade dos resultados. Soluções como GitHub Actions permitem a implementação de pipelines de integração contínua (CI), automatizando testes e outras tarefas, algo que não é possível com controles de versão simples.

5. Documentação e Transparência:

- O Git e o GitHub incentivam a documentação detalhada através de commit messages e issues, promovendo a transparência e o entendimento do progresso e das decisões do projeto. Ferramentas simples de versionamento não oferecem mecanismos equivalentes para documentar o processo de desenvolvimento de forma estruturada.

6. Resolução de Conflitos:

- Em projetos complexos, conflitos de versão são inevitáveis. Sistemas simples de versionamento podem não oferecer ferramentas adequadas para resolver esses conflitos de maneira eficiente. O Git proporciona ferramentas avançadas

atendem um fluxo de trabalho de uma pesquisa empírica no contexto da ciência aberta.

Continuando a conversa...

- *No meu enredo argumento que o Git e Github são “coisas” diferentes e o pesquisador, se quiser, desenvolve seu workflow apenas localmente com o Git. Compare o Git e Github em termos de soluções propostas para o versionamento para eu apresentar como exemplo de meus argumentos.*

Continuando a conversa...

- *Certo, gostei da comparação, mas gostaria que desenvolvesse sua resposta na forma de um texto descritivo e não na forma de bullets points.*

Continuando a conversa...

- *Certo, era exatamente isso que precisava para meus argumentos nesse ponto do artigo. No entanto, desejo finalizar com o seguinte enredo: o Git/Github são preparados para projetos muito complexos (cite cases para exemplificar esse argumento), mas suas funcionalidades também podem atender projetos de pesquisas mais simples que envolvam três pesquisadores ou um único pesquisador. Preciso de sua ajuda para desenvolver esses argumentos sem você repetir argumentos que já apresentou para mim nessa conversa.*

de merge e resolução de conflitos, minimizando o risco de perda de dados ou inconsistências.

7. Histórico Completo e Analítico:

- Ferramentas simples geralmente mantêm um histórico limitado, focado em versões específicas de documentos. O Git mantém um histórico completo e analítico de todas as mudanças, permitindo análises detalhadas do desenvolvimento do projeto ao longo do tempo.

Git e GitHub são ferramentas intimamente relacionadas, mas oferecem soluções distintas para o versionamento, atendendo a diferentes necessidades dos pesquisadores.

Git é um sistema de controle de versão distribuído que permite aos usuários rastrear alterações em arquivos e coordenar o trabalho em projetos colaborativos. Uma das principais vantagens do Git é a capacidade de operar de forma totalmente local. Isso significa que os pesquisadores podem manter um histórico completo de alterações em seus arquivos sem a necessidade de conexão com a internet ou de um servidor externo. Essa funcionalidade é particularmente útil para aqueles que preferem manter seus dados em um ambiente controlado e privado.

Além disso, Git oferece funcionalidades avançadas de branching e merging. Isso permite que diferentes linhas de trabalho sejam desenvolvidas simultaneamente e depois combinadas de maneira controlada. Essa flexibilidade é essencial para experimentações e desenvolvimentos paralelos, comuns em projetos de pesquisa. O rastreamento detalhado é outra característica fundamental do Git. Cada commit no sistema é identificado de forma única e inclui metadados sobre quem fez a alteração e uma mensagem descritiva, permitindo um histórico minucioso das mudanças. Caso seja necessário, Git permite reverter para estados anteriores do projeto, recuperando versões passadas sem perder o histórico de alterações. Como um sistema distribuído, Git realiza operações de controle de versão localmente, o que resulta em um desempenho rápido e eficiente, sem depender da latência de rede.

Por outro lado, GitHub é uma plataforma baseada na web que utiliza o Git como backend e adiciona funcionalidades colaborativas e de gerenciamento de projetos. Uma das maiores vantagens do GitHub é a hospedagem de repositórios Git, permitindo que os pesquisadores façam backup de seus projetos na nuvem e colaborem com outros usuários de qualquer lugar do mundo. Isso facilita a colaboração extensiva, um aspecto crucial no contexto da CA.

GitHub também fornece ferramentas como pull requests e reviews de código, que simplificam a colaboração entre diferentes pesquisadores. Essas ferramentas permitem que propostas de mudanças sejam discutidas, revisadas e integradas de forma estruturada, promovendo um fluxo de trabalho colaborativo e transparente. Além disso, GitHub Actions oferece suporte à automação de testes, builds e outras tarefas, garantindo que cada alteração seja verificada e validada automaticamente. Essa funcionalidade é vital para assegurar a reprodutibilidade e a qualidade do projeto, aspectos centrais da CA.

A plataforma GitHub também se destaca em termos de documentação e comunicação. Issues, wikis e páginas de projetos proporcionam meios para uma documentação detalhada, rastreamento de problemas e comunicação eficiente entre os membros da equipe. O controle de acesso e permissões é outro ponto forte do GitHub, permitindo que os gestores de projetos configurem quem pode fazer alterações ou revisar o código, assegurando a integridade do trabalho.

Além de todas essas funcionalidades, a hospedagem de projetos no GitHub aumenta significativamente a visibilidade da pesquisa. Isso facilita a disseminação de resultados e a colaboração com a comunidade científica global, promovendo uma cultura de transparência e compartilhamento de conhecimento.

Em resumo, enquanto o Git fornece uma solução robusta para controle de versão local, ideal para quem necessita de um ambiente privado e eficiente, o GitHub expande essas capacidades com ferramentas que promovem a colaboração, automação, documentação e visibilidade pública. No contexto da CA, o GitHub se alinha melhor com os princípios de transparência, colaboração e reprodutibilidade, oferecendo um conjunto de ferramentas que suportam e amplificam as boas práticas da pesquisa científica.

Git e GitHub têm sido fundamentais em projetos de grande escala, como o desenvolvimento do kernel do Linux e projetos de software de código aberto como o TensorFlow, mantido pelo Google. Estes projetos envolvem milhares de colaboradores ao redor do mundo, exigindo um sistema robusto de controle de versão que possa lidar com uma vasta quantidade de alterações simultâneas, fusões complexas e um alto nível de coordenação e colaboração. A capacidade do Git de gerenciar branches de forma eficiente e a integração contínua proporcionada pelo GitHub são elementos cruciais para o sucesso desses projetos. A Figura 5.2 ilustra um diagrama hipotético do fluxo de trabalho em um ambiente de desenvolvimento de software típico, com diversos ramos, e como a complexidade de gerenciamento de versões, apesar de tratada pelo Git e GitHub, pode escalar.




Figura 5.2: Diagrama GitFlow hipotético num ambiente de desenvolvimento de software típico

No entanto, o Git/Github são igualmente valiosos para projetos de menor escala. Em um projeto de pesquisa envolvendo três pesquisadores, Git e GitHub facilitam a colaboração ao permitir que cada pesquisador trabalhe em diferentes partes do projeto simultaneamente. Eles podem criar branches individuais para testar novas hipóteses ou desenvolver partes do projeto de forma independente. Quando uma nova contribuição está pronta, ela pode ser integrada ao projeto principal através de um pull request

no GitHub, permitindo uma revisão por pares antes da fusão. Isso não só mantém a qualidade do trabalho como também documenta o processo de desenvolvimento de maneira transparente.

A Figura 5.3 ilustra um Gitflow hipotético para uma colaboração científica envolvendo três autores. Note que cada autor tem seu próprio branch de produção, que é integrado ao branch principal através de pull requests, administrado pelo autor principal. Essa estrutura permite que cada autor trabalhe de forma independente, mantendo um histórico detalhado de suas contribuições e facilitando a revisão e a fusão de alterações. Com apenas três branches, o gerenciamento dessa hipotética pesquisa não seria tão complexo com o Git e GitHub.




Figura 5.3: Um fluxo de trabalho hipotético do Git para uma colaboração científica envolvendo três autores. Cada círculo representa um commit e as cores indicam commits específicos do autor. Setas bidirecionais indicam uma sincronização (um push e pull na terminologia Git). Setas unidirecionais indicam uma atualização de uma ramificação para outra. As setas horizontais indicam o desenvolvimento ao longo de um ramo específico. Ilustração disponível em: <<https://doi.org/10.5281/zenodo.12165926>>.

Para um único pesquisador, o Git oferece uma maneira eficaz de versionar seu trabalho, mantendo um histórico detalhado de todas as alterações. Isso pode ser especialmente útil para rastrear o progresso ao longo do tempo, revertendo alterações se necessário e experimentando diferentes abordagens sem o risco de perder trabalho anterior. Além disso, o GitHub fornece um backup seguro na nuvem, garantindo que os dados estejam protegidos contra perda.

A Figura 5.4 ilustra um Gitflow hipotético para um único pesquisador. Neste caso, o pesquisador mantém um branch principal para o desenvolvimento do projeto e cria branches individuais para experimentos ou novas ideias. Cada commit é documentado com uma mensagem descritiva, permitindo que o pesquisador rastreie o progresso e o propósito de cada alteração. Esse processo garante que o projeto seja desenvolvido de forma estruturada e transparente, com um histórico detalhado de todas as contribuições, que podem ser acompanhadas, revisadas e auditadas por qualquer pessoa interessada, se o repositório remoto for público.

Por outro lado, um pesquisador pode optar por tornar público seu trabalho (dados, materiais e histórico de mudanças) somente quando for submeter o artigo para publicação, como podemos ver na Figura 5.5. Essa figura ilustra um workflow em que o pesquisador desenvolveu seu trabalho localmente, fazendo uso do Git para seu controle de versões, e apenas quando da necessidade de tornar público, vinculou o repositório local com o




Figura 5.4: Um fluxo de trabalho hipotético do Git para a execução de uma pesquisa solo. Cada círculo representa um commit específico do autor. Setas bidirecionais indicam uma sincronização (um push ou pull na terminologia Git). Setas unidirecionais indicam uma atualização de uma ramificação para outra. As setas horizontais indicam o desenvolvimento ao longo de um ramo específico. Nesse fluxo de trabalho o autor optou por sincronizar o repositório local com o repositório remoto (Github) desde as etapas iniciais da pesquisa. Nessa perspectiva o repositório remoto funciona como um armazenamento de backup, e se público, para tornar a evolução do trabalho do pesquisador disponível para quem deseja acompanhar. Ilustração disponível em: <<https://doi.org/10.5281/zenodo.12165926>>

repositório remoto.

Embora sejam projetadas para lidar com projetos extremamente complexos, as funcionalidades do Git/Github também se adaptam perfeitamente a projetos de pesquisa mais simples, seja com número pequeno de pesquisadores ou mesmo com um único pesquisador.

i *Curating Research Assets: A Tutorial on the Git Version Control System*

Como uma tentativa de enfrentar os desafios da reprodutibilidade na ciência empírica, um fator específico que se destaca é a forma como os pesquisadores organizam, curam, compartilham e colaboram em seus ativos de pesquisa (Vuorre & Curley, 2018). Para mitigar essas dificuldades, sistemas de controle de versão (VCS), como o Git, têm sido amplamente adotados, uma vez que facilitam o acompanhamento das mudanças, versões e colaboração em projetos científicos.

O Git, inicialmente desenvolvido para a escrita colaborativa de código, agora é amplamente utilizado em diversas áreas além da ciência da computação. Isso se deve à sua capacidade de tratar qualquer texto digitado em um computador – manuscritos, scripts de análise estatística, código-fonte de experimentos computadorizados e até arquivos de dados – como código, gerenciando assim múltiplas versões e autores sem introduzir erros (Vuorre & Curley, 2018).

Ao trabalhar com Git, os usuários podem salvar versões intermediárias de seus arquivos no disco rígido e, subsequentemente, no histórico do VCS. Esse processo permite que todas as alterações sejam monitoradas e revertidas quando necessário. A instalação do Git e sua integração com ferramentas como o RStudio proporcionam uma interface gráfica amigável para gerenciar repositórios locais e remotos,




Figura 5.5: Um fluxo de trabalho hipotético do Git para a execução de uma pesquisa solo. Cada círculo representa um commit específico do autor. Setas bidirecionais indicam uma sincronização (um push ou pull na terminologia Git). Setas unidirecionais indicam uma atualização de uma ramificação para outra. As setas horizontais indicam o desenvolvimento ao longo de um ramo específico. Nesse fluxo de trabalho o autor optou por sincronizar o repositório local com o repositório remoto (Github) somente quando finalizou o artigo. Nessa perspectiva o repositório remoto só faz sentido se para publicar os dados, materiais da pesquisa e o histórico de mudanças, pois como backup, o autor pode utilizar um serviço de armazenamento nas nuvens (OneDrive, GoogleDrive, DropBox, etc.). Ilustração disponível em: <<https://doi.org/10.5281/zenodo.12165926>>

facilitando o controle de versões e a colaboração (Vuorre & Curley, 2018).

A introdução do Git desde o início de um projeto científico torna o fluxo de trabalho mais eficiente e menos trabalhoso do que tentar incorporar práticas de reprodutibilidade após a conclusão do projeto. A organização clara de arquivos e pastas, seguindo diretrizes como as recomendações do Project TIER, é uma etapa inicial crucial para garantir a reprodutibilidade (Vuorre & Curley, 2018).

O GitHub, uma plataforma online para hospedagem de repositórios Git, permite a criação de repositórios centralizados que facilitam o trabalho colaborativo. Os usuários podem clonar esses repositórios para suas máquinas locais, fazer mudanças e enviar (push) essas alterações de volta para o repositório central, assim como obter (pull) as alterações feitas por outros colaboradores. Esse fluxo de trabalho centralizado evita problemas de sobrescrita de arquivos e mantém um histórico detalhado das contribuições de cada membro da equipe (Vuorre & Curley, 2018).

No entanto, é importante notar que o Git não é a única solução para colaboração e curadoria de materiais de pesquisa. Embora plataformas como Google Docs e Dropbox ofereçam funcionalidades de colaboração em tempo real e acesso ao histórico de arquivos, o Git proporciona vantagens significativas para projetos mais complexos. Ele permite o gerenciamento simultâneo de múltiplos componentes de um projeto, como dados, scripts de análise e manuscritos, reduzindo a possibilidade de erros associados ao uso de versões desatualizadas de arquivos (Vuorre & Curley, 2018).

Além disso, a utilização do Git com o RStudio é particularmente atrativa para psicólogos, pois o ambiente integrado de desenvolvimento (IDE) do RStudio, juntamente com os pacotes R Markdown (e Quarto) e knitr, oferece uma solução

completa para gestão de projetos, análise de dados e preparação de manuscritos (Vuorre & Curley, 2018). A integração com serviços como Zenodo, que permite a atribuição de DOIs (identificadores digitais) aos repositórios do GitHub, também facilita a citação dos materiais de pesquisa (Vuorre & Curley, 2018).

Em suma, a adoção de sistemas de controle de versão como o Git, especialmente quando integrados a plataformas como o RStudio e o GitHub, proporciona uma solução elegante para os desafios de curadoria, compartilhamento e colaboração em ativos de pesquisa, contribuindo significativamente para a melhoria da reprodutibilidade na ciência.

i *Furthering Open Science in Behavior Analysis: An Introduction and Tutorial for Using GitHub in Research*

Este tutorial (Gilroy & Kaplan, 2019) revisa as diretrizes de Práticas Transparentes e Abertas fornecidas pela Open Science Foundation e explora como os pesquisadores podem utilizar a transparência do GitHub em suas pesquisas. Ele exemplifica como os pesquisadores podem usar o GitHub para compartilhar código, dados e materiais de pesquisa, permitindo a inspeção e replicação por parte de revisores e outros pesquisadores através do **Github Desktop**.

As implicações do aumento da demanda por transparência e métodos estatísticos modernos são discutidas, e plataformas como o GitHub são revisadas como uma forma de apoiar a pesquisa transparente.

A “crise de reprodutibilidade” é mencionada, referindo-se às tentativas malsucedidas de replicar efeitos estatisticamente significativos relatados em estudos psicológicos. As pressões para publicar em revistas prestigiadas e obter financiamento são destacadas como fatores que contribuem para a presença de práticas questionáveis de pesquisa em várias disciplinas, incluindo psicologia.

A importância da transparência e da abertura é enfatizada como uma maneira de enfrentar essas questões. As diretrizes TOP (Transparent and Open Practices) são mencionadas, estabelecendo padrões para a transparência em citações, dados, análises, materiais de pesquisa, pré-registros e suporte para replicações. No entanto, é observado que poucos estudos utilizam o pré-registro dos métodos e planos analíticos.

O OSF e o GitHub são apresentados como plataformas que oferecem recursos relacionados à pesquisa, como pré-registro e arquivamento público. O GitHub é descrito como um serviço amplamente utilizado para arquivar e gerenciar projetos de pesquisa. O controle de versão baseado em Git é destacado como uma ferramenta de arquivamento robusta para pesquisa analítica atual e futura. A importância de compartilhar o código-fonte, dados e materiais do estudo é mencionada, permitindo a inspeção e replicação por parte de revisores e outros pesquisadores. O foco do tutorial é na execução do Github Desktop, uma interface gráfica para o Git (Git Client), que facilita a colaboração e o controle de versão.

A configuração adequada da máquina local é mencionada como necessária para executar os programas estatísticos e scripts de análise. O processo de bifurcação de um repositório no GitHub é explicado, assim como a importância de plataformas

como o GitHub para fornecer maior visibilidade e facilitar a colaboração na pesquisa. Ao arquivar materiais de estudo publicamente no GitHub, os pesquisadores têm a oportunidade de interagir com os proprietários do repositório. Por fim, a transparência e a ciência aberta são reconhecidas, mas também representam desafios para a comunidade científica.

Capítulo 6

Documentos Reprodutíveis

Você pode ter chegado até aqui e pensado: esse negócio de reprodutibilidade e transparência não é para mim! Eu sou um pesquisador qualitativo e não tenho nada a ver com essas “coisas” de código e programação. Talvez a aula de Git te assustou! Se você pensou isso, eu tenho uma boa notícia: você está enganado! A reprodutibilidade e a transparência são para todos os pesquisadores, independentemente da abordagem metodológica que você adote. E, para provar isso, eu vou mostrar como você pode usar o [Quarto](#), através do RStudio, para organizar e documentar o seu projeto de pesquisa, mesmo que qualitativo.

De qualquer forma, como refletimos até a penúltima seção, talvez dominar a plataforma [OSF](#), o [Zotero](#) e um protocolo rígido de organização de dados e projetos (vide [Protocolo TIER](#), por exemplo) seja suficiente para você. A integração dessas soluções com outras que você já utiliza no dia a dia (armazenamento nas nuvens, processadores de texto, softwares específicos de análise qualitativa, etc) já lhe capacita para ter um projeto de pesquisa organizado e documentado com boas práticas da Ciência Aberta (CA).

Ou talvez você, mesmo sendo um pesquisador que utiliza métodos quantitativos, empregue o mesmo argumento: eu nem gosto dessas “coisas” de código e programação. Prefiro soluções *point-and-click*, tal como o SPSS e Stata! Tenho uma boa notícia para você também: existem dois outros softwares com essa funcionalidade e boa compatibilidade com os princípios da CA: o [JASP](#) e o [Jamovi](#).

Primeiramente, os dois são softwares gratuitos e de código aberto. Segundo, ambos possuem uma interface gráfica amigável e intuitiva, que permite a execução de análises estatísticas sem a necessidade de programação. Terceiro, em ambos os outputs das análises ficam disponíveis, quando salvos, no mesmo arquivo da base de dados. Através da tela dos outputs o usuário pode editar os títulos, adicionar notas, copiar as citações dos pacotes do R que estão sendo utilizados, copiar as análises para edição em outros softwares e duplicar as análises (Rogers, 2024). Essas últimas funcionalidades são extremamente úteis para a reprodutibilidade.

No entanto, ambos os softwares ainda são recentes e ainda não englobam todas as análises dos softwares mais tradicionais, como o SPSS e o Stata. Eles não possuem a mesma quantidade de pacotes do R, o que pode ser um limitante para pesquisadores que necessitam de análises mais complexas. Os dois carecem de funcionalidades para

a organização e estruturação dos dados, ficando o ETL (*Extraction, Transform and Loading*) a cargo de outros softwares, colocando dificuldade ao controle de versões. De qualquer forma, acreditamos que a tendência é que esses softwares evoluam e se tornem mais populares, principalmente entre pesquisadores que não têm familiaridade com a programação.

De qualquer forma, o foco dessa seção é mostrar como você pode usar o Quarto para documentos dinâmicos, independente se você é um pesquisador qualitativo ou quantitativo, que prefere ou não usar recursos *point-and-click*. O Quarto é uma ferramenta de código aberto que permite a criação de documentos dinâmicos, tal como o R Markdown, mas com uma interface gráfica mais amigável e intuitiva. Através do Quarto, você pode criar documentos dinâmicos com texto, imagens, tabelas, gráficos, equações, referências bibliográficas, etc. E, o melhor de tudo, você pode fazer isso com pouca necessidade de programação, caso seu interesse seja apenas utilizar o Quarto como editor de documentos dinâmicos, ou seja, somente para escrever e organizar seu projeto de pesquisa.

O Quarto é integrado ao RStudio, o que facilita a sua utilização por pesquisadores que já estão familiarizados com o R. Através do RStudio, você pode criar, editar e renderizar documentos dinâmicos em Quarto. Entretanto, o Quarto integra várias linguagens de programação (R, Python, Julia e Observable). No RStudio, os usuários escrevem seus códigos e análises em R e Python, e o Quarto processa esse conteúdo e exporta o resultado em diferentes formatos, como HTML, PDF e DOCX, facilitando a disseminação e o compartilhamento do trabalho em múltiplas plataformas, como é ilustrado na Figura 6.1.




Figura 6.1: Integração do Quarto

i O que o ChatGPT 4o nos diz sobre a Figura 6.1?

1. Múltiplas Linguagens de Programação:

- No lado esquerdo da imagem, temos ícones representando várias linguagens de programação e plataformas suportadas pelo Quarto, incluindo:

- **R**: Linguagem popular para análise estatística e visualização de dados.
 - **Python**: Linguagem versátil utilizada em ciência de dados, aprendizado de máquina, entre outras áreas.
 - **Julia**: Linguagem de programação de alto desempenho para computação técnica.
 - **Observable**: Plataforma para criar visualizações de dados interativas.
 - O texto “+ more!” indica que o Quarto suporta outras linguagens além das mencionadas.
2. **Quarto**:
- No centro da imagem, há um círculo azul com o logo do Quarto, representando a ferramenta em si.
 - Quarto atua como uma plataforma de integração, permitindo que os usuários combinem códigos de diferentes linguagens e criem documentos ricos em conteúdo.
3. **Exportação para Diversos Formatos**:
- À direita, a imagem mostra os diferentes formatos para os quais o Quarto pode exportar:
 - **HTML**: Para visualização web.
 - **PDF**: Para documentos portáteis e impressos.
 - **Word (DOCX)**: Para edição e compartilhamento em formato de texto.
 - O texto “+ more!” indica que o Quarto pode exportar para outros formatos além dos ilustrados.

A Figura 6.2 explica o fluxo de trabalho de criação e publicação de documentos com Quarto de forma mais analítica. Inicia-se com um arquivo `.qmd` que é processado por ferramentas como knitr ou Jupyter para gerar um arquivo Markdown. Esse arquivo Markdown é então convertido pelo Pandoc para os formatos finais de saída, permitindo uma ampla flexibilidade na distribuição do conteúdo.




Figura 6.2: Workflow analítico do Quarto

i O que o ChatGPT 4o nos diz sobre a Figura 6.2?

1. **Documentos Quarto (qmd):**

- O processo começa com um documento no formato Quarto Markdown (qmd), que é um arquivo que pode conter texto, código e outros elementos dinâmicos.

2. **Processamento com knitr ou Jupyter:**

- A próxima etapa do fluxo envolve a escolha de um processador para converter o conteúdo do documento qmd:
 - **knitr**: Um pacote no R que permite a integração de código e texto, frequentemente usado para documentos R Markdown.
 - **Jupyter**: Um ambiente interativo de notebooks que suporta várias linguagens de programação, como Python.
- A imagem mostra que o documento **qmd** pode ser processado por qualquer uma dessas ferramentas, resultando em um documento Markdown intermediário (md).

3. **Markdown (md):**

- Após o processamento inicial, o documento é convertido em um arquivo Markdown padrão (md). Este arquivo contém o texto e as marcações, mas ainda precisa ser convertido para o formato de saída final desejado.

4. **Conversão com Pandoc:**

- O arquivo Markdown é então processado pelo Pandoc, uma ferramenta poderosa de conversão de documentos. Pandoc é capaz de transformar arquivos Markdown em uma variedade de formatos de saída.
- A imagem retrata o Pandoc como uma máquina que processa o documento md e o converte para os formatos finais.

5. **Formatos de Saída:**

- O resultado final do processo pode ser exportado para diversos formatos, conforme ilustrado na imagem:
 - **HTML**: Para publicação na web.
 - **PDF**: Para distribuição de documentos portáteis e impressos.
 - **Word (DOCX)**: Para edição e compartilhamento em formato de texto.
- Novamente, o texto “+ more!” indica que o Pandoc pode converter os documentos para outros formatos além dos mencionados.

Se quisermos pensar o fluxo de trabalho com Quarto com enfoque específico nos passos de criação e renderização de um documento, oferecendo um guia passo a passo um pouco mais sintético, podemos considerar a ilustração da Figura 6.3. Essa figura ilustra de maneira didática e sequencial as etapas que um usuário deve seguir, desde a criação do arquivo até a renderização do documento final em múltiplos formatos. Nessa imagem destacamos explicitamente a incorporação e a renderização de código R, que é software mais utilizado por pesquisadores.

i O que o ChatGPT 4o nos diz sobre a Figura 6.3?

1. **Open (Abrir):**

- **Passo**: Abrir um novo arquivo de tipo Quarto Document com a extensão




Figura 6.3: Workflow sintético do Quarto

- **Detalhe:** Este passo inicial foca na criação do arquivo fonte que será usado para todo o fluxo de trabalho subsequente.
- 2. **Write (Escrever):**
 - **Passo:** Escrever o conteúdo usando a sintaxe compatível com o Quarto.
 - **Detalhe:** Este passo enfatiza a fase de escrita, onde o usuário insere o texto e a estrutura básica do documento.
- 3. **Embed (Incorporar):**
 - **Passo:** Incorporar código R que gera saída a ser incluída no relatório.
 - **Detalhe:** Este passo mostra como os usuários podem integrar blocos de código no documento. Aqui, o exemplo específico de código R (`hist(x)`) é dado, o que ilustra a capacidade do Quarto de processar e renderizar código dinâmico.
- 4. **Render (Renderizar):**
 - **Passo:** Substituir o código R pela sua saída e transformar o relatório em uma apresentação de slides, PDF, HTML ou arquivo MS Word.
 - **Detalhe:** Este passo final detalha o processo de renderização, onde o Quarto processa o código embutido, gera os resultados e cria o documento final no formato desejado.

E por fim, se desejamos melhorar nosso entendimento de como utilizar o Quarto no contexto de uma pesquisa científica empírica, a Figura 6.4 enfatiza a integração da narrativa científica, código e dados, culminando na publicação de resultados. Esse fluxo de trabalho é ideal para pesquisas que requerem transparência e reprodutibilidade, permitindo que outros pesquisadores verifiquem e repliquem os resultados. A integração da narrativa científica, código e dados em um único documento facilita a manutenção e a atualização do trabalho. Além disso, a capacidade de publicar tanto em formatos estáticos quanto dinâmicos amplia o alcance e o impacto da pesquisa, atendendo a diferentes necessidades de distribuição e engajamento do público.

i O que o ChatGPT 4o nos diz sobre a Figura 6.4?

1. **Narrativa e Código (Narrative story, Code, Data):**
 - **Narrativa:** A história ou o contexto da pesquisa, incluindo introdução, metodologia, resultados e discussão, é escrita em texto plano.
 - **Código:** O código utilizado para análises, simulações ou geração de




Figura 6.4: Workflow de uma pesquisa empírica utilizando Quarto

figuras e tabelas. Esse código pode ser gerido através de controle de versão, garantindo rastreabilidade e reprodutibilidade.

- **Dados:** Os dados brutos ou processados usados na pesquisa, que também podem estar sob controle de versão.
2. **Edição de Texto (Text editing):**
 - **Edição de Texto Plano:** A narrativa e o código são combinados em um editor de texto plano, formando um documento integral que contém a descrição da pesquisa e os scripts de análise.
 3. **Execução (Execute):**
 - **Executar Código:** O código embutido no documento é executado, gerando saídas como gráficos, tabelas e resultados estatísticos que são automaticamente incorporados ao documento.
 4. **Publicação (Publish):**
 - **Folha de Estilo (Style sheet):** Um template pode ser aplicado para formatar o documento de acordo com as normas de publicação ou preferências estilísticas.
 - **Pandoc:** Ferramenta usada para converter o documento em vários formatos de saída.
 - **Resultados:**
 - **Artigo PDF Estático (Scholarly PDF article):** Um documento PDF pronto para submissão a revistas acadêmicas ou para distribuição formal. É um formato estático, onde o conteúdo é fixo e não interativo.
 - **Website Dinâmico (Website):** Um site interativo onde os leitores podem interagir com gráficos e visualizações de dados. Este formato permite uma experiência de leitura mais envolvente.
 5. **Renderização (quarto render):**
 - **Comando de Renderização:** O comando `quarto render` é utilizado para processar o documento (projeto) e gerar as versões finais nos formatos desejados.

Fluxo de Trabalho de uma Pesquisa Empírica Hipotética:

1. **Início:**

- Começa com a escrita da narrativa da pesquisa e o desenvolvimento do código para análise dos dados.
 - Os dados são coletados e preparados, podendo ser versões controladas para assegurar integridade e reprodutibilidade.
2. **Edição e Integração:**
 - O texto da narrativa, o código e os dados são integrados em um único documento Quarto (.qmd), utilizando um editor de texto plano.
 3. **Execução de Análises:**
 - O código é executado dentro do documento, gerando os resultados das análises que são automaticamente incorporados à narrativa.
 4. **Preparação para Publicação:**
 - Aplicação de um template para garantir que o documento final esteja formatado corretamente.
 - Uso do Pandoc para converter o documento em formatos de saída, tanto estáticos (PDF) quanto dinâmicos (site web interativo).
 5. **Publicação e Distribuição:**
 - **PDF Estático:** Criado para ser submetido a revistas científicas ou compartilhado formalmente.
 - **Website Dinâmico:** Disponibilizado para o público, permitindo interação com os dados e gráficos, promovendo maior engajamento e entendimento dos resultados da pesquisa.

Capítulo 7

Controle de Ambiente

Imagine a seguinte situação: você publicou uma pesquisa quantitativa, disponibilizando o código e os dados para que outros pesquisadores possam reproduzir os resultados. Um pesquisador entra em contato e diz que não conseguiu replicar seus resultados. Você como bom mineiro, responde: “Uai, comigo funcionou!”. Prestativo como é sugere para o pesquisador, da Polônia, que venha até sua casa para que você possa ajudá-lo, e aproveitar para tomar um café e comer um pão de queijo. O pesquisador, educadamente, responde que não pode ir até sua casa, pois está do outro lado do mundo.

Então, prestativo como é, você sugere que vai enviar uma imagem do seu HD para ele. O pesquisador, educadamente, responde que não pode aceitar, pois o arquivo da imagem é muito grande e ele não tem espaço suficiente para armazenar a imagem. Além do mais, ele não entende muito bem (e não tem!) a infraestrutura para poder acessar seu HD. Inclusive, ele utiliza um sistema operacional (e estrutura de hardware) diferente do seu.

Pois bem, essa situação poderia ser a única saída alguns anos atrás. No entanto, hoje em dia, com os serviços de armazenamento em nuvem, as soluções de virtualização (máquinas virtuais), containers e controle de ambiente, é possível compartilhar o ambiente de desenvolvimento de forma mais simples.

Máquinas virtuais (VM) são ambientes que emulam um sistema operacional (SO) completo sobre um hardware físico, permitindo a execução de múltiplos sistemas operacionais em uma única máquina. Elas oferecem um alto nível de isolamento e controle, pois cada VM inclui seu próprio SO, bibliotecas e aplicativos. As VMs podem ser classificadas em dois tipos: *Type 1 Hypervisor* e *Type 2 Hypervisor*. Tipo 1 Hypervisor roda diretamente sobre o hardware, gerenciando várias VMs sem a necessidade de um SO subjacente, o que proporciona melhor desempenho e eficiência. Já o *Type 2 Hypervisor* roda sobre um SO existente, sendo menos eficiente, mas mais fácil de configurar e utilizar em ambientes de desktop Figura 7.1.

Exemplos de soluções de virtualização Tipo 1 podemos elencar:

- **VMware ESXi**: Uma solução comercial amplamente utilizada em ambientes corporativos para criar e gerenciar VMs. Oferece alta performance e várias funcionalidades avançadas de gerenciamento.
- **Microsoft Hyper-V**: Integrado ao Windows, é uma solução comercial que também




Figura 7.1: Soluções para controle do ambiente de desenvolvimento. Ilustração disponível em: <https://doi.org/10.5281/zenodo.12521134>

pode ser usada gratuitamente com recursos limitados. Hyper-V é amplamente utilizado em ambientes Windows.

- **Xen:** Uma solução open-source popular em ambientes de nuvem, como o Amazon Web Services (AWS). Xen é altamente eficiente e suportado por várias distribuições Linux.

Exemplos de Tipo 2 incluem:

- **VMware Workstation:** Uma solução comercial usada principalmente em desktops e laptops para executar múltiplos SOs. VMware Workstation é conhecido pela sua estabilidade e facilidade de uso. Recentemente ele passou a ser gratuito.
- **Oracle VirtualBox:** Uma solução open-source amplamente utilizada para virtualização em desktops. VirtualBox é gratuito e suporta uma vasta gama de SOs convidados.
- **Parallels Desktop:** Uma solução comercial popular entre usuários de Mac, permitindo que eles rodem Windows, Linux e outros no macOS de maneira integrada.

As vantagens das VMs incluem um alto isolamento e segurança, além da flexibilidade para rodar diferentes SOs. No entanto, elas consomem muitos recursos, como CPU, memória e armazenamento, e as imagens são grandes e difíceis de compartilhar (Clyburne-Sherin et al., 2019). Nesse sentido, para a reprodutibilidade das pesquisas empíricas no âmbito da Ciência Aberta o emprego de VMs pode ser impraticável. Para nosso dia a dia enquanto pesquisadores e professores pode ser uma ferramenta extremamente útil. **Esse curso está organizado dentro de uma VM.**

Por outro lado, os containers são uma tecnologia de virtualização a nível de SO, mais leve que as VMs, que compartilham o mesmo kernel do SO hospedeiro, mas ainda assim oferecem isolamento para aplicações. **Docker**, **Kubernetes** e **OpenShift** são uma das ferramentas mais populares para criar e gerenciar containers. Ao contrário das VMs, os containers contêm apenas a aplicação e suas dependências, compartilhando o kernel do SO hospedeiro. Isso torna os containers mais leves e eficientes em termos de recursos, e ainda são rápidos na inicialização e execução. Além disso, são fáceis de distribuir e compartilhar (Clyburne-Sherin et al., 2019).

Enquanto as VMs oferecem maior isolamento, os containers têm menor consumo de recursos e são mais práticos para desenvolvimento e distribuição de aplicações. No entanto, eles compartilham o kernel do SO hospedeiro, o que resulta em menor isolamento comparado às VMs. Os contêineres estão ganhando força na pesquisa científica (Moreau et al., 2023) e o Docker despontado como uma das soluções mais populares para controle de ambiente em pesquisas empíricas quantitativas (Wiebels & Moreau, 2021).

Por fim, temos as ferramentas de controle de ambiente como **Conda** e **renv**, que ajudam a gerenciar pacotes e dependências em ambientes de desenvolvimento, sem a necessidade de virtualização. Conda, por exemplo, gerencia pacotes, dependências e ambientes virtuais para linguagens como Python e R, permitindo criar ambientes isolados com versões específicas de pacotes e dependências. Já o **renv** (R Environment) é específico para projetos R, criando um ambiente de desenvolvimento reproduzível.

Essas ferramentas oferecem a vantagem de menor sobrecarga de recursos e são fáceis de configurar e utilizar, promovendo a reprodutibilidade de ambientes de desenvolvimento para linguagens específicas. No entanto, oferecem menor isolamento comparado às VMs

e containers e dependem da compatibilidade do sistema operacional e das versões dos pacotes.

A recomendação para os pesquisadores que desejem ter seus trabalhos transparentes e reprodutíveis é que eles entendam das duas últimas soluções, por exemplo, num ambiente R, de containers + renv. Na verdade, essas duas soluções devem caminhar juntas, pois no contexto da maioria dos workflows (pipelines) de pesquisa a construção de containers é facilitada pela aplicação correta dos pacotes de controle de ambiente (Conda, renv, etc.).

No entanto, a computação em nuvens também nos agraciou com outras soluções que facilitam a reprodutibilidade, transparência e colaboração em pesquisas empíricas. Plataformas de notebooks na nuvem como [Google Colab](#) e [Posit Cloud](#) (anteriormente conhecido como RStudio Cloud) permitem compartilhar notebooks rodando num mesmo hardware, mas os usuários precisam garantir que as dependências e versões de pacotes sejam corretamente especificadas e gerenciadas.

No [JupyterHub](#) temos proposta parecida, mas ele nos dá um controle melhor sobre o ambiente, já que um administrador pode configurar e manter as dependências necessárias de um projeto colaborativo. O [Binder](#) é uma plataforma open-source que transforma repositórios Git em ambientes executáveis, focando principalmente em notebooks Jupyter. Ele facilita a execução de notebooks a partir de repositórios Git e garante que as dependências especificadas no repositório sejam instaladas, mas depende da configuração correta dos arquivos de dependências.

O [Code Ocean](#) e [Nextjournal](#) são soluções específicas para a reprodutibilidade de pesquisas científicas, focando na facilidade de uso e na acessibilidade para a comunidade acadêmica. O Code Ocean permite que os cientistas agrupem código, dados, resultados, metadados e um ambiente computacional em um único lugar — chamado de “cápsula”, cujos resultados podem ser reproduzidos por qualquer pessoa num simples botão (Clyburne-Sherin et al., 2019). O Nextjournal é uma plataforma de colaboração e publicação de notebooks interativos, que permite a execução de código em diferentes linguagens, como o Code Ocean, e a criação de artigos científicos interativos. Essas duas soluções oferecem um ambiente integrado, com interface gráfica intuitiva para configurar ambientes de desenvolvimento e execução, o que facilita para pesquisadores sem conhecimento técnico avançado. No entanto, são soluções comerciais e podem ter limitações em termos de recursos e personalização.

As soluções apresentadas sobrepostas à nuvem do lado direito na Figura 7.1 podem ser consideradas soluções intermediárias aos containers tradicionais, no sentido de que elas utilizam containerização para criar ambientes reprodutíveis, mas abstraem a complexidade técnica e fornecem interfaces mais amigáveis e específicas para a comunidade científica. Elas são ideais para pesquisadores que buscam simplicidade e reprodutibilidade sem a necessidade de se aprofundar nos detalhes técnicos dos containers. Essas plataformas tornam a poderosa tecnologia de containerização acessível e aplicável ao contexto da pesquisa científica.

Podemos dizer que em termos de níveis de reprodutibilidade, Google Colab e Posit Cloud atendem a um nível básico, porque a reprodutibilidade pode ser limitada pela variabilidade das dependências das sessões e cabe ao usuário uma configuração cuidadosa dos pacotes e versões. Binder e JupyterHub fornecem um nível intermediário de reprodutibilidade, pois apesar de um melhor controle sobre o ambiente, requer configuração e

manutenção adequadas das dependências. Por fim, Code Ocean e Nextjournal oferecem um alto nível de reprodutibilidade, pois são ambientes integrados para criar, executar e compartilhar projetos de pesquisa reprodutíveis.

i *Leveraging Containers for Reproducible Psychological Research*

O artigo de Wiebels & Moreau (2021) discute a importância e a aplicação das práticas de ciência aberta na pesquisa. Eles destacam que, desde 2019, cerca de 35% dos pesquisadores de psicologia adotaram práticas de CA, um aumento significativo em relação aos 5% de apenas cinco anos antes.

O artigo, inicialmente, discute o pacote [renv](#), que gerencia dependências em R armazenando o código-fonte de todos os pacotes R usados em um projeto. No entanto, eles observam que essa abordagem não lida com dependências do sistema ou dependências de outras linguagens de programação e pacotes de software.

Para resolver essas limitações, os autores apresentam os “containers”, que permitem empacotar todo o código e dependências para garantir que as análises sejam executadas de maneira confiável em uma variedade de sistemas operacionais e versões de software. Eles descrevem a lógica por trás dos containers, o que são e os problemas práticos que podem resolver.

Os autores explicam que o ideal é “empacotar” (isolar) todo o ambiente de computação de forma que qualquer pessoa em qualquer computador possa examinar e replicar nosso trabalho, independentemente do software instalado, drivers e sistemas operacionais. Uma maneira popular de alcançar esse objetivo é com máquinas virtuais (VMs), mas as VMs podem ficar muito grandes e lentas, o que pode tornar o compartilhamento e o uso delas impraticáveis. Os containers também isolam ambientes de computação, mas usam menos recursos do que as VMs.

Apesar de suas vantagens, a contêinerização ainda é raramente usada na psicologia, talvez por falta de conscientização ou porque o uso - e especialmente a construção - de containers pode parecer assustador para aqueles que não têm formação em ciência da computação. Para superar essa barreira, os autores usam a plataforma de contêiner [Docker](#) e se concentram na linguagem R.

Eles explicam que o Docker é um projeto de contêinerização de código aberto baseado em Linux; ou seja, o Linux está rodando dentro dos containers, mesmo que estejamos em um computador Windows ou Mac. Eles também esclarecem que um número ilimitado de containers pode ser criado a partir de uma imagem e, ao contrário das imagens, os containers podem ser modificados enquanto estão em execução.

Os autores comparam uma imagem Docker a uma receita de bolo e o container Docker correspondente a um bolo acabado. A receita contém as instruções para fazer o bolo, pode ser usada para fazer quantos bolos você quiser e pode ser compartilhada para permitir que outros façam o mesmo bolo. Todos que usam a receita acabam com o mesmo tipo de bolo, que pode ser modificado adicionando, por exemplo, cobertura ou confeitaria. No entanto, sua adição de cobertura e minha adição de confeitaria não mudarão a receita, e da próxima vez que usarmos a receita, teremos o mesmo bolo de antes.

Os autores escolheram usar o Docker para o tutorial por cinco razões principais.

Primeiro, o Docker é uma das principais plataformas de contêiner e foi estabelecido como uma prática recomendada em vários campos de pesquisa. Segundo, o Docker funciona em todos os principais sistemas operacionais (Linux, macOS e Windows). Terceiro, os containers Docker são fáceis de usar, muito leves e rápidos. Quarto, as imagens Docker podem ser armazenadas e compartilhadas gratuitamente no registro central Docker Hub. Finalmente, graças à sua crescente popularidade, o Docker se beneficia de uma grande comunidade de usuários e um rico ecossistema de ferramentas relacionadas, como o Rocker, que fornece containers com ambientes R.

Os autores concluem que a contêinerização é um passo importante para tornar a pesquisa reprodutível, fornecendo um ambiente de computação consistente que pode ser usado por todos os colaboradores ao longo do projeto e que pode ser compartilhado junto com a publicação. Compartilhar um container após a finalização de um projeto de pesquisa garante que suas análises sejam reprodutíveis. Nesse contexto, a proficiência em contêinerização, entre o conjunto mais amplo de ferramentas computacionais exigidas por um cientista moderno, pode se revelar um investimento valioso para cientistas comportamentais em todos os estágios de carreira.

Capítulo 8

IA Aplicada à Pesquisa Reprodutível

8.1 Aplicações da IA neste Curso

Este curso adota o uso de **Inteligência Artificial Generativa (IA)**  como ferramenta de apoio metodológico e pedagógico, alinhado às diretrizes éticas e responsáveis propostas por Sampaio et al. (2024). A IA é utilizada exclusivamente em funções complementares, que ampliam a eficiência do trabalho científico e a acessibilidade dos conteúdos, **sem substituir o trabalho intelectual, crítico e autoral do pesquisador**.

Consideramos que o uso da IA generativa na pesquisa científica representa um **caminho sem volta** . Por isso, o ensino de CA e reprodutibilidade deve incorporar essa realidade — tanto no processo de **produção do conhecimento**, quanto na **transmissão e avaliação** do aprendizado. Ignorar essa transformação tecnológica seria negligenciar o potencial de inovação, transparência e inclusão que ela oferece para a prática da ciência aberta.

Seguindo os princípios de **preservação da agência humana, transparência e uso eticamente orientado** preconizados por Sampaio et al. (2024), a IA tem sido empregada nas seguintes funções ao longo do desenvolvimento e execução deste curso:

1.  **Resumo de materiais didáticos:** Síntese de artigos científicos, documentações técnicas e materiais extensos para facilitar a compreensão inicial e identificação de pontos-chave, sempre com revisão e contextualização humana.
2.  **Auxílio na codificação:** Suporte para escrita, depuração e otimização de códigos em R, Python e outras linguagens, acelerando o desenvolvimento de exemplos práticos e soluções técnicas.
3.  **Reflexão e estruturação de conteúdos:** Apoio na concepção de roteiros didáticos, organização lógica de tópicos e desenvolvimento de sequências de aprendizagem mais coerentes.
4.  **Busca e seleção de literatura:** Identificação preliminar de referências relevantes, mapeamento de debates atuais e descoberta de fontes complementares,

sempre com curadoria humana final.

5. 🎨 **Elaboração de imagens e vídeos:** Criação de elementos visuais e recursos multimídia para enriquecer a experiência de aprendizado e tornar conceitos complexos mais acessíveis. Nessa função utilizamos “com força”, pois temos zero habilidade artística ou sensibilidade estética 😊.
6. ✅ **Revisão de conteúdo:** Suporte na revisão gramatical, clareza textual e coerência argumentativa dos materiais didáticos, mantendo a autoria e decisão final humanas.
7. 🌐 **Tradução de literatura:** Tradução preliminar de materiais em idiomas estrangeiros para ampliar o acesso a recursos internacionais, com revisão técnica posterior.
8. 🎓 **Ensino preliminar de tópicos:** Exploração inicial de áreas fora da zona de conhecimento consolidado do instrutor, servindo como ponto de partida para aprofundamento posterior com fontes especializadas.

8.1.1 🌀 Princípios Norteadores

Conforme Sampaio et al. (2024), a IA deve ser utilizada como **apoio à expressão humana** — e não como substituto da reflexão, da análise crítica ou da autoria. É essa perspectiva que orienta todas as aplicações tecnológicas neste curso. Os autores destacam que a **supervisão humana contínua** é essencial para evitar que a IA incorpore erros, vieses ou problemas de integridade acadêmica.

Ademais, seguimos os seguintes princípios práticos estabelecidos no guia:

- ✨ **Transparência:** Documentar quando e como a IA foi utilizada na produção de materiais
- 🌀 **Integridade acadêmica:** Garantir originalidade, evitar plágio e preservar direitos autorais
- 👤 **Agência humana:** Manter o pesquisador/instrutor como responsável final por todas as decisões
- 🧠 **Letramento em IA:** Desenvolver compreensão crítica sobre limitações e potencialidades das ferramentas
- 📦 **Uso complementar:** Empregar a IA como ferramenta auxiliar, nunca como substituta do trabalho científico

8.1.2 ✨ Contexto da Ciência Aberta

O uso transparente e documentado de ferramentas de IA alinha-se perfeitamente com os princípios da **CA** 📖: **transparência, reprodutibilidade e compartilhamento** de processos e recursos. Ao adotar IA de forma ética e responsável, contribuímos para uma cultura científica mais eficiente, inclusiva e, sobretudo, **transparente sobre seus métodos e ferramentas**.

Nenhum conteúdo é gerado de forma integral ou automatizada sem supervisão docente. Todo material passou por processo de curadoria, validação e contextualização humana, respeitando os princípios de autoria, originalidade e responsabilidade acadêmica (Sampaio et al., 2024).

Referências

- Albano, C. S., Pedroso, P. de O., & Caetano, D. O. (2023). Ciência Aberta: Um Panorama Sobre as Publicações No Cenário Brasileiro. *Saber Científico*, 12(1), 1–12.
- Alessandroni, N., & Byers-Heinlein, K. (2022). Ten Strategies to Foster Open Science in Psychology and Beyond. *Collabra: Psychology*, 8(1), 57545. <https://doi.org/10.1525/collabra.57545>
- Baker, D. H., Berg, M., Hansford, K., Quinn, B. P. A., Segala, F. G., & English, E. (2023). *ReproduceMe: Lessons from a Pilot Project on Computational Reproducibility* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/k8d4u>
- Baker, M. (2016). 1,500 Scientists Lift the Lid on Reproducibility. *Nature*, 533(7604), 452–454. <https://doi.org/10.1038/533452a>
- Behera, P. K., & Jain, S. J. (2023). *Zotero – An Open-Source Reference Management Software: A Practical Manual*. OSF. <https://doi.org/10.17605/OSF.IO/8S73R>
- Bernard, C. (2023). Stop Reproducing the Reproducibility Crisis. *Eneuro*, 10(2), ENEURO.0032–23.2023. <https://doi.org/10.1523/ENEURO.0032-23.2023>
- Bezjak, S., Clyburne-Sherin, A., Conzett, P., Fernandes, P., Görögh, E., Helbig, K., Kramer, B., Labastida, I., Niemeyer, K., Psomopoulos, F., Ross-Hellauer, T., Schneider, R., Tennant, J., Verbakel, E., Brinken, H., & Heller, L. (2018). *Open Science Training Handbook*. Zenodo. <https://doi.org/10.5281/ZENODO.1212496>
- Broman, K. W., & Woo, K. H. (2018). Data Organization in Spreadsheets. *The American Statistician*, 72(1), 2–10. <https://doi.org/10.1080/00031305.2017.1375989>
- Bryan, J. (2018). Excuse Me, Do You Have a Moment to Talk About Version Control? *The American Statistician*, 72(1), 20–27. <https://doi.org/10.1080/00031305.2017.1399928>
- Caballero-Rivero, A., Sánchez-Tarragó, N., & Santos, R. N. M. dos. (2019). Práticas de Ciência Aberta da comunidade acadêmica brasileira: estudo a partir da produção científica. *Transinformação*, 31, e190029. <https://doi.org/10.1590/2318-0889201931e190029>
- Chopik, W. J., Bremner, R. H., Defever, A. M., & Keller, V. N. (2018). How (and Whether) to Teach Undergraduates About the Replication Crisis in Psychological Science. *Teaching of Psychology*, 45(2), 158–163. <https://doi.org/10.1177/0098628318762900>
- Clyburne-Sherin, A., Fei, X., & Green, S. A. (2019). Computational Reproducibility via Containers in Psychology. *Meta-Psychology*, 3. <https://doi.org/10.15626/MP.2018.892>
- Committee on Reproducibility and Replicability in Science, Board on Behavioral, Cognitive, and Sensory Sciences, Committee on National Statistics, Division of Behavioral and Social Sciences and Education, Nuclear and Radiation Studies Board, Division on

- Earth and Life Studies, Board on Mathematical Sciences and Analytics, Committee on Applied and Theoretical Statistics, Division on Engineering and Physical Sciences, Board on Research Data and Information, Committee on Science, Engineering, Medicine, and Public Policy, Policy and Global Affairs, & National Academies of Sciences, Engineering, and Medicine. (2019). *Reproducibility and Replicability in Science* (p. 25303). National Academies Press. <https://doi.org/10.17226/25303>
- Crüwell, S., Van Doorn, J., Etz, A., Makel, M. C., Moshontz, H., Niebaum, J. C., Orben, A., Parsons, S., & Schulte-Mecklenbeck, M. (2019). Seven Easy Steps to Open Science: An Annotated Reading List. *Zeitschrift für Psychologie*, 227(4), 237–248. <https://doi.org/10.1027/2151-2604/a000387>
- Dogucu, M., & Çetinkaya-Rundel, M. (2022). Tools and Recommendations for Reproducible Teaching. *Journal of Statistics and Data Science Education*, 30(3), 251–260. <https://doi.org/10.1080/26939169.2022.2138645>
- Domingos, A., & Batista, I. R. (2021). A map for transparency and replicability in empirical social science: the TIER Protocol. *Revista Política Hoje*, 30(1), 40–86. <https://doi.org/10.51359/1808-8708.2021.245776>
- European Commission. Directorate General for Research and Innovation. (2017). *Providing Researchers with the Skills and Competencies They Need to Practise Open Science*. Publications Office. <https://data.europa.eu/doi/10.2777/121253>
- Fanelli, D. (2018). Is Science Really Facing a Reproducibility Crisis, and Do We Need It To? *Proceedings of the National Academy of Sciences*, 115(11), 2628–2631. <https://doi.org/10.1073/pnas.1708272114>
- Freedman, L. P., Cockburn, I. M., & Simcoe, T. S. (2015). The Economics of Reproducibility in Preclinical Research. *PLOS Biology*, 13(6), e1002165. <https://doi.org/10.1371/journal.pbio.1002165>
- Gilroy, S. P., & Kaplan, B. A. (2019). Furthering Open Science in Behavior Analysis: An Introduction and Tutorial for Using GitHub in Research. *Perspectives on Behavior Science*, 42(3), 565–581. <https://doi.org/10.1007/s40614-019-00202-5>
- Heinz, M., & Miranda, M. (2024). Ciência Aberta: Argumentos e Desafios Para Sua Legitimação Científica. *Em Questão*, 30. <https://doi.org/10.1590/1808-5245.30.135618>
- Hertz, M. I., & McNeill, A. S. (2024). Eleven quick tips for properly handling tabular data. *PLOS Computational Biology*, 20(11), e1012604. <https://doi.org/10.1371/journal.pcbi.1012604>
- Janz, N. (2015). Bringing the Gold Standard into the Classroom: Replication in University Teaching. *International Studies Perspectives*, n/a–n/a. <https://doi.org/10.1111/insp.12104>
- Kathawalla, U.-K., Silverstein, P., & Syed, M. (2021). Easing Into Open Science: A Guide for Graduate Students and Their Advisors. *Collabra: Psychology*, 7(1), 18684. <https://doi.org/10.1525/collabra.18684>
- Klein, O., Hardwicke, T. E., Aust, F., Breuer, J., Danielsson, H., Mohr, A. H., IJzerman, H., Nilsson, G., Vanpaemel, W., & Frank, M. C. (2018). A Practical Guide for Transparency in Psychological Science. *Collabra: Psychology*, 4(1), 20. <https://doi.org/10.1525/collabra.158>
- Li, L., Parulian, N., & Ludäscher, B. (2021). Automatic Module Detection in Data Cleaning Workflows: Enabling Transparency and Recipe Reuse. *International Journal of Digital Curation*, 16(1), 11–11. <https://doi.org/10.2218/ijdc.v16i1.771>
- Limongi, R., & Rogers, P. (2025a). Open Science in Three Acts: Foundations, Practice, and Implementation - First Act. *BAR - Brazilian Administration Review*, 22(1),

- e250079. <https://doi.org/10.1590/1807-7692bar2025250079>
- Limongi, R., & Rogers, P. (2025b). Open Science in Three Acts: Foundations, Practice, and Implementation - Second Act. *BAR - Brazilian Administration Review*, 22(2), e250116. <https://doi.org/10.1590/1807-7692bar2025250116>
- McAleer, P., Stack, N., Woods, H., DeBruine, L. M., Paterson, H., Nordmann, E., Kuepper-Tetzel, C. E., & Barr, D. J. (2022). *Embedding Data Skills in Research Methods Education: Preparing Students for Reproducible Research* [Preprint]. PsyArXiv. <https://doi.org/10.31234/osf.io/hq68s>
- Mendes-Da-Silva, W. (2023). What Lectures and Research in Business Management Need to Know About Open Science. *Revista de Administração de Empresas*, 63(4), e0000-0033. <https://doi.org/10.1590/s0034-759020230408x>
- Moreau, D., Wiebels, K., & Boettiger, C. (2023). Containers for Computational Reproducibility. *Nature Reviews Methods Primers*, 3(1), 50. <https://doi.org/10.1038/s43586-023-00236-9>
- Munafò, M. R., Nosek, B. A., Bishop, D. V. M., Button, K. S., Chambers, C. D., Percie Du Sert, N., Simonsohn, U., Wagenmakers, E.-J., Ware, J. J., & Ioannidis, J. P. A. (2017). A Manifesto for Reproducible Science. *Nature Human Behaviour*, 1(1), 0021. <https://doi.org/10.1038/s41562-016-0021>
- Neto, S. C., Willinsky, J., & Alperin, J. P. (2016). Measuring, Rating, Supporting, and Strengthening Open Access Scholarly Publishing in Brazil. *Education Policy Analysis Archives*, 24, 54-54. <https://doi.org/10.14507/epaa.24.2391>
- Oddone, N., & Souza, L. V. R. L. (2024). Acesso ao conhecimento no contexto da ciência aberta: o segredo da popularidade do Sci-Hub. *Revista Digital de Biblioteconomia e Ciência da Informação*, 22. <https://doi.org/https://doi.org/10.20396/rdbci.v22i00.8673883>
- Olson, E., Pfeiffer, N., Call, M., & Steger, D. (2022). *Getting Started on OSF*. <https://doi.org/10.17605/OSF.IO/YAQE8>
- Proske, A., Wenzel, C., & Queitsch, M. B. (2023). Reference Management Systems. Em O. Kruse, C. Rapp, C. M. Anson, K. Benetos, E. Cotos, A. Devitt, & A. Shibani (Eds.), *Digital Writing Technologies in Higher Education* (pp. 215-230). Springer International Publishing. https://doi.org/10.1007/978-3-031-36033-6_14
- Protzko, J., Krosnick, J., Nelson, L., Nosek, B. A., Axt, J., Berent, M., Buttrick, N., DeBell, M., Ebersole, C. R., Lundmark, S., MacInnis, B., O'Donnell, M., Perfecto, H., Pustejovsky, J. E., Roeder, S. S., Walleczek, J., & Schooler, J. W. (2023). High Replicability of Newly Discovered Social-Behavioural Findings Is Achievable. *Nature Human Behaviour*. <https://doi.org/10.1038/s41562-023-01749-9>
- Pruim, R., Gîrjău, M.-C., & Horton, N. J. (2023). Fostering better coding practices for data scientists. *Harvard Data Science Review*, 5(3). <https://doi.org/10.1162/99608f92.97c9f60f>
- Rezende, L. V. R., & Falgueras, E. A. (2020). Estado Da Arte Dos Marcos Regulatórios Brasileiros Rumo à Ciência Aberta. *Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação*, 25, 01-25. <https://doi.org/10.5007/1518-2924.2020.e71370>
- Rodrigues, B. (2023). *Building reproducible analytical pipelines with R*. <https://raps-with-r.dev/>
- Rogers, P. (2024). Best Practices for Your Confirmatory Factor Analysis: A JASP and Lavaan Tutorial. *Behavior Research Methods*. <https://doi.org/10.3758/s13428-024-02375-7>
- Rogers, P., & Limongi, R. (2025). Open Science in Three Acts: Foundations, Practice,

- and Implementation - Third Act. *BAR - Brazilian Administration Review*, 22(3), e250162. <https://doi.org/10.1590/1807-7692bar2025250162>
- Sampaio, R. C., Sabbatini, M., & Limongi, R. (2024). *Diretrizes para o uso ético e responsável da inteligência artificial generativa: um guia prático para pesquisadores*. Sociedade Brasileira de Estudos Interdisciplinares da Comunicação - Intercom. <https://portcom.intercom.org.br/ebooks/detalheEbook.php?id=57203>
- Silva, F. C. C. D., & Silveira, L. D. (2019). O Ecossistema Da Ciência Aberta. *Transinformação*, 31, e190001. <https://doi.org/10.1590/2318-0889201931e190001>
- Silveira, L. D., Calixto Ribeiro, N., Melero, R., Mora-Campos, A., Piraquive-Piraquive, D. F., Uribe Tirado, A., Machado Borges Sena, P., Polanco Cortés, J., Santillán-Aldana, J., Couto Corrêa Da Silva, F., Ferreira Araújo, R., Enciso Betancourt, A. M., & Fachin, J. (2023). Taxonomia Da Ciência Aberta: Revisada e Ampliada. *Encontros Bibli: revista eletrônica de biblioteconomia e ciência da informação*, 28. <https://doi.org/10.5007/1518-2924.2023.e91712>
- Soderberg, C. K. (2018). Using OSF to Share Data: A Step-by-Step Guide. *Advances in Methods and Practices in Psychological Science*, 1(1), 115–120. <https://doi.org/10.1177/2515245918757689>
- Sullivan, I., DeHaven, A., & Mellor, D. (2019). Open and Reproducible Research on Open Science Framework. *Current Protocols Essential Laboratory Techniques*, 18(1), e32. <https://doi.org/10.1002/cpet.32>
- Thomas, P. A. (2023). *Using Zotero for Citation Management: A Step-by-Step Guide to Organizing and Citing Your Research*. University of Kansas Libraries. <https://kuscholarworks.ku.edu/handle/1808/34983>
- Toelch, U., & Ostwald, D. (2018). Digital Open Science—Teaching Digital Tools for Reproducible and Transparent Research. *PLOS Biology*, 16(7), e2006022. <https://doi.org/10.1371/journal.pbio.2006022>
- UNESCO. (2021). *UNESCO Recommendation on Open Science*. UNESCO. <https://doi.org/10.54677/MNMFH546>
- Vicente-Saez, R., & Martinez-Fuentes, C. (2018). Open Science Now: A Systematic Literature Review for an Integrated Definition. *Journal of Business Research*, 88, 428–436. <https://doi.org/10.1016/j.jbusres.2017.12.043>
- Vuorre, M., & Curley, J. P. (2018). Curating Research Assets: A Tutorial on the Git Version Control System. *Advances in Methods and Practices in Psychological Science*, 1(2), 219–236. <https://doi.org/10.1177/2515245918754826>
- Weidmann, N. B. (2023). *Data Management for Social Scientists: From Files to Databases* (1.^a ed.). Cambridge University Press. <https://doi.org/10.1017/9781108990424>
- Wickham, H. (2014). Tidy Data. *Journal of Statistical Software*, 59, 1–23. <https://doi.org/10.18637/jss.v059.i10>
- Wickham, H., Cetinkaya-Rundel, M., & Grolemund, G. (2023). *R for Data Science: Import, Tidy, Transform, Visualize, and Model Data*. O'Reilly Media. <https://r4ds.hadley.nz/>
- Wiebels, K., & Moreau, D. (2021). Leveraging Containers for Reproducible Psychological Research. *Advances in Methods and Practices in Psychological Science*, 4(2), 251524592110178. <https://doi.org/10.1177/25152459211017853>
- Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology*, 13(6), e1005510. <https://doi.org/10.1371/journal.pcbi.1005510>
- Zandonella Callegher, C., & Massidda, D. (2022). *The open science manual: Make your scientific research accessible and reproducible*. <https://doi.org/10.5281/zenodo.>

6521850

